

# 基于图像深度学习的无线电信号识别

周鑫, 何晓新, 郑昌文

(中国科学院软件研究所天基综合信息系统重点实验室, 北京 100190)

**摘 要:** 提出了一种利用图像深度学习解决无线电信号识别问题的技术思路。首先把无线电信号具象化为一张二维图片, 将无线电信号识别问题转化为图像识别领域的目标检测问题; 进而充分利用人工智能在图像识别领域的先进成果, 提高无线电信号识别的智能化水平和复杂电磁环境下的识别能力。基于该思路, 提出了一种基于图像深度学习的无线电信号识别算法——RadioImageDet 算法。实验结果表明, 所提算法能有效识别无线电信号的波形类型和时/频坐标, 在实地采集的 12 种、4 740 个样本的数据集中, 识别准确率达到 86.04%, mAP 值达到 77.72, 检测时间在中等配置的台式计算机上仅需 33 ms, 充分验证了所提思路的可行性和所提算法的有效性。

**关键词:** 无线电信号识别; 深度学习; 射频机器学习; 卷积神经网络; 图像目标检测

**中图分类号:** TN971

**文献标识码:** A

**doi:** 10.11959/j.issn.1000-436x.2019167

## Radio signal recognition based on image deep learning

ZHOU Xin, HE Xiaoxin, ZHENG Changwen

Science & Technology on Integrated Information System Laboratory, Institute of Software Chinese Academy of Sciences, Beijing 100190, China

**Abstract:** A technical idea was innovatively proposed that uses image deep learning to solve the problem of radio signal recognition. First, the radio signal was transformed into a two-dimensional picture, and the radio signal recognition problem was transformed into the object detection problem in the field of image recognition. Then, the advanced achievements about image recognition were used to improve the intelligence and ability of radio signal recognition in complex electromagnetic environment. Based on the proposed idea, a novel radio signal recognition algorithm named RadioImageDet was proposed. The experimental results show that the algorithm can effectively identify the waveform types and time/frequency coordinates of radio signals. After training and testing on the self-collected data set with 12 types and 4 740 samples, the accuracy reaches 86.04% and the mAP value reaches 77.72, while the detection time is only 33 ms on the medium configured desktop computer.

**Key words:** radio signal recognition, deep learning, radio frequency machine learning, convolutional neural network, image object detection

### 1 引言

近年来, 随着无线通信技术的发展, 特别是物联网的兴起, 无线电波已成为连通万物的重要载体。然而, 无线电波开放性的特点使其容易受到干扰和非法利用, 导致正常通信系统受扰甚至中断, 进而威胁社会和国家安全。因此, 加强无线电监测

与识别, 特别是在机场、边境等重点区域及重大活动现场的无线电监管, 具有重要的现实意义和迫切需求。

无线电信号识别技术最初主要用于军事电子战和政府频谱监管领域, 近年来, 随着频谱共享需求的提升和认知无线电技术的发展, 又逐渐成为商业通信领域关注的焦点<sup>[1]</sup>。早期的无线电信号识别

收稿日期: 2018-07-30; 修回日期: 2019-04-11

基金项目: 国防科技创新特区基金资助项目

**Foundation Item:** The Special Fund for National Defense Technology Innovation

技术,是利用各种频谱采集设备采集空中射频信号,经过处理后,以频谱图、瀑布图、余晖图等可视化方式展现出来,由专业人员分析信号时频特征并寻找目标信号<sup>[2]</sup>。这种技术对操作人员的专业素质要求非常高,而且当监测时间变长或无线电信号较多时,人工分析效率和准确率也会大幅下降。

目前,比较流行的无线电信号识别方式是先由本领域专家挑选信号关键特征,如功率谱密度最大值<sup>[3]</sup>、信号包络峭度<sup>[4]</sup>、瞬时相位标准差<sup>[5]</sup>、相位脉冲个数<sup>[4]</sup>、循环谱<sup>[6-7]</sup>、高阶矩<sup>[8-9]</sup>等时/频域信号特征,然后利用传统的信号处理算法计算特征参数值,最后基于固定规则或者机器学习的方法进行分类<sup>[10]</sup>。通常,一个模型需要选取其中的几项甚至十几项特征作为模型输入,计算复杂度非常高,很难实际部署使用。同时,受信号波形多样性和多径衰落效应的影响,该方式在特征选择和判决准则方面也缺乏普适性。

人工智能在模式识别任务中具有独特优势,近年来,在图像/语音识别、自然语言处理、医疗、金融等很多领域取得了很大的成就,引起了社会各界的热切关注<sup>[11]</sup>。无线电信号识别本质上也是一种特殊的模式识别,因此本文认为,可以将人工智能与传统无线电信号识别技术深度融合,利用人工智能的机器学习方法,特别是深度学习算法,自动提取无线电波的模式特征,避免基于经验的人工特征提取,提高复杂电磁环境下无线电信号的识别能力。

基于这一设想,本文提出了一种利用图像深度学习方法解决无线电信号识别问题的技术思路:首先把无线电信号具象化为一张二维图片,将无线电信号识别问题转化为图像识别领域的目标检测问题;进而充分利用人工智能在图像识别领域的先进成果,提高无线电信号识别的智能化水平和复杂电磁环境下的识别能力。基于该思路,本文提出了一种基于图像深度学习的无线电信号识别算法——RadioImageDet 算法,并通过实物系统实验,验证了所提思路的可行性和 RadioImageDet 算法的有效性。

## 2 相关工作

早在 20 世纪 90 年代,传统机器学习算法,如朴素贝叶斯、神经网络、决策树等,已经在无线电调制识别领域中得到了应用<sup>[12-14]</sup>,但受限于当时的技术发展水平,仅利用机器学习算法根据人工提取出的信号特征进行分类,具体流程如图 1 所示。




图 1 基于传统机器学习的无线电信号识别流程

近年来,随着计算机技术和深度神经网络技术的飞速发展,上述限制逐渐被打破。2016 年,受到深度神经网络在图像识别领域巨大成功的鼓舞,O'shea 及其团队连续发表多篇论文,研究深度学习技术在无线电通信与识别领域应用的方法与问题<sup>[15-18]</sup>,开启了无线电识别从经验驱动的人造特征范式到数据驱动的表示学习范式的新纪元。同年,美国国防先进研究项目局(DARPA, Defense Advanced Research Projects Agency)宣布,将于 2017 年启动 SC2 挑战赛(The Spectrum Collaboration Challenge),旨在“将先进的机器学习能力应用于无线电领域,优化频谱使用策略,以缓解电磁频谱拥挤状态”<sup>[19]</sup>。这是 21 世纪 DARPA 组织的第三次挑战赛,前两次分别是 21 世纪初的自动化月球探测器挑战赛和 2015 年的机器人挑战赛。

2017 年,DARPA 频频推动 AI (artificial intelligence) 与无线电的融合。2017 年 3 月,DARPA 借助认知无线电领域的著名学术会议——DySPAN (IEEE International Symposium on Dynamic Spectrum Access Networks) 会议,组织了一场“ModRec”竞赛,要求各挑战者识别会议现场随机生成的 20 多种不同调制方式的信号波形,并声称“这是以更高效的方式管理电磁频谱的第一步”。同年 8 月,DARPA 启动了射频机器学习系统(RFMLS, radio frequency machine learning system)项目。作为 SC2 项目的补充,RFMLS 项目旨在“建立一种射频鉴别能力,能够从信号嘈杂聚集的频谱中分辨出独特和特殊的信号”,未来将应用于民用和军事领域。

下面从 3 个方面介绍与本文相关的研究工作。

### 2.1 基于 CNN 的调制方式识别

O'shea 在文献[15]中提出了一种基于端到端 CNN (convolutional neural network) 的调制识别模型。该模型是以时域 I/Q 采样为输入,经过两层卷积层(conv 层)和两层全链接层(dense 层)处理,输出信号的调制方式,具体结构如表 1 所示。文献[15]利用 GnuRadio 仿真生成了 11 种不同调制方式的信号作为训练和测试数据,通过与朴素贝叶斯、K 近

邻、决策树、多层感知机、支持向量机等传统机器学习方法进行对比,发现新算法与传统算法的最佳性能相当(传统算法采用以循环矩为基础构造的 32 个特征作为算法输入),证明了端到端 CNN 用于自动调制识别的有效性。

表 1 O'Shea 模型结构

网络层类型	输入尺寸	参数	激活函数
conv 层	128×2	3×1 卷积核 256 个特征映射 dropout 50%	ReLU
conv 层	256×126×2	3×2 卷积核 80 个特征映射 dropout 50%	ReLU
dense 层	9 920×1	256 个神经元 dropout 50%	ReLU
dense 层	256×1	11 个神经元	softmax

在此基础上,文献[20]采用分层识别的方法进行改进,即先用一个 CNN 网络区分模拟调制和数字调制,然后在先验知识基础上,用一个 CNN 网络识别具体的调制类型,最后用一个 CNN 网络识别调制的阶数。文献[21-22]从网络结构的角度进行改进,在 CNN 网络基础上,增加了时序特征的考虑,采用 CNN+LSTM(long short term memory)的网络结构进行调制方式识别。文献[23]在 O'shea 模型的基础上,在全连接层之前增加了一些边缘信息(即传统的循环平稳特征参数)作为输入,用于辅助 CNN 识别。该方法摒弃了完全以原始信息作为输入的前提条件,将传统的自动调制识别方法与新型的 CNN 网络结合,虽然提高了识别准确率,但遗留了很强的专家系统印记,且计算复杂度较高。

## 2.2 无线电个体识别

文献[15, 20-23]均属于调制方式识别,其输出需要联合其他信息,才能形成对电子侦察、频谱监管等应用有直接作用的结果。文献[24-27]则属于更高层的无线电个体识别,其结果可直接用于上述应用场景,因此更加符合“端到端”识别的理念。

文献[24]利用信号矩阵的次要特征值区分信号,通过矩阵特征值求解法进行无线电信号识别。文献[25]利用物理波形和射频器件的非线性杂散发射特征来区分信号发射源,并采用相位空间重构法进行分析识别。文献[26]利用信号功率谱密度的相似性来区分信号,并采用基于神经模糊的相似度测量方法进行分析识别。以上文献均属于传统的基于

专家系统的无线电识别方法,而 Schmidt 在文献[27]中提出了一种基于 CNN 的无线电通信标准识别模型,该模型结构与 O'Shea 模型相似,但以频域快速傅里叶变换(FFT, fast Fourier transform)的变换结果为输入,直接输出无线电通信标准名称,涉及 802.11、802.15.1、802.15.4 这 3 种通信标准。文献[28]也采用类似的 CNN 网络,但是以 Choi-Williams 时频分布变换结果作为模型输入,用于识别线性调频信号、Frank 序列、Costas 码等 8 种常见雷达波形。本文研究也属于无线电个体识别,其输入为包含时/频信息的频谱瀑布图,输出为信号的波形名称及其时/频坐标。

## 2.3 基于深度学习的图像目标检测

图像目标检测的任务是找出图像中所有感兴趣的物体,并确定其位置和大小,是计算机视觉领域的核心问题之一。2013 年以前,以多尺度形变部件模型(DPM, deformable part model)为代表的传统目标检测方法一直处于强势地位。2014 年, Girshick 等<sup>[29]</sup>提出了 R-CNN(region proposal CNN)算法框架,使目标检测的准确率取得巨大突破,并开启了基于深度学习的目标检测的研究热潮。随后, fast R-CNN<sup>[30]</sup>、faster R-CNN<sup>[31]</sup>、FPN(feature pyramid network)<sup>[32]</sup>、YOLOv2(you only look once)<sup>[33]</sup>、SSD(single shot multibox detector)<sup>[34]</sup>等一系列研究成果的出现,在检测速度、检测准确率等方面均有较大提高。目前,基于深度学习的图像目标检测主要分为两类:一类是以 R-CNN、faster R-CNN 为代表的基于区域提取(region proposal)的目标检测算法,另一类是以 YOLOv2、SSD 为代表的基于回归问题的端到端目标检测算法。前者需要把检测过程分为区域提取和检测分类两步;而后者直接在一个卷积网络中实现目标的定位和识别,简化了网络结构,在保证准确率的前提下,检测速度达到了实时检测的要求,因此,本研究将以 YOLOv2 为基础设计无线电信号识别模型。

## 3 RadioImageDet 算法模型设计

本文提出了一种基于图像深度学习的无线电信号识别算法——RadioImageDet 算法,该算法基于一种端到端卷积神经网络,能够在时/频混叠的复杂电磁环境下,同时识别出环境中存在的多个信号的波形类型,并可定位出这些信号各自的起止时间和频率范围。RadioImageDet 算法结构如图 2 所示。




图2 RadioImageDet 算法结构

RadioImageDet 算法由预处理模块和端到端目标检测模块两部分组成。预处理模块以观察窗口的原始 I/Q 采样数据为输入，经过离散傅里叶变换 (DFT, discrete Fourier transform)，将时域数据变换为更易识别的频域表达；再经过数据图像化处理，将连续多次 DFT 的结果组合成一张二维频谱瀑布图。端到端目标检测模块以预处理所得的频谱瀑布图为输入，经过 CNN 特征提取层，获取具象化的信号特征；再经过目标检测层，将抽象的特征转化为信号波形类型、时/频坐标等有确定含义的输出结果。其中，端到端目标检测模块采用端到端深度神经网络模型实现。本文所提端到端深度神经网络模型是以 YOLOv2 模型<sup>[33]</sup>为基础，通过迁移学习构建得到，因此称为 RadioYOLO 模型。

### 3.1 预处理模块

运行 RadioImageDet 算法首先要进行数据预处理，预处理的目的是将原始 I/Q 采样数据变换为一种更有利于自动特征提取和识别的表达形式。为了充分发挥卷积神经网络在特征提取方面的优势，降低计算复杂度，研究者希望预处理过程是无损且容易计算的。根据离散信号处理理论和现代通信系统原理，原始的 I/Q 采样数据就是数字通信系统后端处理的基本输入，任何复杂的数字信号处理算法都是在此基础上经过数学变换完成的，因此它天然蕴含了无损信息。这也是 O'shea 等直接选用 I/Q 采样数据作为神经网络输入的原因<sup>[15,20]</sup>。从数学角度分析，DFT 是对有限长 I/Q 采样数据的无损变换，如式(1)所示。

$$\text{DFT: } X[k] = \sum_{n=0}^{N-1} x[n] e^{-jk\left(\frac{2\pi}{N}\right)n}, k = 0, 1, \dots, N-1$$

$$\text{IDFT: } x[n] = \frac{1}{N} \sum_{k=0}^{N-1} X[k] e^{jk\left(\frac{2\pi}{N}\right)n}, n = 0, 1, \dots, N-1 \quad (1)$$

同时 DFT 的结果作为信号的频域表达形式，更有利于以电磁辐射为基础的无线电信号的识别<sup>[35]</sup>，因此，本文首先对原始 I/Q 采样数据进行 DFT，得到信号的频域表达，然后进行后续的处理，这与文

献[26, 27]的思路一致。

一次 DFT 运算的结果是一个一维复数序列，可以形象地认为是“一条线”，它表示某一时间点的频谱。但是，无线电信号波形总是随时间变化，仅观察某个“时间点”的特征很难准确识别信号，因此将连续多个时间点的观测结果堆叠组合成“一个面”，就可以同时表达时域和频域的信息特征，有助于提高信号识别率。在这个二维平面中，横轴表示频率，纵轴表示时间，元素值就是 DFT 的结果值。如果将元素值按图像灰度值进行映射，就可以绘出一张可视化的图片，该图片就是频谱瀑布图，如图3所示。因此，本文在 DFT 之后，增加了一个数据图像化处理过程，将连续多组 DFT 的结果组合成频谱瀑布图的格式，增加单个样本的时域信息量，便于后续卷积神经网络的处理和信号识别。




图3 频谱瀑布图合成示意

理论上，频谱瀑布图的尺寸为  $2MN$ ，其中，2 表示图片有 2 个通道，分别为通道 I 和通道 Q；N 表示 DFT 的点数；M 表示一张频谱瀑布图内合并的 DFT 结果的组数，其大小反映了一个样本的时间跨度，M 值越大，表征的时间跨度越长，计算也越复杂。为了方便运算，本文进行以下 3 个简化操作。

1) 为了简化图像转化操作，直接将 I/Q 两通道的数据按式(2)合并为一个通道 S，合并后的物理含义为功率密度。

$$S = \sqrt{S_I^2 + S_Q^2} \quad (2)$$

其中， $S_I$  和  $S_Q$  分别为 I/Q 通道的采样数据。

2) 为了利用 FFT 加快运算速度，N 取值应为 2 的正整数次幂，本文取  $N=512$ 。



表2 RadioYOLO 模型结构

层名称	输入尺寸	尺寸/步进	卷积核数
conv1	512×512	3×3 / 1×1	32
maxpool1	512×512	2×2 / 2×2	—
conv2	256×256	3×3 / 1×1	64
maxpool2	256×256	2×2 / 2×2	—
conv3	128×128	3×3 / 1×1	128
conv4	128×128	1×1 / 1×1	64
conv5	128×128	3×3 / 1×1	128
maxpool3	128×128	2×2 / 2×2	—
conv6	64×64	3×3 / 1×1	256
conv7	64×64	1×1 / 1×1	128
conv8	64×64	3×3 / 1×1	256
maxpool4	64×64	2×2 / 2×2	—
conv9	32×32	3×3 / 1×1	512
conv10	32×32	1×1 / 1×1	256
conv11	32×32	3×3 / 1×1	512
conv12	32×32	1×1 / 1×1	256
conv13	32×32	3×3 / 1×1	512
maxpool5	32×32	2×2 / 2×2	—
conv14	16×16	3×3 / 1×1	1 024
conv15	16×16	1×1 / 1×1	512
conv16	16×16	3×3 / 1×1	1 024
conv17	16×16	1×1 / 1×1	512
conv18	16×16	3×3 / 1×1	1 024
conv19	16×16	3×3 / 1×1	1 024
conv20	16×16	3×3 / 1×1	1 024
conv21	32×32	1×1 / 1×1	64
reshape1	32×32	2×2	256
concatenate1	16×16	—	1 280
conv22	16×16	3×3 / 1×1	1 024
conv23	16×16	1×1 / 1×1	85

$$\begin{cases} b_x = \text{Sigmoid}(t_x) + c_x \\ b_y = \text{Sigmoid}(t_y) + c_y \\ b_w = \text{anchor}_w e^{t_w} \\ b_h = \text{anchor}_h e^{t_h} \\ \text{conf} = \text{Sigmoid}(t_o) \end{cases} \quad (4)$$

其中,  $\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}}$

## 4 数据集构建

### 4.1 数据采集

在之前的无线电识别研究文献中,无线电数据通常来自仿真系统,如 Matlab 仿真软件、GnuRadio

仿真软件、信号发生器等,在实验室环境下,通过人工代码的控制,生成单一的或混合的有噪信号<sup>[15-17,20-23,27-28]</sup>。这种方式降低了数据获取和预处理的难度,方便利用先验信息进行数据标注,进而完成算法的验证。但是,受到信道衰落、时钟抖动、未知辐射源、接收机射频特性等复杂因素的影响,仿真数据与真实环境下的电磁环境往往存在较大差异,影响算法的真实性和实用性。

为此,本文利用 GnuRadio+USRP 软件无线电平台开发了一套高速频谱采集系统,用于采集真实环境下的频谱数据,如图 5 所示。USRP 设备是美国 NI 公司设计并生产的一款开源软件无线电模块,采用 AD9361 射频集成芯片方案,工作频段可覆盖 70~6 000 MHz。GnuRadio 是一个开源软件,利用普通计算机实现调制/解调、编解码等数字信号处理,与 USRP 配套使用可快速构建无线通信原理验证系统。该系统通过优化数据存储算法,最高可支持 50 MHz 瞬时带宽信号的分钟级无损保存,并可在预设频率集上自动扫频存储。




图5 高速频谱采集系统

本文的所有训练数据和测试数据均来自 GnuRadio+USRP 软件无线电平台的实地频谱采样。采样速率为 40 Msample/s, 单频点采样时长约 5 s, 采样地点包括北京中关村地区、天津滨海新区、天津渤海湾地区等共 7 个点位, 关注信号为常见 2G/3G/4G 蜂窝下行信号 12 种, 在包含关注信号的频段内, 每偏移 10 MHz 设立一个采样频点, 共计 34 个频点, 数据集总大小约为 650 GB。

表 3 是北京中关村地区三大运营商 2G/3G/4G 蜂窝下行频率分配表, 该表是基于相关标准文件, 利用仪器实际测量观察后校对所得。结合北京、天津等地的实测结果, 发现该表并不通用, 各运营商有可能在不同区域按照入网用户的数量和流量特征, 在一定条件下自主调整频率资源的分配, 使不同区域、相同频点处的信号类型可能有所不同。这对本研究的核心算法没有任何影响, 但会给数据标

注工作带来一定麻烦。

表 3 北京地区三大运营商 2G/3G/4G 蜂窝下行频率分配

频率范围/MHz	信号名称
870 ~ 885	Tele2G_DL_CDMA
935 ~ 955	Mobi2G_DL_GSM900
955 ~ 960	Uni2G_DL_GSM900
1 805 ~ 1 820	Mobi2G_DL_GSM1800
1 840 ~ 1 860	Uni4G_DL_FDD1800
1 860 ~ 1 875	Tele4G_DL_FDD1800
1 885 ~ 1 905	Mobi4G_TDLTE_20M
1 905 ~ 1 915	Mobi4G_TDLTE_10M
2 010 ~ 2 025	Mobi3G_TDSCDMA
2 110 ~ 2 130	Tele4G_DL_FDD2100
2 130 ~ 2 135	Uni3G_DL_WCDMA
2 135 ~ 2 140	Uni3G_DL_WCDMA
2 140 ~ 2 155	Uni4G_DL_FDD2100
2 575 ~ 2 595	Mobi4G_TDLTE_20M
2 595 ~ 2 615	Mobi4G_TDLTE_20M
2 615 ~ 2 635	Mobi4G_TDLTE_20M

## 4.2 数据预处理与标注

原始数据的格式为时域 I/Q 采样,必须先转换为频谱瀑布图,才能被 RadioYOLO 模型识别和处理。本文利用 Python 语言和相关第三方库,按照 3.1 节的预处理流程,编写了一系列脚本代码,将采集到的 650 GB 时域 I/Q 采样数据转变为 4 740 张 512 像素×512 像素的灰白图片,其中,训练集 3 792 张,测试集 948 张。

对训练样本和测试样本进行标注。使用传统方法进行数据标注是一项烦琐的人力劳动,而本文基于本数据集内待识别信号具有固定工作频段且持续存在的特点,设计了一种半自动的数据标注方法,大大减少了重复性工作。该方法先在每个点位、每个频点挑选 2 张频谱图进行人工标注,然后对该点位、该频点剩余的频谱图进行软件自动化标注,其标注坐标在 2 张人工标注的坐标范围内随机抖动,标注示例如图 6 所示。在以 1 860 MHz 为中心的 40 MHz 范围内,共存在一个 Uni4G\_DL\_FDD1800 信号(联通 4G 下行信号)和一个 Tele4G\_DL\_FDD1800 信号(电信 4G 下行信号),通过标注可视化边框,软件按一定格式自动在后台生成该图片的文本标注信息。

值得一提的是,虽然本文方法中数据的采集和标注都基于频率,而对于 2G/3G/4G 蜂窝等授权通信系统,直接利用频率信息几乎就可以完成信号识别,但这并不具备通用性,且无法完成核心技术的验证。因此,本文在模型训练和检测时,刻意回避了中心频率信息,只对接收机通带内的数字基带信号进行处理。这也意味着,即使某信号被调谐到未知的非授权频段内,也不会影响本算法的检测结果。

## 5 结果与分析

为了验证算法性能,本文在 Tensorflow 框架下,利用 Python 语言实现了 RadioYOLO 模型及整个 RadioImageDet 算法,并进行模型训练与测试。数据集来自预处理后的真实频谱数据,共包含 12 种

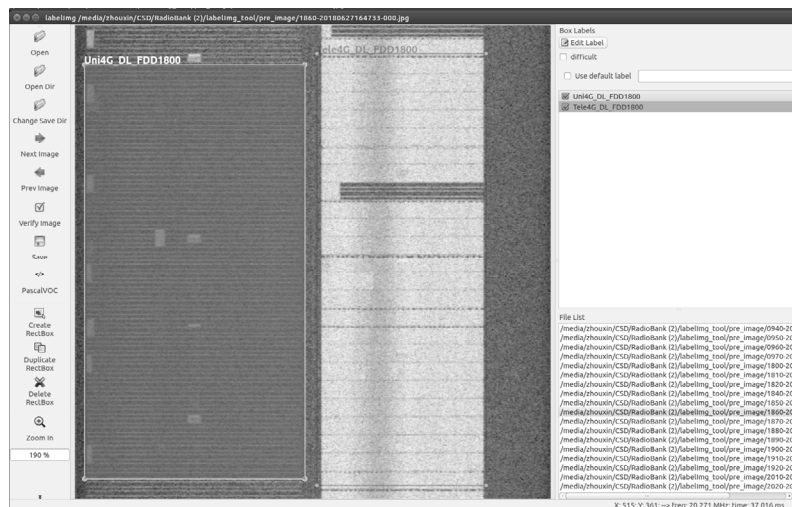


图 6 1 860 MHz 频点数据标注示例

2019167-7

信号,其中,训练样本 3 792 个,测试样本 948 个,具体数据特征见第 3 节。模型训练时,对训练集的前 80%进行训练,后 20%用于训练过程中的模型验证。模型训练优化器采用 Adam 算法,轮次(epoch)上限设为 50,批大小(batch\_size)设为 8。从实际运行结果来看,在采用 NVIDIA GTX1060T 显卡加速的条件下,训练速度约为 600 ms/batch,每轮耗时约为 230 s。单个样本的测试速度约为 33 ms,检测帧速为 30 frame/s,基本满足实时应用需求。

### 5.1 识别效果分析

识别结果的输出如图 7 所示,图中底部标签中的“√”表示该样本检测的结果是正确的,“×”表示该样本检测的结果出现错误。模型软件会根据识别的结果自动在原图上进行标框,并注明信号类型和识别置信度。如图 7(d)所示,在该时频观察窗内识别出 2 个信号,分别是 Mobi4G\_TDLTE\_20M 和 Mobi4G\_TDLTE\_10M 信号,2 个信号的时频范围分别用不同线形的方框围起来,并在顶部注明信号类型名称和检测置信度。由图可知,某些信号在频谱瀑布图上的特征非常明显,通过人眼可以轻易判决,这是本文开展本研究的基本前提和动机。从检测结果上看,人眼能够轻易识别的信号,在绝大多数情况下该算法模型也能正确识别,但也有一些例外,如图 7(g)所示。而人眼不易识别的信号,算法

模型出错的概率更高,如图 7(b)所示,但某些情况下也能正确识别,如图 7(e)所示。这些现象都直观地证明了利用图像深度学习方法进行无线电信号识别的可行性和有效性。

为了更严谨地评估算法的性能,需要更多的量化指标。如图 8 所示,对于二分类问题,根据真实值和预测值的结果,可以将整个样本集分为 4 个象限,分别是真正例(TP)、伪正例(FP)、真反例(TN)和伪反例(FN)。经过简单扩展,二分类混淆矩阵(confusion matrix)也可以变成多分类混淆矩阵。基于混淆矩阵,可以构造多种分类器性能评价指标。准确率(accuracy)是最常见的评价指标,其计算

式为  $\text{accuracy} = \frac{TP + TN}{P + N}$ ,即被分对的样本数占总

样本数的比例。通常来说,准确率越高,分类器越好。图 9 是本文模型测试结果的归一化混淆矩阵,其中纵轴表示真实标签,横轴表示预测标签,在  $12 \times 12$  的坐标内,用方框灰色的深浅表示数值,灰色越深、数值越大。一般而言,混淆矩阵对角线的灰色越深越好,其他坐标点的灰色越浅越好。由图可知,本文模型对于大部分信号识别性能很好,但是容易将 Uni4G\_DL\_FDD1800 和 Uni4G\_DL\_FDD2100 分别识别成 Tele4G\_DL\_FDD2100 和 Tele4G\_DL\_FDD 1800。根据混淆矩阵和准确率计算式,可

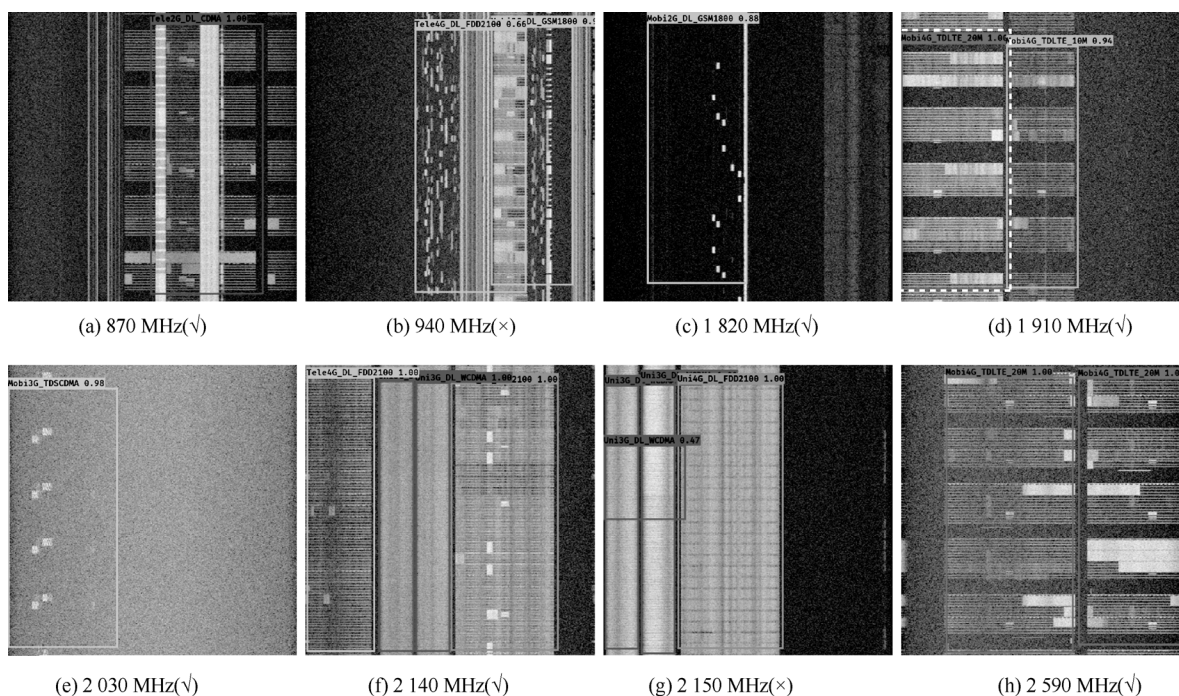


图 7 模型测试结果样本



以算出该模型的识别准确率为 86.04%。

准确率虽然是一个很直观的评价指标,但是有时并不能完全反映一个算法的好坏,特别是在样本数据分布不均衡时尤为明显,因此本文引入了功能更强大的 PR (precision-recall) 曲线,即查准率—查全率曲线,其纵坐标为 precision,横坐标为 recall。precision 又称精准率,其计算式为  $\text{precision} = \frac{TP}{TP + FP}$ ,表示被分为正例的示例中实际为正例的比例;

recall 又称召回率,其计算式为  $\text{recall} = \frac{TP}{TP + FN}$ ,表示所有正例中被分对的比例。PR 曲线可以直观展示分类效果的好坏,在分类、检索等领域应用广泛,通常曲线越靠近坐标(1, 1),分类器性能越好。

		预测结果		总计
		Yes	No	
实际结果	Yes	TP	FN	$P$ (实际正例)
	No	FP	TN	$N$ (实际反例)
总计		$P'$ (预测正例)	$N'$ (预测反例)	

图8 二分类问题的混淆矩阵

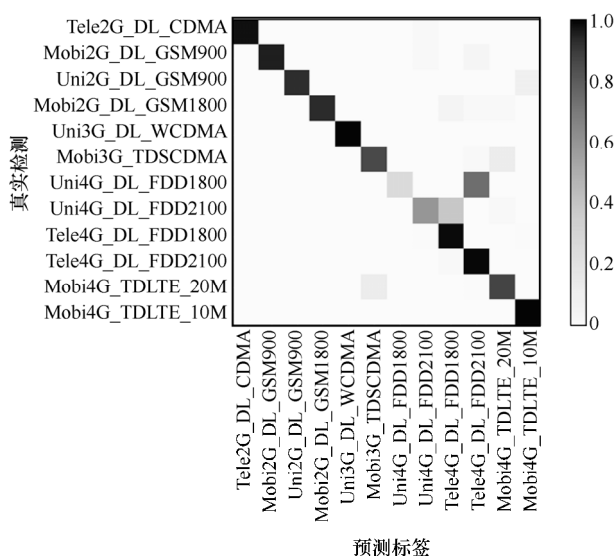


图9 测试结果—12类信号识别的归一化混淆矩阵

但是 PR 曲线是一个向量,不便于数值比较,因此通常使用平均查准率 (AP, average-precision),即 PR 曲线下的面积,进行分类效果评估。通常一个分类器能够同时识别多个目标,而一条 PR 曲线

及其 AP 值只能表示其中一种目标的分类效果,因此,可以对所有 AP 值求平均,就得到了 mAP(mean average precision)值。目前, mAP 值已经成为检测算法的核心性能指标之一。

图 10 是本文模型测试结果的 PR 曲线,表 4 是其对应的结果数值,由于图 10 存在多条曲线重叠的情况,具体数值可见表 4。从表 4 可以看出,尽管 Uni4G\_DL\_FDD1800 和 Uni4G\_DL\_FDD2100 的识别精准率很高,均在 90%以上,但由于其召回率较低,分别约为 26%和 60%,因此整体的 AP 值指标并不好,分别只有 26.02 和 58.50。换句话说,如果该分类器判定一个信号是 Uni4G\_DL\_FDD1800 或 Uni4G\_DL\_FDD2100,则很可能是对的,但也会出现很多漏检情况。Tele4G\_DL\_FDD2100 的情况刚好相反,其召回率可达到 99%,但精准率不高,只有不到 54%,也就是说,该分类器能够把几乎所有的 Tele4G\_DL\_FDD 2100 信号都检测出来,但也会出现很多误判情况。Mobi3G\_TDSCDMA 的情况则兼具二者的特征,召回率和精准率都一般,整体识别效果也比较一般。除了这 4 种信号以外,其他 8 种信号的识别效果都比较好,某些信号的 AP 值甚至达到 95 以上。12 类信号的平均 AP 值 mAP 达到 77.72,在未经任何模型优化的前提下,识别性能非常接近目前自然图像目标检测的最好指标——78.8<sup>[31]</sup>,这在一定程度上说明了频谱具象化图片的复杂度略低于自然界中的图片,因此,现有的自然图像目标检测模型的复杂度完全能够胜任无线电信号目标检测任务。




图10 12类信号识别的PR曲线, mAP=77.72

## 5.2 性能对比

本文所提的 RadioImageDet 算法,能够同时检测出混叠信号中存在的每一种信号类型及其时频

坐标,而现有算法往往只能检测出所含的多个信号类型,甚至只能检测出最可能存在的一个信号类型。因此,本文在现有算法的能力范围内,对部分指标进行对比,对比算法选择 NFSC (neuro-fuzzy signal classifier) 算法<sup>[26]</sup>和 WII (wireless interference identification) 算法<sup>[27]</sup>。

表4 测试结果

序号	信号名称	精准率	召回率	AP 值
1	Tele2G_DL_CDMA	100%	98%	97.67
2	Mobi2G_DL_GSM900	100%	95%	95.35
3	Uni2G_DL_GSM900	100%	92%	92.31
4	Mobi2G_DL_GSM1800	100%	93%	93.02
5	Uni3G_DL_WCDMA	100%	100%	100
6	Mobi3G_TDSCDMA	30%	62%	45.76
7	Uni4G_DL_FDD1800	100%	26%	26.02
8	Uni4G_DL_FDD2100	94%	60%	58.50
9	Tele4G_DL_FDD1800	72%	98%	85.09
10	Tele4G_DL_FDD2100	54%	99%	55.02
11	Mobi4G_TDLTE_20M	94%	84%	83.91
12	Mobi4G_TDLTE_10M	93%	100%	99.92
平均	mAP	—	—	77.72

NFSC 算法属于一种传统信号识别算法。它利用信号功率谱密度的相似性区分信号,首先为每一种信号选择一个参考信号,经过滤波、归一化等处理后,采用基于神经模糊的相似度测量方法,计算待测信号与每一个参考信号间功率谱密度的相似性,如果相似度大于某门限,则判定含有该类信号。根据文献[26],神经模糊相似度计算方法如式(5)所示,判决门限为 0.5。

$$SM = \frac{\sum_n \min(R[n], S[n])}{\max(\sum_n R[n], \sum_n S[n])} \quad (5)$$

其中,  $R[n]$  表示参考信号功率谱密度,  $S[n]$  表示待测信号功率谱密度,  $SM$  为相似度。

WII 算法是一种基于深度学习的信号识别算法。它采用与 O'shea 模型极为相似的 4 层 CNN 结构,只是将输入替换为 FFT 的频域表达形式。原始的 WII 算法只能识别单一信号的类型,无法检测混叠信号,因此需要对其进行一些改进。首先,将模型最后一层由 softmax 激活改为 sigmoid 激活,让其能够输出所有信号类型的置信概率向量,以实现

识别混叠信号的能力;然后,利用本研究采集的原始 I/Q 数据,专门为 WII 算法的训练和测试构造数据集,样本量总计 11 700 条,并且其标注数据样式为 Multi-Hot,而非原始的 One-Hot;最后,利用训练后的模型进行测试,将模型输出向量  $Y$  与某一概率门限进行对比,如果  $Y[i]$  大于该门限,则判定信号  $i$  存在。显而易见,门限值对判决结果影响很大。经过遍历性测试发现,当门限值等于 0.1 时,精准率指标最高,因此,本对比实验中将概率门限置为 0.1。

为了便于评估某一具体信号类型的分类准确性,选用精准率 (precision) 作为对比指标,它表示被分为正例的示例中实际为正例的比例。由图 11 可见, RadioImageDet 算法的平均精准率达到 89.0%,改进后的 WII 算法为 53.8%,传统的 NFSC 算法只有 49.3%,平均精准率分别提高了 35.2%和 39.7%。




图 11 3 种算法的精准率指标对比

## 6 结束语

无线电信号识别技术作为无线通信的一个重要研究领域,在军事电子战、政府频谱监管、商业频谱共享接入等方面应用广泛。结合其作为一种“模式识别”任务的本质,以及人工智能在模式识别任务中特有的优势,本文提出了一种基于图像深度学习的无线电信号识别算法——RadioImageDet 算法。该算法首先利用传统数字信号处理方法,将 I/Q 采样数据流变换为一张二维频谱瀑布图,将无线电信号识别问题转化为图像识别领域的目标检测问题;进而利用人工智能在图像识别领域的先进

成果,以YOLOv2模型为基础,构造了一种面向无线电信号识别的端到端深度神经网络模型——RadioYOLO模型,并利用该模型识别信号的波形类型和时/频坐标。这种将无线电信号识别问题转化为图像目标检测问题的思路,在国内外尚属首次提出,给未来复杂电磁环境下智能化无线电信号识别技术的研究开启了一条新思路。

为了检验算法的真实性能,本研究基于GnuRadio和USRP平台,开发了一套高速频谱采集系统,并在北京、天津等地实地采集频谱数据,构建无线电数据集。实验结果表明,RadioImageDet算法能有效识别具象化后的无线电信号,识别效果与人眼近似,在实地采集的12种、4740个样本的数据集中,识别准确率达到86.04%,mAP值达到77.72,检测时间在中等配置的台式计算机上仅需33ms,充分验证了本文所提思路的可行性和本文算法的有效性。

RadioImageDet算法只是基于图像深度学习的无线电信号识别技术思路的第一次初步尝试,从实验结果中也能看出一些不足。未来,将进一步研究其他信号具象化方法和更加适合无线电信号特征的神经网络模型。

#### 参考文献:

- [1] DOBRE O A. Signal identification for emerging intelligent radios: classical problems and new challenges [J]. IEEE Instrumentation & Measurement Magazine, 2015, 18(2): 11-18.
- [2] YAO Y, HUANG Z. Communicational signals' modulation recognition (Chinese with English abstract) [J]. Communications Technology, 2003, 6(1): 41-50.
- [3] AZZOUZ E E, NANDI A K. Automatic identification of digital modulation types [J]. Signal Processing, 1995, 47(1): 55-69.
- [4] LOPATKA J, PEDZISZ M. Automatic modulation classification using statistical moments and a fuzzy classifier [C]// International Conference on Signal Processing Proceedings. 2000, 3(1): 1500-1506.
- [5] NANDI A K, AZZOUZ E E. Algorithms for automatic modulation recognition of communication signals [J]. IEEE Transactions on Communications, 1998, 46(4): 431-436.
- [6] REICHERT J. Automatic classification of communication signals using higher order statistics [C]// IEEE International Conference on Acoustics, Speech, and Signal Processing. IEEE, 1992: 221-224.
- [7] SPOONER C M, MODY A N, CHUAN G J. Modulation recognition using second- and higher-order cyclostationarity [C]// IEEE International Symposium on Dynamic Spectrum Access Networks. IEEE, 2017: 1-3.
- [8] SOLIMA N S S, HSUE S Z. Signal classification using statistical moments [J]. IEEE Transactions on Communications, 1992, 40(5): 908-916.
- [9] YAMASHITA Y, OCHIAI H. A classification of OFDM signals with or without DFT precoding based on high-order moment [C]// IEEE International Symposium on Dynamic Spectrum Access Networks. IEEE, 2017: 1-2.
- [10] CHEN J, KUO Y, LI J, et al. Review of automatic communication signals recognition (Chinese with English abstract) [J]. Journal of Circuits and Systems, 2005, 10(5): 102-109.
- [11] PARNAS D L. The real risks of artificial intelligence [J]. Communications of the ACM, 2017, 60(10): 27-31.
- [12] WONG M L D, NANDI A K. Automatic digital modulation recognition using spectral and statistical features with multi-layer perceptron [C]// Signal Processing and its Applications. 2001: 390-393.
- [13] ARULAMPALAM G, RAMAKONAR V, BOUZERDOUM A. et al. Classification of digital modulated schemes using neural networks [C]// International Symposium on Signal Processing and its Applications. 1999: 649-652.
- [14] TRIANTAFYLAKIS K, SURLIGAS M, VARDAKI S G. Phasma: an automatic modulation classification system based on random forest [C]// IEEE International Symposium on Dynamic Spectrum Access Networks. IEEE, 2017: 1-3.
- [15] O'SHEA T, CORGAN J, CLANCY T C. Convolutional radio modulation recognition networks [C]// International Conference on Engineering Applications of Neural Networks. 2016: 213-226.
- [16] O'SHEA T, CORGAN J, CLANCY T C. Unsupervised representation learning of structured radio communication signals [C]// First International Workshop on Sensing, Processing and Learning for Intelligent Machines. 2016: 1-5.
- [17] O'SHEA T, WEST N, VONDAL M, et al. Semi-supervised radio signal identification [C]// International Conference on Advanced Communication Technology. 2017: 33-38.
- [18] O'SHEA T, WEST N. Radio machine learning dataset generation with GNU radio [C]// Proceedings of the GNU Radio Conference. 2016: 1-6.
- [19] ZIEGLER J L, ARN R T, CHAMBERS W. Modulation recognition with GNU radio, Keras and HackRF [C]// IEEE International Symposium on Dynamic Spectrum Access Networks. IEEE, 2017: 1-3.
- [20] KARRA K, KUZDEBA S, PETERSEN J. Modulation recognition using hierarchical deep neural networks [C]// IEEE International Symposium on Dynamic Spectrum Access Networks. IEEE, 2017: 1-3.
- [21] WEST N, O'SHEA T. Deep architectures for modulation recognition [C]// IEEE International Symposium on Dynamic Spectrum Access Networks. IEEE, 2017: 1-6.
- [22] WEST N, HARWELL K, MCCALL B. DFT signal detection and channelization with a deep neural network modulation classifier [C]// IEEE International Symposium on Dynamic Spectrum Access Networks. IEEE, 2017: 1-3.
- [23] ARUMUGAM K, KADAMPOT I, TAHMASBI M, et al. Modulation recognition using side information and hybrid learning [C]// IEEE International Symposium on Dynamic Spectrum Access Networks. IEEE,

- 2017: 1-2.
- [24] HUANG L, YU J, SHEN Z, et al. Radio individual identification via stable communication signals based on subordinate component analysis [C]// IET International Radar Conference. 2016, 1:1-4.
- [25] YUAN Y, HUANG Z, WANG F, et al. Radio specific emitter identification based on nonlinear characteristics of signal [C]// IEEE International Black Sea Conference on Communications and Networking. IEEE, 2015: 77-81.
- [26] AHMAD K, SHRESTA G, MEIER U, et al. Neuro-fuzzy signal class IFIER (NFSC) for standard wireless technologies [C]// International Symposium on Wireless Communication Systems. 2010: 616-620.
- [27] SCHMIDT M, BLOCK D, MEIER U. Wireless interference identification with convolutional neural networks [J]. IEEE 15th International Conference on Industrial Informatics, 2017: 180-185.
- [28] ZHANG M, DIAO M, GUO L. Convolutional neural networks for automatic cognitive radio waveform recognition [J]. IEEE Access, 2017, 5(1): 11074-11082.
- [29] GIRSHICK R, DONAHUE J, DARRELL, et al. Rich feature hierarchies for accurate object detection and semantic segmentation [C]// IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2014, 1: 580-587.
- [30] GIRSHICK R. Fast R-CNN [C]// IEEE International Conference on Computer Vision. IEEE, 2015: 1440-1448.
- [31] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.
- [32] LIN T, DOLLAR P, GIRSHICK R, et al. Feature pyramid networks for object detection [C]//IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2017: 936-944.
- [33] REDMON J, FARHADI A. YOLO9000: better, faster, stronger [C]// IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2017: 6517-6525.
- [34] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot multibox detector [C]// European Conference on Computer Vision. 2016: 21-37.
- [35] DANEV B, CAPKUN S. Transient-based identification of wireless sensor nodes [C]// International Conference on Information Processing in Sensor Networks. 2009: 25-36.
- [36] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions [C]// IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2015: 1-9.
- [37] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C]// IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2016: 770-778.

#### [作者简介]



周鑫 (1986—), 男, 河南项城人, 博士, 中国科学院软件研究所副研究员、硕士生导师, 主要研究方向为认知无线网络、无线信道接入、射频机器学习等。



何晓新 (1966—), 女, 湖南衡阳人, 中国科学院软件研究所研究员, 主要研究方向为认知无线电、通信指挥系统等。



郑昌文 (1969—), 男, 湖北大冶人, 博士, 中国科学院软件研究所研究员、博士生导师, 主要研究方向为计算机图形学、空间系统仿真、智能搜索等。