

电子科技大学
UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

专业学位硕士学位论文

MASTER THESIS FOR PROFESSIONAL DEGREE



论文题目 基于机器学习的无人机无线电信号
识别技术研究

专业学位类别	<u>电子信息</u>
学 号	<u>202022100134</u>
作者姓名	<u>庞新蕊</u>
指导教师	<u>吴绍炜 高 工</u>
学 院	<u>航空航天学院</u>

分类号 _____ 密级 _____ 公开 _____
UDC 注 1 _____

学 位 论 文

基于机器学习的无人机无线电信号 识别技术研究

(题名和副题名)

庞新蕊

(作者姓名)

指导教师 吴绍炜 高 工
电子科技大学 成 都

(姓名、职称、单位名称)

申请学位级别 硕士 专业学位类别 电子信息
提交论文日期 2023 年 4 月 8 日 论文答辩日期 2023 年 5 月 29 日
学位授予单位和日期 电子科技大学 2023 年 6 月
答辩委员会主席 _____
评阅人 _____

注 1: 注明《国际十进分类法 UDC》的类号。

Research on UAV Radio Signal Identification Technology Based on Machine Learning

A Master Thesis Submitted to
University of Electronic Science and Technology of China

Discipline **Electronic Information**

Student ID **202022100134**

Author **Pang Xinrui**

Supervisor **Prof. Wu Shaowei**

School **School of Aeronautics and Astronautics**

摘 要

随着无人机技术的逐渐成熟，无人机在军事、工业和社会生活等领域的应用不断扩展。民用无人机在搜索救援和航空拍摄等应用领域提供便利的同时也带来了各种各样问题，在部队驻地、政府部门、机场、化工等重大工业机构、大型活动现场等敏感或人员密集情景下“黑飞”的无人机无疑存在安全隐患，需要加强对民用无人飞行器的管控。

无线电探测和对抗是低慢小民用无人机管控的重要手段，在行业发挥着至关重要的作用，但从周围复杂的无线电环境中发现“黑飞”的无人机信号还存在很多技术问题需要攻关。要从复杂的无线电环境中发现“黑飞”的无人机，需要对复杂电磁环境中的无线电信号进行分析、识别，本文提出了对复杂电磁环境中的无线电信号进行分类，分类后的信号筛选出样本用于无人机信号分类识别的流程，主要研究内容如下：

（1）选用不需要预先确定信号类型数目等先验知识的狄利克雷混合模型对未知复杂无线电环境中的信号进行分类：先对复杂电磁环境中的无线电信号进行预处理以便于后续提取特征向量，形成无线电信号特征向量数据库；使用狄利克雷混合模型处理特征向量库数据，完成无线电信号分类并形成分类数据库；依据分层随机抽样法从分类库中按类抽样，抽样得到的信号绘出信号瀑布图和信号双谱分析图生成待处理样本数据库。

（2）开发无人机信号分类识别程序并处理分类后的样本数据：使用图像分类常用的残差神经网络模型结合自校准卷积和注意力机制开发无人机识别程序；采集标准无人机无线电信号并绘出无线电信号的瀑布图和双谱分析图建立样本库作为训练集和验证集并用于训练识别程序；训练后程序用于无人机无线电信号识别，并在识别过程中持续训练和学习。

关键词：无线电信号分类，无人机，狄利克雷混合过程，卷积神经网络

ABSTRACT

With the gradual maturity of UAV technology, the application of UAV in military, industrial and social life has been expanding. Civil unmanned aerial vehicles provide convenience in search and rescue, aerial photography and other application fields, but also bring various problems. In sensitive or crowded scenes such as military stations, government departments, airports, chemical industry and other major industrial institutions, large-scale events, there is no doubt that "black flying" UAVs have security risks, and it is necessary to strengthen the control of civil unmanned aerial vehicles.

Radio detection and countermeasure is an important means of management and control of low-speed and small-scale civil unmanned aerial vehicles, which plays a vital role in the industry. However, there are still many technical problems to be solved in finding the "black flying" UAV signal from the surrounding complex radio environment. In order to find the "black flying" UAV from the complex radio environment, it is necessary to analyze and identify the radio signals in the complex electromagnetic environment. Thesis puts forward the process of classifying radio signals in complex electromagnetic environment, and screening samples from the classified signals for UAV signal classification and identification. The main research contents are as follows:

(1) The Dirichlet mixed model is selected to classify the signals in the unknown complex radio environment without prior knowledge such as the number of signal types: firstly, the radio signals in the complex electromagnetic environment are preprocessed to facilitate the subsequent extraction of feature vectors to form a radio signal feature vector database; Using Dirichlet mixed model to process the data of feature vector library, complete the classification of radio signals and form a classification database; According to the stratified random sampling method, the samples are sampled from the classification database by class, and the signals obtained by sampling draw the signal waterfall diagram and the signal bispectrum analysis diagram to generate the sample database to be processed.

(2) Develop UAV signal classification recognition program and process the classified sample data: develop UAV recognition program by using residual neural network model commonly used in image classification combined with self-calibration convolution and attention mechanism; Collecting radio signals of standard unmanned

aerial vehicle, drawing waterfall diagram and bispectrum analysis diagram of radio signals, establishing a sample library as a training set and a verification set, and training the identification program; After training, the program is used for UAV radio signal recognition, and it is continuously trained and learned during the recognition process.

Keywords: Radio Signal Classification, unmanned aerial vehicle(UAV), Dirichlet Mixing Process, Convolutional Neural Network

目 录

第一章 绪论.....	1
1.1 研究工作的背景及意义.....	1
1.2 国内外研究历史及现状.....	3
1.2.1 无线电信号分类.....	3
1.2.2 无人机信号识别.....	6
1.3 本文的主要工作与创新.....	7
1.4 本论文的结构安排.....	9
第二章 狄利克雷混合模型理论分析	10
2.1 无线电信号分类.....	10
2.2 狄利克雷分布和狄利克雷过程	11
2.2.1 狄利克雷分布.....	12
2.2.2 狄利克雷过程.....	14
2.3 狄利克雷过程混合模型.....	15
2.3.1 断棍模型.....	15
2.3.2 狄利克雷混合模型.....	17
2.4 后验分布近似算法.....	19
2.4.1 马尔科夫链蒙特卡洛算法.....	19
2.4.2 变分法.....	21
2.5 本章小结.....	23
第三章 基于狄利克雷混合模型的无线电信号分类算法	24
3.1 无线电信号预处理.....	24
3.2 无线电信号特征提取.....	26
3.2.1 无线电信号带宽估计.....	26
3.2.2 无线电信号载波频率和循环频率估计	29
3.3 基于狄利克雷混合模型的无线电信号分类算法	32
3.3.1 无线电信号分类系统模型.....	32
3.3.2 无线电信号分类算法.....	34
3.4 基于狄利克雷混合模型的无线电信号分类仿真	38
3.4.1 无线电信号分类仿真结果.....	38
3.4.2 分类正确率仿真结果分析.....	39
3.5 本章小结.....	41
第四章 基于改进的卷积神经网络的无人机信号分类识别研究	42
4.1 无人机通信系统.....	42
4.1.1 无人机无线电信号	42

4.1.2 无人机信号指纹特征.....	43
4.2 无人机信号时频分析与仿真	44
4.2.1 基于短时傅里叶变换的时频分析.....	44
4.2.2 无人机信号瀑布图仿真.....	45
4.3 无人机信号双谱特征分析与仿真	47
4.3.1 高阶谱理论与信号双谱分析.....	47
4.3.2 无人机信号双谱图仿真.....	48
4.4 经典卷积神经网络介绍.....	49
4.4.1 卷积神经网络基本原理.....	49
4.4.2 残差神经网络.....	52
4.4.3 注意力机制.....	53
4.4.4 自校准卷积.....	55
4.5 无人机无线电信号分类识别算法	57
4.5.1 无人机信号瀑布图样本库.....	57
4.5.2 无人机信号分类算法.....	58
4.6 无人机信号分类识别算法仿真结果及分析	60
4.6.1 无人机信号分类算法仿真结果.....	60
4.6.2 仿真结果的评价指标及分析.....	61
4.7 无线电环境中无人机信号识别	63
4.8 本章小结.....	64
第五章 全文总结与展望	65
5.1 全文总结.....	65
5.2 问题与展望.....	66
参考文献.....	67

图目录

图 1-1 整体结构图.....	8
图 2-1 断棍模型.....	16
图 3-1 无线电信号预处理流程图	24
图 3-2 异常数据剔除 hampel 滤波	25
图 3-3 功率谱估计法.....	29
图 3-4 循环谱估计法.....	31
图 3-5 信号分类模型.....	34
图 3-6 无线电信号分类算法流程图	37
图 3-7 信号类型数目 $I=3$, 每类信号数量不同时参数收敛情况.....	38
图 3-8 信号类型 $I=3$, 每类信号数量 $N=10、30、50$ 时的分类准确率.....	39
图 3-9 无线电信号类型数目固定, 信号数目变化时分类正确率情况.....	39
图 3-10 每一类无线电信号数目固定, 信号类型数目变化时分类正确率情况	40
图 4-1 无人机指纹特征	43
图 4-2 短时傅里叶变换原理图	45
图 4-3 背景信号短时傅里叶变换时频图	46
图 4-4 Bebob 无人机悬停时信号短时傅里叶变换时频图.....	46
图 4-5 无无人机背景信号双谱分析图	48
图 4-6 Bebob 无人机悬停时信号双谱分析图	49
图 4-7 卷积神经网络结构图	50
图 4-8 残差单元.....	52
图 4-9 压缩和激励网络 (SE) 模块	54
图 4-10 自校准卷积模块.....	55
图 4-11 两种残差结构	58
图 4-12 加入 SE 模块的残差结构图.....	59
图 4-13 SC-ResNet 网络模型结构图	60
图 4-14 混淆矩阵.....	61
图 4-15 SC-ResNet-101 模型查全率.....	62

图 4-16 SC-ResNet-101 模型查准率.....	63
图 4-17 无人机信号识别结果.....	64

表目录

表 4-1 无人机无线电信号类型	57
表 4-2 不同算法的无人机无线电信号识别率	60

第一章 绪论

1.1 研究工作的背景及意义

无人机（Unmanned Aerial Vehicle, UAV）是无人驾驶飞机的统称，它主要是利用无线电遥控设备和自备的程序控制装置来操纵机身实现无人自动飞行的。无人机最早出自军事领域，二十世纪二十年代也就是第一次世界大战期间，英国的两位将军卡德尔和皮切尔提出研制无人驾驶飞机的建议，相对于载人飞机无人机具有体积小、使用方便、战场生存能力强等突出的优点。到九十年代末期无人机的飞行技术在低空飞行和小型化技术层面取得了重大的突破，之后无人机开始在民用领域得到广泛的应用。无人机一方面在未来的高科技电子战中能够根据战场需要灵活的适应战场侦察、防核生化探测、电子干扰和炮火校射等等作战场景而在军用领域占据不可或缺的重要地位；另一方面也因其较为低廉的成本和便捷的使用逐步在搜索救援、航空拍摄和测绘等民用领域得到广泛的应用。

近些年随着无人机技术和应用的逐渐成熟，无人机也正在慢慢的由军事和工业领域进入到大家的日常生活中，尤其是在无人机航拍和无人机表演方面。大量的无人机厂商如国内最大的小型无人机生产厂商大疆创新等纷纷涌入抢占民用小型无人机市场后更是促进了无人机技术的快速发展和成本的降低，也推出了更多的无人机应用场景，如互联网技术相结合的物流配送等等。但与此同时，随着无人机在民用领域的大量应用，它给社会带来的各种各样的问题也逐渐暴露出来，无人机的不规范使用更是很有可能造成一些意外的危险。2016年3月29日一架无人机在洛杉矶国际机场(LAX)附近与一架汉莎喷气式飞机相撞，造成了巨大的经济损失的同时也引发了人们对空中交通和无人机安全问题的担忧^[1]。在2017年这一年成都双流机场受到了多达近十次无人机干扰的同年且仅在四月份就接连不断的发生了五次无人机干扰机场运行的事件，尤其是在4月21日下午接连三架无人机出现在成都双流机场附近，造成了成都双流国际机场发布大面积航班延误预警，58个航班被迫备降，超过一万名旅客被滞留。2018年河北省唐山市更是发生了一起因私自使用无人机对矿区进行测绘被空军雷达检测发现发生警报，从而导致省军区前后出动千余人和当地多家航班被迫更改航行路线的恶劣事件。因此，对空中无人机的准确识别并求其进行跟踪或者干扰打击在加强空中交通管制有着重要的意义。在军事领域对敌方无人机的准确检测识别和军事打击也是空战中重要的一个环节。

在机场、政府部门、住宅和一些大型活动如体育赛事、节日晚会等“黑飞”的无人机无疑存在安全隐患，因此能够从周围的复杂无线电环境中发现“黑飞”无

人机是尤为重要。无线通信是当前运用最为广泛的通信方式,随着无线电信号的普遍使用和各种类型的以电磁通信为载体的设备先后大规模应用,目前世界上的通信信号的种类多达 100 种以上且各种复杂通信信号的使用更进一步增加了无线电环境的复杂性,在这种复杂的电磁环境下要实现非法使用和非合作信道中无线电信号的有效分析也就变得越来越困难^[2]。

无线电信号分类识别是信号处理领域的关键技术,对无线电信号进行分类识别的依据就是从无线电信号中提取处理的特征参数,因而可以说信号的特征提取技术为无线电信号的分析和分类识别等任务的实现提供了一共基本的保障。无线电信号的特征提取技术主要是通过对高维的输入信号进行非线性的映射以提取出原始信号低维且有效的特征参数,并且还可以通过降低信号的维度达到降低无线电信号分类识别任务复杂度并同时增强信号可识别性的目的。无线电信号特征技术在无线电信号的分类识别任务中有着关键的地位,因此如何设计出鲁棒性更好和算法效率更高的无线电信号特征提取技术也就变成了无线电信号分类识别任务中的重点。

早期对无线电信号进行分析处理时用到的参数化建模在现在常用的无线电信号分类识别方法中已经很少能够看到了,现在大多数都是直接利用无线电信号的高阶统计特性和非线性映射来完成对无线电信号的识别。目前传统的无线电信号特征提取方法主要是利用研究人员的经验知识,并通过对无线电信号的分析处理得到易于分类失败的特征参数,主要是筛选出适合每一种特定的无线电信号分类识别任务的高阶统计特性,比如循环谱等并通过对这些无线电信号进行非线性映射来提取特征参数以用于无线电信号的分类识别任务。但是这种人工设计选择无线电信号特征参数的方法只在无线电信号的类型数目和数据都比较少的情况下效果好,在复杂的无线电环境种却存在局限性。尤其是现在随着无线电技术的不断发展和无线电信号种类不断增加,无线电环境的复杂度也在急剧的增大,这种情况下人工设计无线电信号的特征参数的方法局限也就越大。

因此将机器学习引入无线电信号的分类识别领域以实现无线电信号的智能化识别还是很有必要的。目前基于机器学习的无线电信号分类算法中主要可以分为监督学习和非监督学习这两种。其中监督学习主要是通过对带标签的样本进行训练来调节学习模型的参数并使得该模型能够尽可能地拟合训练样本的标签,然后再利用这个已经训练好的学习模型对新的不带标签的信号进行识别,这种学习模型需要有已知标签的训练数据样本。而非监督学习则不需要任何训练数据样本直接对信号数据进行处理,通过从数据中寻找到的数据之间的内在联系实现对无线电信号的分类。近几年随着计算机运算能力的提升,利用神经网络智能地提取信号数据

的高维的特征来归纳和探寻信号特征间更深层次的信息，并以此来解决复杂的实际问题的深度学习算法得到了迅速的发展。具体到无线电信号的分类识别任务中，深度学习善于从海量数据中提取信号深层次的特征，还可以根据标记的数据中归纳出信号的特征表示模式以提高信号的可识别性，这些特点都使得深度学习在对海量和动态的无线电信号的分类识别领域有着突出的优势。

1.2 国内外研究历史及现状

1.2.1 无线电信号分类

随着学术界以及工业界在无线电通信领域对机器学习方法的需求越来越高，现代机器学习算法尤其是深度学习这一块在无线电信号领域的发展速度也愈发迅猛^[3]。与以往传统的无线电信号分析处理等方面的机制不同，机器学习算法在对无线电信号进行分析处理的时候并不依赖人工来完成决策，而是利用机器学习算法的统计归纳等能力找出无线电信号中的特征信息并由算法来完成相应的决策流程。因此在无线电通信领域引入机器学习无疑可以极大的提高无线电信号分析与处理的效率和准确性。

机器学习的研究领域在其问世以后得到了不断的拓展，无线电信号分类识别与传统机器学习的结合就是机器学习在通信领域中的应用。自从机器学习这一多个领域交叉形成的学科问世以来许许多多的研究人员经过不断的深入研究拓展了它的研究和应用领域^[4]，在无线电信号分类识别领域也有不少研究人员提出来了一些机器学习方法来实现无线电信号的分类识别并达到更好的分类识别性能，这些机器学习方法主要是基于传统算法和结合新兴深度神经网络结构算法来实现的。Dobre 将 QAM 信号、PSK 信号和 ASK 信号这三类调制信号的四、六和八阶循环累计量作为特征输入，通过机器学习中近邻法构建的信号分类模型来实现对这三种调制信号的识别和分类并最终取得了良好的效果^[5]。张震则是以无线电信号的熵作为机器学习算法中随机森林法作为信号分类器的模型中的特征输入，并且最终证明这种方法在信噪比不同的情况下都能比较好的将无线电信号的类型识别出来，并在信噪比高于 5dB 的时候该分类算法实现了超过 95% 的分类识别率^[6]。WuZ 提出了一种从比较大的信号特征集中选择出在噪声不断发生改变的条件下也能够获得更好的鲁棒性的特征来实现对无线电信号的分类识别，这种方法主要是通过提取 25 种对噪声的变化不敏感的信号特征作为该信号分类识别算法的特征集，并再次从这 25 种特征中通过粗糙集理论进行进一步的特征筛选以缩小用于信号处理的特征集，最后通过支撑向量机 (Support Vector Machine, SVM) 完成分类^[7]。袁海英提出了一种通过基于协调旋转数字计算机算法来实现直接在无线电信号时域进行

分析获得信号频谱和功率谱等瞬时特征参数，并将其用于无线电信号调制分类识别的新型基于决策树理论的神经网络模型的无线电信号综合分类算法^[8]。在实数和复数这两个正交通道结构下计算出可以用于信号模式分类识别的特征参数，建立用于无线电信号分类识别的特征向量集，并根据特征向量集里信号的调制方式和需要达到的分类识别性能来设计更合适的信号分类模型。根据信号特征向量集的情况，在每一个无线电信号分类模型中依照决策树理论为相应的无线电信号特征向量选择最合适的阈值，这一过程在实现对无线电信号的调制分类识别的同时还实现了多源信息的融合。

深度学习从 2012 年在 ImageNet 挑战赛上获得冠军开始热度就一直居高不下，它在无线电信号分类这一领域的应用可以大致划分为监督学习和非监督学习这两种类型，其中监督学习这一类的分类识别算法因为需要预先知道无线电环境的先验特征知识比较适用于一些熟悉的无线电环境中。文献[9]提出了一种需要预先给不同类型的信号系统提供完整的特征向量来构建无线电信号分类模型训练样本的无线电信号分类算法，该算法基于隐马尔可夫模型 (Hidden Markov Model, HMM) 并且在该算法中无线电信号分类器会根据预先准备的信号特征向量样本来调整无线电信号分类模型中的参数以实现对这些无线电信号进行分类识别的目的。文献[10]的作者则是根据多层前馈神经网络 (Multilayer Feedforward Neural Network, MFNN) 模型和循环平稳中的频谱感知这两种模型进行结合提出了一种信道状态预测模型，实现了在比较低的信噪比情况下可以根据频谱感知来进行无线电信号分类的算法，另外还跟 HMM 这种方法的计算复杂度比较高和其需要更加巨大的存储空间来存储过程的观测结果这两个明显的缺点进行了对比，说明了本文献中设计出来的基于 MFNN 的无线电新房分类预测算法的优越性。文献[11]设计了一种频谱预测算法，该算法通过将主用户信号特征构建成拥有多个变量的混沌时间序列并以此作为深度神经网络的输入来预测无线电信号随着时间的变化，并根据这些仿真结果中无线电信号随着时间的变化出现的改变来决定该用户是否可以利用这一频段。在无线电信号分类识别领域深度学习的监督学习算法中比较常用的算法还有支持向量机法，该算法通过将不能通过线性进行划分的输入利用核函数将这些输入非线性的映射到可以进行线性划分的高维空间进而达到对无线电信号进行分类识别目的。在文献[12]中作者就为了实现对未知环境中的无线电信号分类提出一种基于支持向量机的 MAC (Medium Access Control) 竞争协议和 MAC 控制协议的无线电信号分类策略，将接收功率的均值和方差选为支持向量机的两个特征参数且最终得出无线电信号正确分类的概率与网络的传输速率成正比的结论。支持向量机处理信号等分类问题时不仅可以处理二分类问题，还可以通过将 K 类

分类问题转化为 K 个二分类问题来实现多元的分类。这一点在文献[13]中得到了充分的体现,作者提出了基于支持向量机的可以实现训练并识别使用实际的载波频率和符号速率等生成的 BPSK、QPSK、GMSK、16-QAM 和 64-QAM 这五种数字调制信号和 FM 和 AM 这两种模拟调制信号,并最终被证明有效的多元信号分类模型中。上面总结的这些在无线电信号分类领域的监督学习算法在可以获得充足的信息时都可以达到非常好的无线电信号分类识别的效果,但是当面对一个未知的无线电环境时,这些算法因为无法获得充分的无线电信号相关信息而不能得到很好的无线电信号分类效果,甚至无法在这种场景下运用。

因此在一个未知的无线电环境对其进行无线电信号的分类识别等任务时面临的一大挑战,就是无法获取该复杂电磁环境中无线电信号相关的信息,尤其是没有充足的训练样本的情况下对该无线电环境进行探索的情况下。要解决这一大问题的关键就是引入不需要训练样本或者其他无线电信号相关信息的非监督学习算法。其中不需要训练样本但是需要预先假设复杂电磁环境中无线电信号类型的数目的非监督学习算法常用的就有高斯混合模型和 K-means 算法,但需要预先确定该复杂电磁环境中无线电信号类型的数目这一点对于一个未知的无线电环境来说是不可能的。因此在文献[14]中作者提出了一种通过最大化贝叶斯信息准则 (Bayesian Information Criterion, BIC) 或赤池信息准则 (Akaike Information Criterion, AIC) 来估计一个未知无线电环境中信号类型的数目,进而克服了上述两种算法中需要预先确定复杂电磁环境无线电信号类型数目这一缺点的算法,这种被称为 X-means 的属于非监督学习的信号分类模型其实是 K-means 算法的拓展,并和 K-means 算法类似也需要假设观测到的无线电信号服从高斯分布,进而导致这种算法在无线电信号的观测数据分布不明确的时候可能出现匹配度不好的情况。

针对这样的情况,基于无参贝叶斯估计的狄利克雷过程 (Dirichlet Process) 因其不需要预先确定未知无线电环境中信号类型的数目这一点而得到了较为广泛的应用。在文献[15]和文献[16]中研究人员就提出了通过提取无线电信号的载波频率和带宽等频谱特征将狄利克雷过程用于识别和分类无线电信号和无线电系统。而对载波频率和带宽等频谱特征进行分类时主要是采用了基于马尔科夫链蒙特卡洛采样算法,这种算法主要步骤就是先确定某一个将要进行分类的特征然后将其余的特征全部固定其类别的索引,然后找到要进行分类的这一特征的后验分布以及这一特征类别所在的索引值并依此对其余的特征重复上述的操作直至满足论文的要求或者设定的条件。

1.2.2 无人机信号识别

无线电探测是无人机管控的重要手段,从复杂无线电环境中发现和识别“黑飞”无人机除了传统的无线电信号特征提取结合机器学习的方法,还有随着图像处理技术快速发展而开始在无线电信号处理领域开始暂露头角的图像识别结合机器学习算法的无人机无线电信号分类识别技术。

文献[17]提出了一种基于功率谱估计的针对多种跳频信号同时存在的情况下对其进行无线电信号分类识别的算法,这种算法实现的主要突破点在于通过对目标信号中定频信号的去除,并根据这些遥控信号的跳频周期等先验信息进行接下来的操作。文献[18]则是通过建立可以自适应的多通道无线电信号检测接收机模型,并对每一个通道根据情况设定独立的门限和自适应选择的精度,以此来实现该多通道无线电信号检测接收机对从干扰中提取出来的跳频信号进行分类识别。但是上述文献中提出来的算法或者模型都离不开对部分跳频参数的依赖。在文献[19]中作者提出了一种基于指数平均的方法来实现对无线电信号的识别,但这些方法无法在复杂的电磁环境中得到有效的应用,因为其只适用于只有白噪声和定频信号干扰的无线电环境。文献[20]在对无人机无线电信号进行识别时则是先通过对无人机无线电信号进行时频分析得到无人机信号的时频瀑布图,并采样该信号的方向梯度直方图来作为无人机无线电信号的特征参数,最后采用基于 adaboost 的机器学习算法来实现对无人机跳频信号的分类识别。文献[21]采用了改进的延时相乘算法和扩频识别算法进行无人机无线电信号的参数估计和 WVD 算法来进行无人机跳频信号的特征提取,并将这些提取的无人机无线电信号特征参数输入到深度神经网络模型中实现对无人机无线电信号的分类识别。文献[22]通过对背景频谱的学习、无人机跳频信号和定频信号的识别和无人机机型的判断以及无人机无线电信号的特征参数的学习这三个模块,并使用二次平均求信号检测阈值来屏蔽宽带信号的方法来实现对无人机无线电信号的分类识别。文献[23]则是通过使用 PCA 算法从无线电信号的时频图中提取无线电信号的特征参数,结合从不同的角度的雷达传感器得到的无线电信号的特征,利用支持向量机实现对无人机无线电信号的分类识别。

随着人工智能领域深度学习和图像处理技术的高速发展,这两者之间结合的应用也变得越来越广泛,尤其是在目标识别领域。深度学习中典型神经网络模型之一的卷积神经网络 (Convolutional Neural Network, CNN)模型与传统的机器学习相比有着更好特征学习和特征表达能力^[24]并因此在结合图像处理技术的目标识别任务中有着出彩的表现。文献[25]提出的方法可以通过将无线电信号转换为时频图来去除干扰,并实现在人为选择结构元素大小的前提下以不同长度的结构元素来对

无线电信号的时频图进行处理,完成信号的识别问题。文献[26]提出了一种二维匹配的方式来实现对跳频信号的检测和识别但是同时也存在着虚警率比较高的问题。上面提到的这些算法都离不开人工的干预或者需要相关信号的先验知识。文献[27]提出了一种针对低空飞行但速度较快的无人机无线电信号的分类识别算法,该算法基于 YOLOV3 神经网络模型并利用残差神经网络模型和多尺度融合算法进行改进,除了在比较昏暗的情况下,该算法对无人机无线电信号分类识别的正确率明显高于未优化的模型。文献[28]则提出了一种专门解决无人机目标较小时无人机检测程序容易受到干扰的问题三维算法,该算法基于多隐含层的深度神经网络模型,并在对该无人机检测程序完成训练后证明其具有良好的尺度变化的检测能力和抗干扰能力。文献[29]设计了一种利用红外和可见光获得的无人机图像,将其输入到残差神经网络模型中对其进行特征提取,同时利用多尺度预测算法对无人机进行分类和位置回归的基于双通道的低空飞行且速度较快的无人机的检测算法。文献[30]则是通过残差深度神经网络模型和预测网络模型的构建来提出一种基于无人机红外图像的低空无人机检测算法。但是残差神经网络模型中传统的卷积模块在对图像的特征进行提取时,因为卷积模块中卷积核的大小固定导致神经网络模型对图像的感受野可能存在获取不足的问题,并进而影响最后对图像识别的正确率。相对于传统的卷积模块,自校准卷积(SC-block)模块可以通过将原本的标准卷积拆分成多个小的卷积操作,实现在不引入新的参数的情况下扩大神经网络模型全局的感受野,并进一步提取输入的图像更丰富的特征信息^[31]。另外还有在文献[32]中提出的注意力机制中的压缩与激励模块(SE),通过模拟人脑可以选择性地忽略不重要的信息这一点实现了对卷积神经网络模型性能的提升。因此根据上文的这些分析,本文选择以残差神经网络为基础,通过引入自校准卷积模块和 SE 模块来优化传统卷积模块存在的感受野受限的问题。

1.3 本文的主要工作与创新

本文通过研究分析现代复杂电磁环境、无线电信号特征及机器学习算法,设计一种复杂未知电磁环境中无线电信号的分类方法,并以低小慢无人机的无线电信号为特定对象设计分类识别技术方案。本文的主要工作如下:

1. 数据预处理。

采集到的无线电信号经常存在因干扰、噪声、采集设备等问题出现异常信号的情况,所以先对原始信号进行预处理,剔除这些异常数据,并对这些信号进行滤波以便于后续对信号的处理。

2. 无线电信号分类。

采用狄利克雷混合模型 (Dirichlet Process Mixture Model, DPMM) 完成。狄利克雷混合模型可以在不知道分类数目的情况下从数据本身推断出要分类的数目来完成对信号的分类, 非常适合在复杂未知的无线电信号环境中使用。本文选择无线电信号的载波频率、符号速率对应的基本循环频率、带宽这三个特征向量完成对无线电信号的分类。

3. 无人机探测与识别。

(1) 建立无人机无线电信号样本库。对采集到的无人机无线电信号进行预处理将其转化为无人机无线电信号瀑布图和双谱分析图, 得到的样本加标签建立为无人机无线电信号训练集和验证集的样本库且可继续更新。

(2) 采用改进的卷积神经网络模型完成。将建立好的训练集样本库输入搭建好的程序, 经过训练得到无人机的识别程序并用验证集对训练好的无人机信号识别程序进行验证。

4. 对未知复杂无线电环境中无人机信号进行识别。

从狄利克雷混合模型分类后的信号中每一类按照分层随机抽样方法筛选出信号样本并将这些样本信号转化为信号瀑布图和双谱分析图的形式, 将其送入训练得到的无人机识别程序实现对无线电环境中无人机信号的识别。

本文整体结构如下:

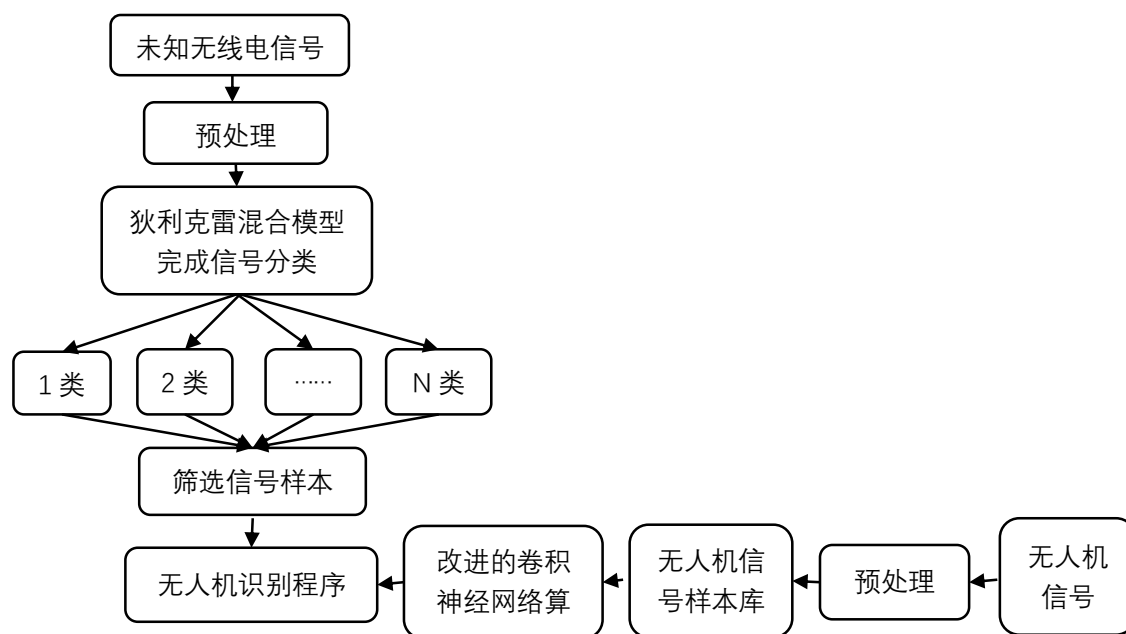


图 1-1 整体结构图

1.4 本论文的结构安排

第一章绪论主要介绍了本文的研究背景，无线电信号分类领域和无人机信号分类识别领域的研究历史及其发展现状，通过分析当前研究现状引出本文两大模块中分别应用的狄利克雷混合模型和结合自校准卷积和注意力机制的残差卷积神经网络模型。

第二章主要分析了针对未知复杂电磁环境中的无线电信号进行分类时可以选用的贝叶斯无参模型，并对贝叶斯无参模型中应用较广的狄利克雷分布、狄利克雷过程和狄利克雷混合模型相关理论进行了详细的描述，同时介绍了狄利克雷混合模型后验概率分布求解时用到的马尔科夫链蒙特卡洛抽样算法和变分近似算法。

第三章先对无线电信号进行预处理和本文选择的载波频率、循环频率和带宽这三个无线电信号特征参数的提取做了简要的介绍，然后着重介绍了本文基于不需要提前指定分类数目的狄利克雷混合模型构建的无线电信号分类系统模型及使用该模型对无线电信号进行分类的仿真结果。

第四章主要是对残差神经网络模型分别结合自校准卷积模块和注意力机制中SE模块实现无人机无线电信号分类识别的介绍。本文通过绘出无人机无线电信号的瀑布图和双谱分析图将无人机无线电信号的识别问题转化为图像识别问题，结合自校准卷积的残差深度神经网络模型和结合SE模块的残差深度神经网络模型都可以很好的实现对无人机信号的识别，同时还能更进一步的实现对某一型号无人机所处的飞行状态的识别。

第五章是本文最后的总结，主要介绍了本文的研究思路以及在实现过程中使用的方法和技术，并点明了本文研究中存在的不足及未来研究和改进的方向。

第二章 狄利克雷混合模型理论分析

面对不知道信号类型数目等无线电环境的先验特征知识的情况，对无线电环境中信号进行分类选用需要通过带标签的训练样本来调节学习模型参数的基于神经网络和支持向量机等监督学习的分类算法是不合适的。而非监督学习可以直接对数据进行处理，从数据中寻找数据之间的内在联系以此来完成对未知环境中无线电信号的分类，具有更强的环境适应性。不过在非监督学习中基于高斯混合模型（Gaussian Mixture Model, GMM）或者基于 K-means 算法的有参分类器却必须预先设定分类的数目，这在一个陌生的无线电环境中并不容易得到，而基于贝叶斯非监督分类方法中的无参估计方法——狄利克雷混合模型（DPMM）可以在不知道分类数目的情况下从数据本身推断出要分类的数目来完成对信号的分类。

2.1 无线电信号分类

对于一个陌生无线电环境中的无线电信号进行分类时，本文选择了一种基于无参贝叶斯估计的狄利克雷混合模型。

贝叶斯估计是一种利用贝叶斯定理根据新证据和先验概率来计算新的假设概率的方法，这在统计学中的描述是先从一系列的随机试验或者观察得到相应的数据样本，之后通过对这些样本数据的一系列分析处理得到可以为接下来要做的事情提供一定的帮助和参考，这一过程其实是通过一定数量内的样本数据进而推断出相应的总体数据所具有的特征，并能在一定程度上对该总体数据的特征做出一些概率上的推测。

在通过样本数据对总体特征进行推测时，如果可以成功的找到相对应的概率分布模型且这个概率分布模型可以被一些不随观测样本数据变化而变化的参数描述，那这个模型就是有参的且可以通过最大似然估计、最大后验估计等常用的求参模型来求出该假设的概率分布模型中的参数。跟有参模型相对应的无参模型中的参数却是跟观测样本数据有着紧密的联系，改变观测样本数据的多少有时候会影响该总体特征模型中参数的数量。因此在使用无参模型时事先并不会假设出总体的概率分布模型而是只把总体看作一个不知道其分布形式的随便变量。这一分布形式一定存在但相关的参数无法通过常用的参数估计算法来求解，模型的规模也会随着观测样本数据量的增大而不断增大^[33]。简单的来说对于某个样本进行分类时有参模型就是从已知的分布类型中通过最大似然估计等算法来选出跟样本数据分布最相似的一个分布类型作为该样本数据的总体分布，而无参模型却不一样，它

不是从一直的分布中选择出来一个作为总体数据的分布类型而是假设该样本数据的总体分布有一定的概率属于未知的某种分布类型。

显然有参模型相比无参模型有着更快的收敛速度等优点，但实际上应用效果更好的却是无参模型。在贝叶斯学派的观点中参数也是一种随机变量，而每一个参数的概率先验分布都会随着样本数据的变化而变化。也正是因为无参模型的参数数量会根据样本数据的改变而变化，也就是说模型参数的空间维度是不固定的，这与贝叶斯是在固定参数维度空间的概率分布的假设将矛盾。为此论文[38]做出了一定的假设并给出了贝叶斯无参模型：假设无参模型中随着样本数据改变而变化的参数空间维度设定为无限，贝叶斯框架也假设为一个参数在无限空间维度上的分布，这样一来无参模型和贝叶斯框架中的参数空间维度取得了一致，并将该模型称为贝叶斯无参模型。

可将上述内容更直观的描述为模型就是在描述数据，概率模型就是从概率的角度描述数据，可表述为：给定的数据集 $X = \{x_1, x_2, \dots, x_n\}$ 中的元素是从某个概率分布 M 中独立采样获得的，也就是 $x_1, x_2, \dots, x_n \sim M$ 。而模型估计就是要根据给定的 X 来找出 M 。通过假设 M 是一个由参数控制的模型即 $M = \{M_\theta | \theta \in S\}$ ，可以根据给定寻找最合适的 M 的问题转化为在参数空间 S 中寻找最佳参数 θ^* 的问题。具体来说就是先定义一个目标函数为

$$L(\theta | X) = \prod_{i=1}^n p_\theta(x_i) \quad (2-1)$$

然后通过 S 上得到最优的目标函数时对应的 θ^* 就是最佳参数，其中 p_θ 是 M_θ 的概率密度函数。而贝叶斯无参模型不是根据目标函数寻找最佳参数 θ^* 而是在 S 上定义 θ 的先验分布并根据 X 来计算 θ 的后验分布，公式为

$$p(\theta | X) \propto p(\theta) \prod_{i=1}^n p_\theta(x_i) \quad (2-2)$$

其中 $p(\theta)$ 是对应 p_θ 的概率密度函数。

2.2 狄利克雷分布和狄利克雷过程

狄利克雷分布（Dirichlet Distribution）和狄利克雷过程在贝叶斯模型中应用非常广泛。狄利克雷分布也可以称为多元贝塔分布，它是贝塔分布维度扩展到高维的版本，是一种高维连续概率分布。狄利克雷分布对应的随机过程就是狄利克雷过程，它每一次抽取的样本都是一个分布也就是说狄利克雷过程是一个分布的分布。狄利克雷过程在实际的应用中多用于狄利克雷混合模型。

2.2.1 狄利克雷分布

贝塔分布是二项分布的共轭先验分布，贝塔分布的高维版本狄利克雷分布自然也是二项分布的高维版本多项式分布的共轭先验分布。因此可以先从贝塔分布和共轭分布来了解狄利克雷分布。

贝叶斯公式的函数表达式如下

$$p(\theta|x) = \frac{p(x|\theta)p(\theta)}{\int p(x|\theta)p(\theta)d\theta} \propto p(x|\theta)p(\theta) \quad (2-3)$$

式子(2-3)中 $p(\theta|x)$ 与 $p(\theta)$ 的函数表达形式相同时， $p(\theta)$ 也就是 $p(x|\theta)$ 的共轭先验分布，这就是贝叶斯概率理论中的共轭性。其中 $p(\theta|x)$ 是后验概率分布， $p(x|\theta)$ 是似然函数， $p(\theta)$ 是先验概率分布。

狄利克雷分布是贝塔分布扩展到高维的一种情形，因此贝塔分布也就是是多变量概率分布狄利克雷分布的一种特殊形式，当只考虑狄利克雷分布有两个变量时即可以将狄利克雷分布退化为贝塔分布。而贝塔分布与二项分布互为共轭分布，对于基于伯努利实验的二项分布可以表达为

$$Binomial(m|n, p) = C_n^m p^m (1-p)^{n-m} \quad (2-4)$$

式子(2-4)为重复 n 次伯努利实验且伯努利实验结果记为 1 的事件发生了 m 次，其中伯努利实验结果记为 1 的事件发生的概率为 p 。

相应的某次实验 $y = \{x_1, x_2, \dots, x_n\}$ 的似然函数表达式为

$$prob(y|p) = \prod p^{x_k} (1-p)^{1-x_k} \quad (2-5)$$

由式子(2-5)和二项式分布与贝塔分布的共轭性可知跟 p 有关的后验概率分布与先验概率分布有着相同的表达形式，所以引入贝塔函数后可以得到关于 p 的后验概率分布表达式为

$$prob(p|m, n, \alpha, \beta) \propto p^{m+\alpha-1} (1-p)^{n-m+\beta-1} \quad (2-6)$$

其中 α 和 β 是控制贝塔函数形状的两个参数，贝塔函数的表达式为

$$Beta(p|\alpha, \beta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha-1} (1-p)^{\beta-1} \quad (2-7)$$

由上述式子(2-6)和(2-7)这两个式子可以看出关于 p 的后验概率分布函数和贝塔函数的表达式形式相同且参数不同，也印证了贝塔分布和二项分布互为共轭分布的性质。

在二项分布中的伯努利实验结果只有某事件发生和该事件不发生这两种情况, 参数 p 是在某次伯努利实验中该事件发生的概率。多项式分布是二项分布扩展到高维的情形, 与此相对应的多项式分布可能发生的事件有多个, 也就是说可以假设多项式分布中的状态变量 x 可能的取值为 K 个, 每一种事件发生的概率可以记为 $p = \{p_1, p_2, \dots, p_K\}$ 而在重复 n 次的实验中这 K 种事件可能发生的次数可以分布记为 m_1, m_2, \dots, m_K , 由此可以推导出多项式分布的属性表达式为

$$Multi(m_1, m_2, \dots, m_K | p, n) = \binom{n}{m_1, \dots, m_K} \prod_{k=1}^K p_k^{m_k} \quad (2-8)$$

根据上文中贝塔分布和二项分布互为共轭分布时的函数表达形式相同这一点可以从多项式分布的函数表达式(2-8)推导出其共轭分布的函数表达式

$$prob(p, \alpha) = \frac{\Gamma\left(\sum_{k=1}^K \alpha_k\right)}{\Gamma(\alpha_1) \dots \Gamma(\alpha_K)} \prod_{k=1}^K p_k^{\alpha_k - 1} \quad (2-9)$$

多项式分布和狄利克雷分布互为共轭, 所以上述式子(2-9)就是狄利克雷分布的函数表达式, 其中 α 是狄利克雷分布函数中影响其在坐标轴上形状的参数, 而 p 是满足以下两个条件的变量

$$\begin{aligned} \sum p_k &= 1 \\ 0 &\leq p_k \leq 1 \end{aligned} \quad (2-10)$$

狄利克雷分布还有一个可以在后续模型计算中起到很好的作用的性质, 那就是聚合性, 对于服从狄利克雷分布的随机变量有如下情况:

$$\begin{aligned} (x_1, x_2, \dots, x_K) &\sim Dirichlet(\alpha_1, \alpha_2, \dots, \alpha_K) \\ (x_1 + x_2, x_3, \dots, x_K) &\sim Dirichlet(\alpha_1 + \alpha_2, \alpha_3, \dots, \alpha_K) \end{aligned} \quad (2-11)$$

(l_1, l_2, \dots, l_j) 是 $(1, 2, \dots, n)$ 的一个划分则有

$$\left(\sum_{i \in l_1} x_i, \dots, \sum_{i \in l_j} x_i\right) \sim Dirichlet\left(\sum_{i \in l_1} \alpha_i, \dots, \sum_{i \in l_j} \alpha_i\right) \quad (2-12)$$

相应的该聚合性的交叉为

$$\begin{aligned} (x_1, x_2, \dots, x_K) &\sim Dirichlet(\alpha_1, \alpha_2, \dots, \alpha_K) \\ (\pi_1, \pi_2) &\sim Dirichlet(\alpha_1 \beta_1, \alpha_1 \beta_2) \end{aligned} \quad (2-13)$$

$\beta_1 + \beta_2 = 1$ 可以将上述两个式子整合为

$$(x_1 \pi_1, x_1 \pi_2, x_2, \dots, x_K) \sim Dirichlet(\alpha_1 \beta_1, \alpha_1 \beta_2, \alpha_2, \dots, \alpha_K) \quad (2-14)$$

除此之外狄利克雷分布还涉及到测度的概念。测度在数学上是一个给定集合中关于描述类似面积、体积和概率等方面的一个函数。积分是针对区间的概念来说的，而测度则是将积分扩展到任意可测度的空间上。测度还可以理解为一个分布函数，在狄利克雷过程中就可以将该过程中的一个分布看作是对于某个参数空间的测度。

2.2.2 狄利克雷过程

狄利克雷过程是属于贝叶斯无参模型中的一种以狄利克雷分布为基础向无限维拓展的与高斯过程类似的无限边缘分布。狄利克雷过程在实际应用中多是以狄利克雷混合模型的形式出现，与它类似的高斯过程最常见的应用也同样是混合模型。

在高斯混合模型中根据高斯分布任何连续的概率分布都可以由若干个高斯分布混合逼近的性质和假设样本数据是由多个高斯混合分布产生的这两个条件推测出高斯过程就是由多个高斯分布混合而成的。由此可以类比出狄利克雷过程也是由多个狄利克雷分布混合而成的。

狄利克雷过程的定义可以描述为：狄利克雷过程 $DP(\alpha_0, G_0)$ 是在可测度空间 (θ, B) 上随机概率测度 G 的分布，假设随机概测度 G 的基分布 G_0 是基于 θ 的分布， α 是一个大于零的实数，那么对于参数 θ 的任意有限可测划分 A_1, \dots, A_r ，它对应的随机概率测度 G_1, \dots, G_r 即为参数为 $\alpha_0 G(A_1), \dots, \alpha_0 G(A_r)$ 的有限维狄利克雷分布，其表达式为

$$(G(A_1), \dots, G(A_r)) \sim \text{Dirichlet}(\alpha_0 G_0(A_1), \dots, \alpha_0 G_0(A_r)) \quad (2-15)$$

假设一个随机分布 G 时狄利克雷过程 $DP(\alpha_0, G_0)$ 的一个样本，那么可以将这种情况记为 $G \sim DP(\alpha_0, G_0)$ ，所以随机分布 G 就是一个由该狄利克雷过程 $DP(\alpha_0, G_0)$ 给定的一个随机概率测度。狄利克雷过程是分布的分布的理解也就是狄利克雷过程 $DP(\alpha_0, G_0)$ 是一个随机概率分布 G 的随机分布。对于狄利克雷过程 $DP(\alpha_0, G_0)$ 中定义中的基分布 G_0 和集中参数 α_0 的理解是狄利克雷过程的基分布 G_0 就是该狄利克雷过程的均值，而集中参数 α_0 则描述的是该狄利克雷过程在基分布 G_0 附近的集中程度，它是通过影响该狄利克雷过程的方差也就是随机概率测 G 与基分布 G_0 之间距离大小来表现这一点的。

狄利克雷过程的性质在构建狄利克雷数学模型并进行相关计算时有着很大的作用，因此这里再简单描述一下相关的重要性质。主要是关于狄利克雷过程后验分布的性质，假设 $\theta_1, \dots, \theta_n$ 是从服从狄利克雷过程 $DP(\alpha_0, G_0)$ 的随机概率测度 G 中采样得到的样本数据，那么根据贝塔分布的高维扩展狄利克雷分布和二项分布的高

维扩展多项式分布互为共轭的性质可以得到对于任意的关于 θ 的有限可测度划分 A_1, \dots, A_r 有 G 的后验分布表达式为

$$(G(A_1), \dots, G(A_r) | \theta_1, \dots, \theta_n) \sim \text{Dirichlet}(\alpha_0 G_0(A_1) + n_1, \dots, \alpha_0 G_0(A_r) + n_r) \quad (2-16)$$

根据上述表达式(2-16)可以得出随机概率测度 G 的后验分布也是一个狄利克雷过程且它的基分布和集中参数变为

$$\begin{aligned} \alpha'_0 &= \alpha_0 + n \\ G'_0 &= \frac{\alpha_0}{\alpha_0 + n} G_0 + \frac{n}{\alpha_0 + n} \frac{\sum_{i=1}^n \delta_{\theta_i}}{n} \end{aligned} \quad (2-17)$$

将改变后的随机概率测度 G 的基分布和集中参数写入其后验分布的表达式中可以得到如下式子

$$(G | \theta_1, \dots, \theta_n) \sim DP \left(\alpha_0 + n, \frac{\alpha_0}{\alpha_0 + n} G_0 + \frac{n}{\alpha_0 + n} \frac{\sum_{i=1}^n \delta_{\theta_i}}{n} \right) \quad (2-18)$$

其中 $\sum_{k=1}^n \delta_{\theta_i}(A_k) = n_k$ 。

这一性质说明服从狄利克雷过程的随机测度 G 的后验分布 $G | \theta_1, \dots, \theta_n$ 也服从狄利克雷过程。在随机概率测度 G 的后验分布 $G | \theta_1, \dots, \theta_n$ 中其基分布 G'_0 是先验分布中基分布 G_0 和经验分布 $\sum_{i=1}^n \delta_{\theta_i} / n$ 的加权平均且其权重分别正比于集中参数和样本数量。由此还可以推断当随机概率测度 G 的集中参数 α_0 趋近于零的时候随机概率测度的后验分布几乎是由经验分布所确定，当观测的样本数据量 n 远大于随机概率测度 G 的集中参数 α_0 的时候随机概率测度的后验分布也几乎由经验分布确定。所以狄利克雷过程的后验分布几乎由真实分布的近似值经验分布来确定，这也体现了狄利克雷过程与真实分布的一致性。

2.3 狄利克雷过程混合模型

2.3.1 断棍模型

狄利克雷过程是随机概率测度 G 的分布，所以要构造狄利克雷过程需要先解决随机概率测度 G 这一随机分布的构造问题。这里介绍的第一种构造随机分布 G 的方法是基于短棍模型的直接构造法，该构造法在狄利克雷混合模型的应用中占比较大。

基于断棍模型的构造方法步骤如下，先假设一根棍子长度为 1 并定义一个服从贝塔分布的变量序列为 $\beta \sim \text{Beta}(1, \alpha)$ ；接下来开始折棍子，第一步先在长度为 1 的这根棍子一端截取占比为 β_1 的一段并将这段长度为 β_1 的棍子长度记为 π_1 ，此时截取后剩下的长度为 $L_1 = 1 - \beta_1$ ；第二步接着剩下的长度为 L_1 的棍子上截取占比 β_2 的一段并将这段长度为 $\beta_2 L_1$ 的棍子长度记为 π_2 ，此时截取后剩下的长度为 $L_2 = L_1(1 - \beta_2)$ ；第三步继续接着剩下的长度为 L_2 的棍子上截取占比为 β_3 的一段并将这段长度为 $\beta_3 L_2$ 的棍子长度记为 π_3 ，此时截取后剩下的长度为 $L_3 = L_2(1 - \beta_3)$ ，以此类推每次都按照在剩下部分棍子长度中占比为 β_4, β_5, \dots 的比例截取获得长度分别为 π_4, π_5, \dots 的短棍，由此构造出来的模型即为断棍模型，其过程如下图所示




图 2-1 断棍模型

由上面的折棍子步骤可以得出短棍模型的函数表达式如下

$$\begin{aligned} \beta_k &\sim \text{Beta}(1, \alpha_0) \\ \pi_k &= \beta_k \prod_{i=1}^{k-1} (1 - \beta_i) \end{aligned} \quad (2-19)$$

其中 π_i 为正实数且 $\sum_{i=1}^{\infty} \pi_i = 1$ ，因此可以将 π_1, π_2, \dots 看作是一个关于正整数的随机概率分布，由此上式中 π 服从的参数为 α_0 分布可以记为 $\pi \sim \text{GEM}(\alpha_0)$ 。将该短棍模型与狄利克雷过程结合起来时可以得到每次折棍子得到的长度 π_k 也就是狄利克雷过程中某一分布 G_0 的观测样本 θ_k^* 的取值概率，所以可以得到基于短棍模型构造随机概率测度 G 获得的狄利克雷过程 $DP(\alpha_0, G_0)$ 的函数表达式为

$$\begin{aligned}\beta_k &\sim \text{Beta}(1, \alpha_0) & \theta_k^* &\sim G_0 \\ \pi_k &= \beta_k \prod (1 - \beta_l) & G &= \sum \pi_k \delta_{\theta_k^*}\end{aligned}\quad (2-20)$$

2.3.2 狄利克雷混合模型

在贝叶斯分类模型中无参估计的分类模型中假设的分类数目是可以随着样本数据复杂情况的变化而发生改变的，但在与无参估计分类模型相对应的有参估计分类模型中，假设的分类数目一般而言都是固定不变且是需要预先知道的先验知识。但是这些要求在实际的工程应用中是很难可以做到的，且现在得到广泛的使用的有参估计分类模型主要都是通过一次又一次的进行试错试验来估计应用中需要分类的数目。因此在实际的工程应用中大多都是选择使用无参估计的分类模型，而狄利克雷过程结合其他模型如断棍模型和中国餐馆过程等构造出来的狄利克雷混合模型（DPMM）^[34]可以说是在无参估计的分类模型中最好的模型了。

用狄利克雷混合模型处理分类问题时可以先假设观测到的一组样本数据 $X = \{X_n\}_{n=1}^N$ 并且有 $X_n = [X_{n,1}, \dots, X_{n,d}]^T \in R^d$ ，除此之外还需要假设观测到的数据 X_n 服从某个随机分布 $X_n | \theta_n \sim f_{\theta_n}(X_n)$ 且该随机分布的参数是也服从某一种分布的随机变量 θ_n 。观测样本数据服从的随机分布的参数 θ_n 在通常情况下其先验分布都是没有办法得知的，刚好的是上文分析中提到狄利克雷过程中的随机概率测度 G 就表示了某一种未知的随机概率分布，因此结合这两个方面就可以将该参数 θ_n 服从的随机概率分布看作是狄利克雷过程中随机概率测度 G 也就可以把这个过程记为 $\theta_n | G \sim G$ 。由狄利克雷过程的构造可以得知随机概率测度 G 是一个定义在无限集合上的离散概率分布从而可以推断出观测样本数据服从的随机分布参数 θ_n 的取值不仅是没有上界的限制还会随着观测样本数据的增多而随之增加。

进一步由观测样本数据服从的随机分布参数 θ_n 可以唯一确定观测样本数据 X_n 服从的随机分布这一点可以推断出狄利克雷混合模型中可以包含无限多的随机概率分布且分量的个数模型可以从观测到的样本数据中自动推断而不需要人工来提供。综合上面的内容可以得到狄利克雷混合模型的函数表达式为

$$\begin{cases} G \sim DP(\alpha_0, G_0) \\ \theta_n | G \sim G \\ X_n | \theta_n \sim f_{\theta_n}(X_n) \end{cases} \quad (2-21)$$

由上面的式子(2-21)可以得出随机概率测度 G 是定义在无限集合上的离散概率分布所以对应的观测到的样本数据服从的随机分布的参数 θ_n 的取值也就有无数个也就是说狄利克雷混合模型在对观测到的样本数据进行分类时其分类的数目是没有限制的。

构造狄利克雷混合模型时选用常用的断棍模型也就是用断棍模型替代狄利克雷过程的随机概率测度 G 可以得到狄利克雷混合模型的断棍模型函数表达式

$$\begin{aligned} \pi | \alpha_0 &\sim GEM(\alpha_0) & \theta_k^* &\sim G_0 \\ Z_n | \pi &\sim Multi(\pi) & X_n | Z_n, \theta_k^* &\sim f(\theta_{Z_n}^*) \end{aligned} \quad (2-22)$$

式子(2-22)中 Z_n 表示的时观测到的样本数据 X_n 所属的参数为 $\theta_{Z_n}^*$ 的随机概率分布。根据断棍模型和狄利克雷混合模型的构造过程，可以得到由断棍模型构造出来的 θ_k^* 就是狄利克雷混合模型中概率分布的参数，且由断棍模型构造出来的属于多项式分布的概率质量序列 π 构成了狄利克雷混合过程中随机概率分布索引变量 Z_n 的参数，索引变量 Z_n 可以通过对观测到的样本数据属于哪一个概率分布的判断来实现对这些观测到的样本数据的分类。也就是说当假设观测到的样本数据 X_n 的概率分布参数为 θ_n 时就会有 $\theta_n = \theta_{Z_n}^*$ 这样一个等式成立。根据 θ 的后验分布为 $p(\theta|X)$ 和狄利克雷过程的性质可以得到 X_{N+1} 的预测分布函数表达式为

$$p(X_{N+1} | X) = \int p(X_{N+1} | \theta) p(\theta | X) d\theta \quad (2-23)$$

由贝叶斯公式来计算 θ 的后验分布可以得到其函数表达式为

$$p(\theta | x) = \frac{p(x | \theta) p(\theta)}{\int p(x | \theta) p(\theta) d\theta} \quad (2-24)$$

但是这里狄利克雷混合模型的参数的先验分布 G_0 和似然函数 $p(x | \theta)$ 的形式过于复杂且其积分表达式很难直接计算出来结果。

为了解决分布参数的联合后验分布^[35]难以计算这个问题，现有的文献种研究者大多数都采用了马尔科夫链蒙特卡洛采样算法，从给定的观测样本数据 X 的分布参数 θ_n 的后验分布 $p(\theta | x)$ 中进行抽样操作并以此来对其进行近似最大后验概率估计。根据上面的分析可以得知当给定其余参数 $\{\theta_j\}_{j \neq n}, \theta_n$ 的条件概率时可以基于吉布斯 (Gibbs) 抽样算法来构造一个马尔科夫链蒙特卡洛算法，并将其用于从 $(\theta_1, \dots, \theta_N)$ 的联合后验分布中来抽取样本，这些抽样得到的样本经过证明可以以概率 1 收敛于 $(\theta_1, \dots, \theta_N)$ 的真实后验分布，也就可以证明这种抽样算法时一种估计观测样本数据的参数分布 θ_n 的有效算法。

不过抽样算法离不开需要抽取到足够数量的样本才能收敛而且收敛速度相对比较缓慢的天生的缺点，不仅如此抽样算法还有不确定性大和一般对于数据量规模比较大情况都不太适用的问题。因为抽样算法的这些确定本文选择了变分法这一不同于抽样算法的确定性的近似算法。变分法假设模型中的隐变量之间相互独立并且用一个具有解析表达式形式的近似分布去近似目标分部然后再通过将该近

似分布与目标分布之间的 KL 散度^[36]进行最小化这一步骤将近似问题转化为确定性的近似优化问题。因此与马尔科夫链蒙特卡洛抽样法相比较的话变分法的很明显具有更快的收敛速度。

2.4 后验分布近似算法

贝叶斯概率模型里有一项重要的任务，就是研究在观测样本数据 X 给定的情况下如何获得该模型中隐变量 Z 的后验分布 $p(Z|X)$ 和如何计算基于这个后验分布的期望问题。在一个贝叶斯模型比如涉及到对模型中隐变量的后验分布进行计算，期望最大化（EM）算法需要先对该模型中所有的未知参数都赋予一个先验分布，并且将这些未知的参数都记入一个被记为 Z 的向量，那么该向量也就是该模型中的隐变量。但是在许多实际的应用中这种贝叶斯模型中的隐变量 Z 很大可能是高维的变量，因此对于这种高维变量 Z 的相关操作都会变得非常困难。在变量是连续分布的情况时运算时所要求解的积分很有可能根本没有封闭的解析解，且其空间的维数和被积函数的复杂性，也都是有可能造成这些相关的积分运算在数值上无法成功得出运算结果。而在变量是离散分布的情况时积分运算直接变成了对于隐变量 Z 中所有的可能的取值的加权求和导致这种情况在理论上看起来是完全可行的，但是在实际的应用中却又极其有可能出现结果是指数级的情况。所以无论变量是连续分布还是离散分布都免不了大量的计算而借助于一定的近似算法就可以一定程度上减小精确计算的代价。

近似算法大体上可以划分为代表方法分别为尔科夫蒙特卡洛（MCMC）抽样算法的概率性近似算法和变分法（VI）的确定性近似算法这两类。概率性近似算法能够在一定的时间内达到近似的效果，且能够提供的计算资源越多这些算法就能够计算出更加精确的结果。当然在实际的工程应用中概率性近似算法这一类抽样算法其实对计算资源的需求是非常大的，也因此导致这一类的算法通常情况下只适用于数据规模比较小的问题。所以本文选择了采用变分法这种确定性的近似算法。确定性近似算法主要是通过借助数学工具对目标的分布进行解析近似以获得近似的解析解。不过因为确定性近似算法存在不能计算出确切结果的问题所以确定性近似算法和概率性近似算法其实是互补的^[37]。

2.4.1 马尔科夫链蒙特卡洛算法

蒙特卡洛算法其实就是通过从概率模型中进行随机抽样并进行近似的数值计算的方法，马尔科夫链蒙特卡洛采样算法顾名思义其实就是概率模型是马尔科夫链的蒙特卡洛算法。具体来说马尔科夫链蒙特卡洛采样算法就是先构建一个马尔

科夫链模型并确定该需要进行抽样的分布是平稳分布，再就是基于该马尔科夫链模型进行随机的游走来产生抽样样本的序列，并使用从这个平稳分布中抽样得到的样本来做近似的数值计算。马尔科夫链蒙特卡洛采样算法是一种重要的统计学计算方法并被广泛的应用于对随机概率分布的估计、定积分的近似计算、最优化问题的近似求解和概率模型的构造和推理等等方面。

马尔科夫链蒙特卡洛采样算法其实就是一个在给定的概率分布 $p(x)$ 中进行抽样，并且其中在给定一个 x 的情况下一定可以根据已知的概率分布 $p(x)$ 来求出的值的抽样算法。在马尔科夫链蒙特卡洛采样算法出现之前就已经有了不少其他的抽样算法，比如可以说是马尔科夫链蒙特卡洛采样算法直接的催化剂的拒绝抽样和重要性抽样这两种抽样算法。当然还有一种很简单的被称为反向抽样的抽样算法。但拒绝抽样和重要性抽样都存在在不知道真实的分布的先验知识的情况下想选择更加合适的媒介分布函数就需要进行不断的尝试这一问题，在这个尝试的过程中如果出现选择的媒介分布函数造成的 $\max(p(x)/q(x))$ 的值非常大的情况，那么拒绝抽样算法就会出现一种拒绝新的建议且重要性抽样算法抽出的样本数据也会出现有很大的方差的情况。更重要的是拒绝抽样算法和重要性抽样算法每一次的抽样都是相互独立的也就是说这两种算法都是无记忆性的也就导致这两种算法的效率低下。而马尔科夫链蒙特卡洛采样算法却因为马尔科夫链中一个状态只与上一个状态有关的特点可以在这一次的抽样过程中用到上一次抽样得到的信息，进而大大提高了这一种抽样算法的效率并使其一跃称为二十世纪十大算法之一。

马尔科夫链蒙特卡洛采样算法其实主要就是通过构造一个可以收敛到 H 的马尔科夫链来实现从目标分布函数 $H(x)$ 中进行抽样的目的，这里构造的马尔科夫链的收敛性只与该模型的转换核心(transition kernel)也就是过渡核 $p(x_{t+1}|x_t)$ 有关而与初始的状态等方面没有一点关系。这一以来马尔科夫链蒙特卡洛采样算法的主要问题就集中在了对转换核心的设计问题上。在这个问题上马尔科夫链蒙特卡洛采样算法其实跟上文提到的拒绝抽样算法和重要性抽样算法是一样的，都是先选择一个媒介分布函数 $q(x)$ 并从中进行抽样操作以获得一定的样本数据，之后再引入一个拒绝机制用来以某个一定的概率对上面抽样获得的样本数据进行筛选。这其中引入的拒绝机制就是使得选择的马尔科夫链模型可以达到细致平稳条件且可以保证马尔科夫链能够收敛到 H 的关键。对于具有可逆性的细致平稳条件的理解可以简单的描述为，假设有一列编号分别为 $1, 2, \dots, n$ 的水坑同时还有设定水坑 i 里面的水量用 H_i 来描述，且该水坑 i 里面的水会有比例为 p_{ij} 的这一部分的水流向水坑 j ，在这样的情况下如果任意两个水坑之间互相流向的水量其实是一样的比如说水坑 i 流向水坑 j 的水量和水坑 j 流向水坑 i 的水量一样那么就可以成这里每一个

坑的水量都是平稳的。对于保证马尔科夫链可以收敛到 H 其实需要满足常用的细致平稳条件和全局平衡条件(global balance condition, GBC)这两个条件, 其中全局平衡条件用上文中对细致平稳条件的描述方法来说的话其实就是要满足从任意一个水坑 i 中流出来的水量与流入该水坑的水量相等这一条件。这两个条件中细致平稳条件因为只需要考虑前后这两种状态就可以了所以细致平稳条件是比较容易构造且最常用的一个。用全局平衡条件来构造算法是目前对马尔科夫链蒙特卡洛采样算法进行研究的一个热门方向, 其随着深度学习在各个领域的应用发展也有研究者用马尔科夫链蒙特卡洛采样算法结合神经网络提出了一些如 NNGHMC 和 A-Nice-MC 等新的算法。

2.4.2 变分法

十八世纪时欧拉和拉格朗日等人就进行了变分计算这差不多可以看作变分算法的起源。一个标准的微积分必然与其函数的导数密不可分也就是当把一个函数看成一个映射的时候, 它可以完成将一个变量的值输入该函数并计算后输出该函数的值。函数的导数描述的是当它的输入值无限小的时候它的输出值是如何随着它的输入值的变化而变化。当将函数定义为一个输入为函数输出为函数的值的映射时相对应, 就可以把函数的导数的定义表述为当它的输入函数的改变值为无限小时, 它描述了一个函数的输出值随着它的输入函数的改变而发生改变的程。如果用一个优化问题来描述这里关于求解函数导数的问题且在这个问题里被优化的量时一个函数, 那么就可以通过搜索所以可能的输入函数来达到最大化或者最小化的目的。

变分法具体极高的适用性其在最大熵和有限元方法等领域中都可以拿来使用并解决的实际问题。其实变分法在本质来说并没有进行任何的近似计算只不过变分法很适合用来寻找近似解, 变分法的求解是通过限制优化变量的取值范围来完成的, 比如在二次函数或者由固定的基础函数线性构造出来的函数, 且构造这种函数时只有线性组合的系数可以发生改变或者在应用到概率问题时需要限制分布的因子分解等方面。将变分法应用到近似求解问题当中时整个思路可以描述为: 先假设一个既有参数变量也有隐变量且这些参数变量都各有相对应的先验分布的贝叶斯估计模型, 并且把所以的隐变量记为向量 Z , 而观测到的大的样本数据可以记为 X 。在这里构造的概率模型给出了联合分布函数 $p(X,Z)$ 的表达式的情况, 就只需要找到后验分布函数 $p(Z|X)$ 的某一个近似分布函数 $q(Z)$, 根据条件概率的公式可以得到关于观测到的样本数据的表达式如下

$$p(X) = \frac{p(X, Z)}{p(Z|X)} \quad (2-25)$$

对式子(2-25)的两边同时取对数可以得到式子

$$\ln p(X) = \ln p(X, Z) - \ln p(Z|X) \quad (2-26)$$

根据表达式(2-26)和对数的性质可以得到

$$\begin{aligned} \ln p(X) &= \ln p(X, Z) - \ln p(Z) - \ln p(Z|X) + \ln p(Z) \\ &= \ln \frac{p(X, Z)}{p(Z)} - \ln \frac{p(Z|X)}{p(Z)} \end{aligned} \quad (2-27)$$

再对式子(2-27)的两边同时对 $q(Z)$ 取期望可以得到

$$\begin{aligned} E_{q(Z)}[\ln p(X)] &= \int q(Z) \ln p(X) dZ = \ln p(X) \\ E_{q(Z)}\left[\ln \frac{p(X, Z)}{q(Z)} - \ln \frac{p(Z|X)}{q(Z)}\right] &= \int q(Z) \ln \frac{p(X, Z)}{q(Z)} dZ \\ &\quad - \int q(Z) \ln \frac{p(Z|X)}{q(Z)} dZ \end{aligned} \quad (2-28)$$

可以用下面这两个式子对表达式(2-28)进行化简

$$\begin{aligned} L(q) &= \int q(Z) \ln \frac{p(X, Z)}{q(Z)} dZ \\ KL(q||p) &= - \int q(Z) \ln \frac{p(Z|X)}{q(Z)} dZ \end{aligned} \quad (2-29)$$

将式子(2-29)代入(2-28)可以得到下面的表达式

$$\ln p(X) = L(q) + KL(q||p) \quad (2-30)$$

由式子(2-30)可以得出下面的不等式

$$\ln p(X) \geq L(q) \quad (2-31)$$

在这里参数变量 θ 是被当作随机变量合并到隐变量 Z 中因为与一般的分布中的求解问题有所不同。上面这些式子中使用的都是积分而不是针对离散型随机变量需要用到的求和，因为本文中关注的问题中的变量是连续型随机变量但变量的类型并不影响分析的过程，如分析的问题中的变量的类型有改变只需要改变积分

和求和这两个操作即可。在这个分析过程中概率分布 $q(Z)$ 就是整个过程的自变量，求 $L(q)$ 的最大值时要知道其上限其实就是 $\ln p(X)$ ，根据上面的分析可以看出来当 $L(q)$ 的取值达到最大值的时候 $KL(q|p)$ 也就相应的会取得它的最小值。 $KL(q|p)$ 被称为 KL 散度和相对熵并且还是一种用来衡量两个分布的相似程度的非对称度量也就是有 $KL(q|p) \neq KL(p|q)$ 成立。当自变量概率分布 $q(Z)$ 可以选择任意的一种分布时存在最理想的情况 $KL(q|p)=0$ 并且这种情况下可以得到关系式 $p(Z|X)=q(Z)$ 。

但是实际的应用中基本没有办法对后验概率分布函数 $p(Z|X)$ 直接进行使用，所以需要在将概率分布 $q(Z)$ 变得更加容易使用的基础上对其加上一些限制条件，使得概率分布 $q(Z)$ 更加接近后验概率分布函数 $p(Z|X)$ 。假定概率分布 $q(Z)$ 是可以从一个有限分布的族里面进行选择，那就需要从这个有限的分布族里面找到是该过程中散度最小的那一个随机分布。进一步的关键点在对这个有限的分布族进行设定时，既要满足在对其进行充分的限制的情况下使得这个有限的分布族里面只包含容易进行解析和处理的随机分布，还要满足这个有限的分布族具有足够的丰富性和灵活性以使得这个有限的分布族可以完成对真实的后验概率分布函数的较好的近似。这些限制条件的存在只是为了解决原来的分布中出现的不容易进行解析处理的问题，并使近似达到更加容易进行处理，而且在具有丰富的有限的分布族来得到真实的后验概率分布的近似的情况下必须要注意这种灵活的有限分布族不存在过拟合的问题。

2.5 本章小结

本章首先介绍了贝叶斯无参模型概念，并进一步引入了贝叶斯无参模型中最常用的狄利克雷模型并分别介绍了狄利克雷分布和狄利克雷过程的相关理论知识，说明狄利克雷过程本质上是分布上的分布，是多项分布的共轭先验分布并且可以表示多项分布的参数取某个值的概率有多大。然后又介绍了狄利克雷混合模型中断棍模型和中国餐馆过程这两种比较经典的构造过程，并在这个过程中加深了对狄利克雷过程的理解，接着给出了构造的狄利克雷混合模型和基于狄利克雷混合模型的分类型模型的数学模型。最后介绍了求解狄利克雷混合模型后验联合分布的两种近似算法，这是分类模型中需要解决的一个大问题。

第三章 基于狄利克雷混合模型的无线电信号分类算法

在对未知电磁环境中的无线电信号进行分类处理时，首先需要对采集到的信号进行预处理以使得这些信号更便于后续的特征提取和信号分类识别等信号处理过程。对于无线电信号进行分类识别时需要预先得到无线电信号的一些特征参数，所以本文根据无线电信号的特征和选用的基于狄利克雷混合模型的无线电信号分类模型选出了无线电信号的带宽、载波频率和循环频率这三个特征参数进行特征提取。基于狄利克雷混合模型本文构造出了系统的信号分类模型并通过仿真证明了该模型的有效性。

3.1 无线电信号预处理

在对无线电信号进行采集时得到的信号数据不仅仅会受到干扰、噪声和信道特性等等各个方面的影响，还有可能出现因为采集无线电信号时用到的硬件的设备或者用到的软件的设计出现问题等人为的对采集到的信号数据结果产生影响的情况。针对上面提到的这些可能发生的情况本文采样了一套通常情况下都能应用的关于采集到的无线电信号的预处理流程。该流程如下图 3-1 所示

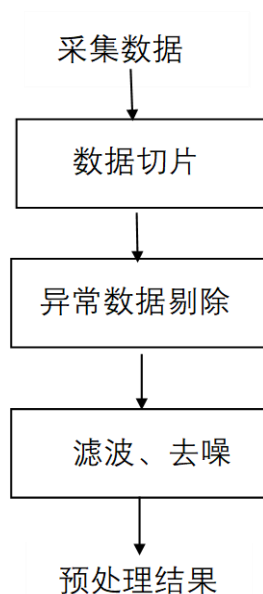


图 3-1 无线电信号预处理流程图

(1) 数据切片

数据切片可以通过对这些样本信号的切片使得这些切片后的数据样本保持一样的长度，同时也可以用于在采集到的信号数据的数目较少单个信号数量却比较大的情况下扩展样本数据的规模。数据切片使样本在数据长度上具有一致性以便于后续的对无线电信号的特征提取和分类识别等处理，不过在对样本数据进行切片时还需要注意选择的信号的切片长度要能保证不破坏信号的完整性。

(2) 异常数据剔除

在对无线电信号进行采集时往往可能出现采集信号数据的设备不稳定的情况，而这种情况下很有可能导致采集到的信号数据存在空数据、重复数据和异常数值等等异常的情况，进而很大程度上对采样得到的信号数据的准确性产生影响。采集到的无线电信号的准确性一旦出现问题，后续对这些无线电信号的特征提取和分类识别等处理也不可避免的会受到影响，因此需要对这些无线电信号数据进行一定的处理以尽量消除这些可能的异常情况对后续无线电信号处理产生的影响。

其中对于异常数值这一点本文选择了使用 **hampel** 滤波来完成对采集到的无线电信号中的异常数值的检测和删除，这种方法的原理可以简单的描述为先围绕一个用一维的向量如 $X = \{x_1, x_2, x_3\}$ 表示的序列中的每一个元素生成对应的观测窗口，并且将这个观测窗口的半个窗口宽度假设为 k ，相对于的就可以得到包含观测窗口中心的那个元素的整个的观测窗口的宽度也就为 $2k+1$ ，接下来计算整个观测窗口中所有的元素的中值，并用这个中位数的绝对值来对各个样本的中值的标准差进行估计，当摸一个样本点的数值与其对应的中值相差超过桑标准差的时候就可以用相应的中值来代替这一个样本点，以此来实现对信号样本中存在的异常数值的检测和剔除。




图 3-2 异常数据剔除 hamper 滤波

(3) 滤波

因为在现实的生活和工作中噪声无处不在等各种原因实际采集到的信号样本数据往往都是含有噪声的，所以在实际的工程应用中对采集到的信号数据进行处理时都避不开对很可能会掩盖信号本身所表达出来的信息的噪声的处理。

3.2 无线电信号特征提取

对未知复杂的无线电环境中的信号进行分类识别等处理前需要得到可以作为样本数据输入到相应的无线电信号分类模型的数据库。本文选择了无线电信号的载波频率、无线电信号符号率对应的循环频率和无线电信号的带宽这三个特征进行提取来组成输入无线电信号分类模型的样本数据。将该复杂电磁环境中的无线电信号记为 $X_{1:N} \triangleq \{X_n\}_{n=1}^N$ ，对信号 n 进行特征提取后得到的对应的特征向量 X_n 记为 $X_n = \{X_{n,1}, X_{n,2}, X_{n,3}\}^T$ 并分别代表了无线电信号的带宽、载波频率和循环频率。对于无线电信号的这三个特征本文分别选择了对应的算法来进行提取，其中无线电信号的带宽的估计选择了使用信号的功率谱密度来完成而无线电信号的载波频率和循环频率都可以用信号的循环谱密度来进行估计。

3.2.1 无线电信号带宽估计

对于一个确定的信号来说它唯一的对应了一个确定的频谱与之相对应的对于一个随机信号来说，它在不同的时间表现出来的信号的波形是会发生变化的也就是说随机信号在不同的时间会对应着不同的频谱。因为一个广义的平稳随机信号的均值是一个常数，也就是说一个广义平稳随机信号的自相关函数只跟信号持续的时间长度或者说观测这个信号的时间间隔有关系而不会像它的频谱一样随着时间的变化而变化，也就是说广义平稳随机信号的自相关函数与观测该信号的时间点无关。不过只观察广义平稳随机信号的自相关函数的波形也就是只从信号的时域进行观察在信号处理的不少领域都是不够，因此可以对自相关函数做傅里叶变换以得到其频域方面的信息，而一个信号的自相关函数的频域表达其实就是该信号的功率谱密度函数。从上面的分析可以得出对于一个广义的平稳随机信号来说，它的功率谱其实是一个可以体现出该随机信号统计特性的统计量并且它并不会像随机信号的频域一样随着时间的不同而发生变化。

功率谱估计在对广义平稳的随机信号的分析处理，比如雷达的信号处理和各种故障的诊断等实际的工程应用等领域得到了非常广泛的应用。对平稳的各态遍历的随机信号分析器频率成分的时候就可以通过功率谱来完成，并且在这整个过程中是通过获取的该平稳各态遍历随机信号的某些离散的数据点，并利用这些书

记点来绘出的一个“非精确”的功率谱来进一步的完成对该平稳各态遍历随机信号的真实的功率谱的估计。分辨率和方差差不多可以说是评价功率谱的性能如何的两大重要标准了，其中之一的分辨率也就是功率谱上能够区分出来的最小的相邻频率成分，并且它跟功率谱之间的关系是功率谱的分辨率越高该随机信号在功率谱上频率的成分也就更加清楚，而反映功率谱的波动情况的则是另一个重要标准也就是方差，且功率谱的波动也就是方差太大的时候在该随机信号的功率谱中很可能会出现有用的频率成分反而被噪声掩盖的情况。因此对于根据获取的该随机信号的一些离散数据点得出的“非精确”的功率谱要想得到更好的估计目标就需要有更高的分辨率和更小的方差。

根据概率论与数理统计中一致估计与非一致估计的概念，可以得出当一个广义的平稳随机信号的真实功率谱记为 $S(\omega)$ ，通过离散的数据点得到的“非精确”的功率谱记为 $\hat{S}(\omega)$ 时，其对应的一致估计可以用下面的这个公式(3-1)来表示

$$\lim_{N \rightarrow \infty} \text{var} \{ \hat{S}(\omega) \} = S(\omega) \quad (3-1)$$

周期图法的原理可以描述为对 N 个已知的离散数据点 $u_N(n)$ ，进行傅里叶变换并得到相应的表达式如下

$$U_N(\omega) = \sum_{n=0}^{N-1} u_N(n) e^{-j\omega n} \quad (3-2)$$

对表达式(3-2)取模平方再除以 N 就可以得到“非精确”的功率谱，其表达式如下

$$\hat{S}(\omega) = \frac{1}{N} |U_N(\omega)|^2 \quad (3-3)$$

这整个过程就是周期图法的原理了。但是根据上面的式子(3-3)对得到的功率谱的分辨率和方差进行分析，可以看出因为周期图法得到的功率谱在数据点数 N 增大的情况下其分辨率会变得更高，但同时它的方差也会变得更大。这样的情况跟期望分辨率尽可能高而方差尽可能小的情况是不一样的，因此在周期法的基础上需要进一步的降低该功率谱的方差。为了达到这一目的可以采用平均周期图法，且该方法主要是将这 N 个观测到的数据点分为 L 段，每一段的长度都是 M ，然后再分别对每一段的数据点求其各自的周期图的功率谱，并在最终进行平均的操作，这样改善后的平均周期图法得到的估计功率谱的方差及其整个的改善过程可以用下面的这些式子来表示

$$\begin{aligned}
\text{var}(\bar{X}) &= E[\bar{X}^2] - E[\bar{X}]^2 = \frac{1}{L} \text{var}(X_i) \\
E[\bar{X}^2] &= E\left[\frac{1}{L} \sum_{i=0}^{L-1} X_i \frac{1}{L} \sum_{j=0}^{L-1} X_j\right] \\
&= \frac{1}{L^2} E\left[\sum_{i=0}^{L-1} X_i \sum_{j=0}^{L-1} X_j\right] \\
&= \frac{1}{L^2} E\left[LX_i^2 + \sum_{i=0}^{L-1} X_i \sum_{j=0, i \neq j}^{L-1} X_j\right] \\
&= \frac{1}{L} E[X_i^2] + \frac{1}{L^2} L(L-1) E[X_i]^2 \\
&= \frac{1}{L} E[X_i^2] + \frac{L-1}{L} E[X_i]^2
\end{aligned} \tag{3-4}$$

根据上面的式子(3-4)可以得出平均周期图法可以将周期图法的方差变为原来的 $1/L$ ，平均周期图法得到的功率谱的分辨率和方差都会随着分段数 L 的增大而变小。因此在观测的样本信号的数据点的个数 N 是一定的情况下，要想降低功率谱的方差就必须增大分段数 L ，但是在观测的样本信号的数据点的个数 N 不大的情况下，分段后每一段的长度 M 也会比较小而相应的该功率谱的分辨率就会不可避免的降低到一个比较低的水平。在分段数 L 一定的时候如果要增加功率谱的分辨率，那就需要分段后每一段的长度 M 有一个比较大的值，而要达到这一点就需要在观测信号的时候获取更多的数据点数。但是在实际的工程应用中能够获得的观测信号的数据点数往往是有限的，因此要改善这一点带来的问题可以在分段的时候允许数据段间有一些重叠的部分。这一以来在观测到的信号样本数据点 N 不足的情况下有更多的分段数 L 并得到功率谱更小的方差，同时还能得到更长的分段后每一段长度 M 以使得功率谱的分辨率更高。

综合上面的内容可以总结出这三种功率谱估计的特点：对于最简单的周期图法来说，随着观测到的样本信号数据点数的增多该功率谱的分辨率会变得更高分而该功率谱的方差也会变得更大；对周期图法进行改进得到的平均周期图法为了得到更低的方差一定程度上牺牲了功率谱的分辨率；而修正的平均周期图法通过允许数据段间存在重合的情况来实现不减小分段和每一段的长度的同时增大分段数，或者在不改变分段数的同时增大每一段的长度，进而实现功率谱的分辨率不变而功率谱的方差减小，或者功率谱的方差不变而功率谱的分辨率得到提高。用修正的平均周期图法绘出 OFDM 信号的功率谱密度图如下图 3-3 所示




图 3-3 功率谱估计法

3.2.2 无线电信号载波频率和循环频率估计

在常见的通信系统中这些非平稳的通信信号大多表现出一定的周期性，比如在模拟调制信号中因为传输的信息调制在周期信号正弦波的频率、幅度或者相位上，从而导致这些模拟调制信号也具有一定的周期性进而表现出循环平稳的特性；在数字调制信号中与模拟调制信号类似的传输的信息也周期性的调制到脉冲信号的脉幅、脉宽或者脉位上进而使得数字调制信号也具有循环平稳的特性；在光通信的系统中更是有常见的相位幅度调制、相移键控和正交振幅调制等数字调制信号且也都具有循环平稳的特性。

符号速率估计问题也就是循环频率估计问题是对通信信号的参数进行盲估计的一个非常重要的基础性问题。Ciblat 在文献[38]中提出了利用通信信号的循环自相关函数来完成通信信号的符号速率估计，这种估计是一种无偏的一致估计。还有文献[39]研究根据通信信号的循环自相关函数与该通信信号的符号速率的极大似然估计之间的关系，得出了在符号信噪比小于 20dB 的情况下通信信号的循环自相关函数和该通信信号的符号速率的极大似然估计这两者之间竟然是等效的。研究人员 Hurd 与 Gerr 在文献[40]通过通信信号循环平稳的周期可以在双谱的平面上形成一个对角线形状得到的图案这一特点来完成对通信信号的循环频率的估计，并且在这一个过程中提出了相干统计量的概念和辨别的依据。文献[41]中还提出来

一种关于通信信号这类循环平稳信号的 χ^2 测试并且证明了可以将这种测试更进一步的扩展到信号任意阶的循环平稳特性。

根据上面的这些总结毫无疑问无线电信号的符号速率是数字通信系统中一个非常重要的参数，且对这些数字调制的无线电信号的符号速率进行估计时依据也就是通信信号的循环平稳理论，而无线电信号的符号速率其实也就是无线电信号的基本循环频率，所以就可以通过无线电信号的循环自相关函数等线性的变换来提取信号的基本循环频率。对于 OFDM 信号来说可以通过对该信号循环谱的性质的分析估计出该 OFDM 信号的载波频率、码片时宽和循环频率等参数，而要想得到 OFDM 的循环谱这里采样了采样比较简便的 FAM 算法。FAM 算法其实是一种基于快速傅里叶变换并在信号的时域进行平滑操作算法，它主要是通过滑动的快速傅里叶变换来实现带通滤波器并对输入的信号样本数据进行一个抽取倍数为大于 1 的 L 倍的抽样，以此来提高算法的运算效率。根据采样定理可以知道在对输入的信号样本数据进行 L 倍的抽样的时候不会对输入样本信号的频谱的计算产生影响，却会将进行时域平均时计算采样到的数据信号的长度降低到 $1/L$ ，以此实现在这个算法中求解无线电信号循环谱时的计算量的降低。

一个 OFDM 系统中它的每一个帧长内用复信号的形式表示的子载波之间其实都是独立和正交的，并且也因此它们还与任意符号周期内的任意子载波上调制的信号也是相互独立和正交的。因此对于整个信号来说它的空间累积分布函数 (Spatial Cumulative Distribution Function, SCDF) 就是任意帧上的所有的子载波的累加和，那么基带 OFDM 信号的循环谱密度函数的表达式就如下

$$S_{rr}^a(f) = \begin{cases} \frac{1}{T_s} \sum_{p=0}^{N-1} e^{-j2\pi(a+p\Delta f)t_0} Q\left(f - p\Delta f + \frac{a}{2}\right) Q^*\left(f - p\Delta f - \frac{a}{2}\right) & a = \frac{m}{T_s} \\ 0 & \text{其他} \end{cases} \quad (3-5)$$

将调制到载频的信号的相关函数做快速傅里叶变换并展开后可以得到其自相关系数的表达式为

$$R_{ss}^a = \frac{1}{4} \left[R_{rr}^{-a}(\tau)^* e^{-j2\pi f_c \tau} + R_{rr}^a(\tau) e^{j2\pi f_c \tau} \right] \quad (3-6)$$

再对上面的式子(3-6)做快速傅里叶变换可以得到式子

$$\begin{aligned} S_s^a(f) &= \int_{-\infty}^{\infty} R_{ss}^a(\tau) e^{-j2\pi f \tau} d\tau \\ &= \frac{1}{4} \left[S_{rr}^a(f - f_c) + S_{rr}^{-a}(-f - f_c) \right] \end{aligned} \quad (3-7)$$

根据上面的式子(3-7)可以得到调制到载波频率的 OFDM 信号的循环谱密度的函数表达式为

$$S_{ss}^a(f) = \begin{cases} \frac{1}{4T_s} e^{-j2\pi a t_0} \left\{ \sum_{p=0}^{N-1} e^{-j2\pi p \Delta f t_0} Q\left(f + f_c - p\Delta f + \frac{a}{2}\right) Q^*\left(f + f_c - p\Delta f - \frac{a}{2}\right) \right. \\ \left. + \sum_{p=0}^{N-1} e^{-j2\pi p \Delta f t_0} Q\left(f - f_c - p\Delta f + \frac{a}{2}\right) Q^*\left(f - f_c - p\Delta f - \frac{a}{2}\right) \right\} & \text{其他} \\ 0 & \text{其他} \end{cases} \quad (3-8)$$

上面的表达式(3-8)就是矩形脉冲成型的 OFDM 信号的循环谱密度的函数表达式, 并且该 OFDM 信号的循环谱密度具有以下三个关系到对该 OFDM 信号的特征参数进行估计的重要的性质, 分别是第一点在 $f = \pm f_c$ 且 $a = 0$ 的时候该循环谱密度有最大值也就是说该信号的循环谱密度在 a 平面上有两个明显的相对应的峰; 第二点则是在 a 轴上该信号的循环谱密度以 $1/T_s$ 为间隔进行了切片; 第三点是该循环谱的相位只与信号的起始时间有关而与载频信号的起始相位无关。

根据上面对 OFDM 信号的循环谱密度的分析, 可以根据信号的循环谱对该信号的载波频率和基本循环频率也就是符号速率进行估计。下图 3-4 就是一个 OFDM 信号的循环谱密度图, 从这幅图中可以看出该 OFDM 信号在 $a = 0$ 的这个平面上有两个对称且明显的峰, 而这两个峰对应的频率的绝对值就是该 OFDM 信号的载波频率 f_c , 而固定 $f = f_c$ 这个平面时可以看到在 a 轴上一定的间隔也出现了两个明显的峰值而这个间隔其实也就是该 OFDM 信号的基本循环频率也就是它的符号速率。




图 3-4 循环谱估计法

3.3 基于狄利克雷混合模型的无线电信号分类算法

大部分文献中对无线电信号的分类问题都采用的是基于 Gibbs 抽样的马尔科夫链蒙特卡洛采样算法来近似的求解其最大后验概率估计, 但这类算法是通过条件分布中的迭代抽样来获取样本数据, 并以此来近似联合后验概率分布的样本特性的。这些抽样得到的样本数据被证明可以以概率 1 收敛于实际的联合后验概率分布, 可以证明马尔科夫链蒙特卡洛算法的有效性, 但是同样这种抽样算法也存在着在对观测样本信号进行抽样时抽样的样本数目必须达到一定的量才能最终达到收敛和抽样得到的这些样本之间并不能确定一定是相互独立的关系等不可能避免掉的缺点, 而且这些缺点的存在直接导致了这一类的抽样算法不能很好的适用于一些大规模的问题中。

出于对马尔科夫链蒙特卡洛算法这类抽样算法存在的这些问题考虑, 本文选择了使用变分法这种确定性的近似方法来完成对狄利克雷混合模型中联合后验概率分布的估计, 主要过程就是用一个比较简单的概率分布去近似没有办法直接使用的复杂的概率分布, 并以此获得含有分类标签的近似的概率分布, 进一步有效的实现对未知无线电环境中信号的分类。

3.3.1 无线电信号分类系统模型

对未知无线电环境中的信号 $X_{1:N} \triangleq \{X_n\}_{n=1}^N$ 中的每一个信号进行特征提取, 并将记为 n 的无线电信号提取后得到的信号的带宽 $X_{n,1}$ 、信号的载波频率 $X_{n,2}$ 和信号的基本循环频率也就是信号的符号速率 $X_{n,3}$ 这三个特征参数用向量 $X_n = \{X_{n,1}, X_{n,2}, X_{n,3}\}^T$ 来表示。根据上文的分析对于无线电信号的这三个特征中的无线电信号带宽的估计是采用了功率谱密度估计的方法, 无线电信号的载波频率和基本循环频率估计则都是采用了信号的循环谱密度的方法。对采集到的无线电信号通过求该无线电信号的自相关函数并做傅里叶变换得到无线电信号的功率谱密度, 在这一过程中采用了修正的平均周期图法。而无线电信号的载波频率和基本循环频率则是根据数字调制的无线电信号的自相关函数的频谱表现出来的周期性也就是循环平稳特性来完成的估计。

一个复杂且未知的无线电环境中信号的分布必然无法用一个简单的模型来描述, 因此本文假设该复杂电磁环境中的无线电信号 $X_{1:N} \triangleq \{X_n\}_{n=1}^N$ 服从混合的概率分布, 采用狄利克雷混合模型对这个混合的概率分布进行描述。对于每一个无线电信号来说, 它必定服从一个特定的分布并且与它属于同一类的无线电信号也一定都服从于这一个特定的分布。那么在这个基于狄利克雷混合模型的无线电信号分类

的系统模型中可以假设每一个信号以某一个概率属于一类已经知道的信号，同时以另一个概率属于一个新的信号的类别。

假设每一个信号属于的概率分布的参数为 θ ，那信号 n 的概率分布的参数记为 θ_n ， θ_n 唯一确定一个概率分布，也就可以得出这些无线电信号对应的概率分布的参数比如 θ_n 相同时这些无线电信号也就来自于同一个概率分布，即这些无线电信号为同一个类型的信号。比如现在有两个类型的信号分布称为 A 类和 B 类且这两类中的信号分别服从参数为 $p_1 = 0.6$ 和 $p_2 = 0.9$ 的两个伯努利分布，当对某一个无线电信号所服从的概率分布的参数进行估计后得出来的值为 0.9，那么就可以说该无线电信号属于 B 类信号。根据上面对该复杂且未知的无线电环境中的信号采用狄利克雷混合模型来进行描述的假设和本文中第 2.3.3 小节对狄利克雷混合模型的理论分析，可以得出 θ_n 来自某个狄利克雷过程的随机概率测度 G 并且有 $G \sim DP(\alpha_0, G_0)$ 。本文对狄利克雷混合模型进行构造时选用了断棍模型并由此可以得出

$$G = \sum_{K=1}^{\infty} \pi_K \delta_{\theta_K^*} \quad (3-9)$$

其中 θ_K^* 是所有的 θ_n 的取值， π_K 是相应的取值的概率， $\delta_{\theta_K^*}$ 则是指示函数且只有在 $\theta_n = \theta_K^*$ 的时候取值才为 1 而其余的情况其取值均为 0。

根据本文中的第 2.3.1 小节对断棍模型的理论分析和本文中第 2.3.2 小节对狄利克雷混合模型的理论分析，可以得出结合断棍模型和狄利克雷过程构建的狄利克雷混合模型的情况给出本文的无线电信号分类器的系统模型

$$\begin{aligned} \pi | \alpha_0 &\sim GEM(\alpha_0) & \theta_k^* &\sim G_0 \\ Z_n | \pi &\sim Multi(\pi) & X_n | Z_n, \theta_k^* &\sim f_{\theta_{Z_n}^*}(X_n) \end{aligned} \quad (3-10)$$

其中式子(3-10)中的 $\pi | \alpha_0 \sim GEM(\alpha_0)$ 表示

$$\begin{cases} \beta_i \sim Bata(1, \alpha_0) \\ \pi_i = \beta_i \prod_{l=1}^{i-1} (1 - \beta_l) \end{cases} \quad (3-11)$$

在本文的混合概率模型中给每一个无线电信号 X_n 赋予其对应的隐变量 Z_n ，该隐变量对应的就是该无线电信号是哪一个类型的无线电信号。举个例子来说的话，假如从无线电信号可能属于的分布的参数 θ 的先验分布 G_0 中抽取三个分布参数分布记为 $\theta_1^*, \theta_2^*, \theta_3^*$ ，当有某一个记为 X_n 的无线电信号所属于的分布的参数为 θ_1^* 时该无线电信号对应的隐变量 Z_n 的取值也就应该是 1，此时可以得出该无线电信号所

属的分布的参数有 $\theta_{z_n}^* = \theta_1^*$ ，等式充分表明了该无线电信号服从的概率分布即为 $f_{\theta_1^*}(X_n)$ ，同时可以认为对于所有的隐变量取值为 1 的无线电信号 $\{X_n | n: Z_n = 1\}$ 都属于同一个分布，也就是这些无线电信号为同一个类型的信号。根据这一分析可以进一步的把无线电信号的分类问题转化为对无线电信号对应的隐变量 Z_n 的取值问题。而 Z_n 的所有可能取值其实是跟无线电信号的类型数目成正相关的，所以可以说 Z_n 服从的是一个多项式分布可以记为 $Multi(\pi)$ ，并且可以跟本文提到的狄利克雷断棍模型结合起来有 $\pi | \alpha_0 \sim GEM(\alpha_0)$ ，式子中的 α_0 其实是由人工来设定的超参数。由上面的这些分析可以得到的基于狄利克雷混合模型的无线电信号分类的系统模型如图 3-5 所示




图 3-5 信号分类模型

3.3.2 无线电信号分类算法

根据上一节中的无线电信号的分类系统模型图可以写出本文中该无线电信号分类模型中所有的无线电信号和其隐变量的联合分布表达式为

$$p(X, Z, \beta, \theta) = p(X | Z, \theta) p(Z | \beta) p(\beta) p(\theta) \quad (3-12)$$

式子(3-12)中的变量除了 X 是观测到的样本数据这一变量其他的全是隐变量。在本文提出的无线电信号分类模型中对无线电信号进行分类时进一步的将其等效为估计这些无线电信号的分布参数 θ_{z_n} ，也可以说是估计这些无线电信号的后验分布 $p(\theta | X)$ ，再进一步的等效可以变成对隐变量 Z_n 的取值估计问题。根据变分法的理论这里只需要用分布 $q(Z, \beta, \theta)$ 去近似后验分布 $p(Z, \beta, \theta | X)$ 就可以得到关于隐

变量 Z_n 的后验概率密度函数的近似解析解, 并以此进一步的估计出隐变量 Z_n 的取值。

所以根据式子(3-10)和无线电信号的分类模型图可以得出 β 的概率密度函数的表达式为

$$p(\beta) = \prod_{i=1}^{\infty} p(\beta_i) = \prod_{i=1}^{\infty} \frac{\beta_i^{1-1} (1-\beta_i)^{\alpha_0-1}}{\text{Beta}(1, \alpha_0)} = \prod_{i=1}^{\infty} \frac{\Gamma(\alpha_0+1)}{\Gamma(\alpha_0)\Gamma(1)} (1-\beta_i)^{\alpha_0-1} \quad (3-13)$$

根据给定的 β 和 Z 服从多项式分布可以写成隐变量 Z 的条件概率密度函数的表达式为

$$\begin{aligned} p(Z|\beta) &= \prod_{n=1}^N p(Z_n) = \prod_{n=1}^N \prod_{i=1}^{\infty} p(Z_n = i) \\ &= \prod_{n=1}^N \prod_{i=1}^{\infty} \pi_i^{1_{\{Z_n=i\}}} \\ &= \prod_{n=1}^N \prod_{i=1}^{\infty} \left[\beta_i \prod_{l=1}^{i-1} (1-\beta_l) \right]^{1_{\{Z_n=i\}}} \\ &= \prod_{n=1}^N \prod_{i=1}^{\infty} \left[(1-\beta_i)^{1_{\{Z_n=i\}}} \beta_i^{1_{\{Z_n=i\}}} \right] \end{aligned} \quad (3-14)$$

假设无线电信号所属的分布参数 θ 的先验分布 G_0 服从参数为 λ 的指数分布族即有 $p(\theta) \sim \text{exponential}(\lambda)$ 。当似然函数 $p(X|Z, \theta)$ 的先验分布 $p(\theta)$ 为指数分布族时, 根据共轭性可以得知该似然函数也属于指数分布族, 这个时候似然函数 $p(X|Z, \theta)$ 和其先验分布 $p(\theta)$ 在参数上具有一定的关联性, 因此可以根据其中一个分布的参数来却独另一个分布的参数, 可以先假设 θ 的先验分布表达式为

$$p(\theta) = \prod_{i=1}^{\infty} h(\theta_i) \exp\{T^T(\theta_i)\lambda - A(\lambda)\} \quad (3-15)$$

式子(3-15)中的 λ 是先验分布 $p(\theta)$ 的分布参数且在本文这个无线电信号分类模型中是由人工来初始化的。其中底层观测量 $h(\theta_i)$ 、充分统计量 $T(\theta_i)$ 和对数归一化因子 $A(\lambda)$ 这三个参数是在原始分布转化成指数分布时对应生成的。在这里可以将参数 λ 进行分解并转化为 $\lambda = \begin{Bmatrix} \lambda_1 \\ \lambda_2 \end{Bmatrix}$ 的形式, 同时相对于的充分统计量 $T(\theta)$ 也会换成

$T(\theta) = \begin{Bmatrix} \theta \\ -a(\theta) \end{Bmatrix}$ 的形式, 进而可以将先验分布 $p(\theta)$ 写成下面的形式

$$p(\theta) = \prod_{i=1}^{\infty} h(\theta_i) \exp\{\theta_i^T \lambda_1 - a^T(\theta_i) \lambda_2 - A(\lambda)\} \quad (3-16)$$

根据指数分布族的共轭性可以得出信号样本数据 X 的条件分布函数表达式为

$$\begin{aligned}
 p(X|Z, \theta) &= \prod_{n=1}^N p(X_n|Z_n, \theta) \\
 &= \prod_{n=1}^N \prod_{i=1}^{\infty} \left\{ h(X_n) \exp \left\{ T^T(X_n) \theta_i - a(\theta_i) \right\} \right\}^{1_{\{Z_n=i\}}} \\
 &= \prod_{n=1}^N h(X_n) \exp \left\{ T^T(X_n) \theta_{Z_n} - a(\theta_{Z_n}) \right\}
 \end{aligned} \quad (3-17)$$

在狄利克雷混合模型中分布参数 θ 的先验分布和似然函数为式子(3-13)和式子(3-14)表达的指数分布的形式时, 可以得出概率密度函数的表达形式如下

$$\begin{cases} q^*(Z_n = i) = \pi_{n,i}^* \\ q^*(\beta_i) = \frac{\beta_i^{a_i^* - 1} (1 - \beta_i)^{b_i^* - 1}}{\text{Beta}(a_i^*, b_i^*)} \\ q^*(\theta_i) \propto h(\theta_i) \exp \{ T^T(\theta_i) \lambda_i^* \} \end{cases} \quad (3-18)$$

式子中 i 和 n 的取值范围为 $i \in [1, +\infty], n \in [1, N]$ 。

用上面的式子去近似 $p(Z|X)$ 、 $p(\beta|X)$ 和 $p(\theta|X)$ 这三个后验分布, 并且可以得到 $\pi_{n,i}^*$ 、 a_i^* 、 b_i^* 和 λ_i^* 这四个参数的迭代公式

$$\begin{cases} \pi_{n,i}^* \propto \exp \left\{ E_{q(\beta)} [\ln \beta_i] + \sum_{l=1}^{i-1} E_{q(\beta)} [1 - \ln \beta_l] + E_{q(\theta)} [T^T(X_n) \theta_i - a(\theta_i)] \right\} \\ a_i^* = \sum_{n=1}^N \pi_{n,i}^* + 1 \\ b_i^* = \sum_{n=1}^N \sum_{j=i+1}^{\infty} \pi_{n,j}^* + \alpha_0 \\ \lambda_i^* = \begin{bmatrix} \lambda_1 + \sum_{n=1}^N T(X_n) \pi_{n,i}^* \\ \lambda_2 + \sum_{n=1}^N \pi_{n,i}^* \end{bmatrix} \end{cases} \quad (3-19)$$

根据上面的式子可以看出上面这四个参数分别由 α_0 、 λ_1 、 λ_2 、 β 这四个参数求出。其中集中参数 α_0 由人工初始化, 且其为狄利克雷过程 $DP(\alpha_0, G_0)$ 中的 α_0 和断棍模型中贝塔分布 $\text{Beta}(1, \alpha_0)$ 中的 α_0 。先验分布 $p(\theta)$ 的分布参数 λ 也由人工初始化, 根据 λ 分解转化得到的 λ_1 、 λ_2 也由人工初始化得到。而 β 根据贝塔分布 $\text{Beta}(1, \alpha_0)$ 得

到并根据断棍模型进一步得到的 π 的初始值。根据上面的分析可以得出对无线电信号进行分类的算法流程图如下

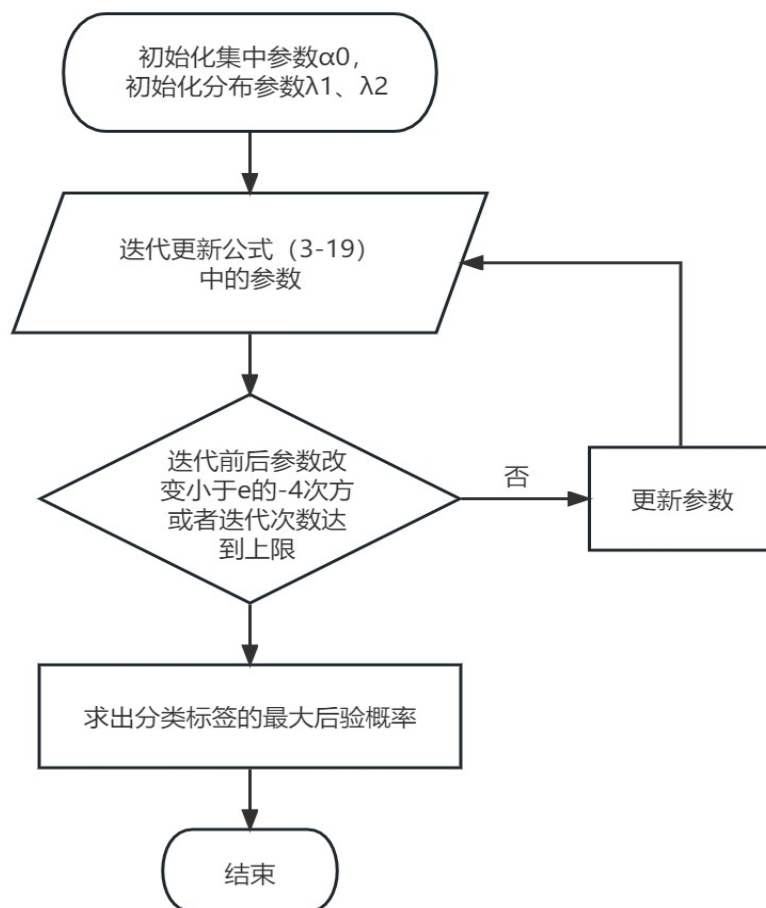


图 3-6 无线电信号分类算法流程图

可以得出对无线电信号进行分类时算法的工作原理如下，先对需要人工初始化的参数人工设定好初始值，根据上文的分析接下来只需要根据公式（3-19）对参数进行迭代更新，达到四个参数迭代前后的欧氏距离之和小于 e^{-4} 或这迭代的次数达到上限这两个算法的收敛条件时算法的迭代停止。这样就可以获得损失信息最小的后验分布近似解析解。

根据上文的分析对无线电信号的分类问题可转化为 $\{Z_n\}_{n=1}^N$ 的取值估计问题，该取值估计问题可以根据最大后验概率求解，计算式可表示为 $\hat{Z} = \arg \max_Z p(Z|X) \cong \arg \max_Z q^*(Z)$ ，其中计算式中的 $q^*(Z)$ 即为后验分布 $p(Z|X)$ 的近似解析解。

3.4 基于狄利克雷混合模型的无线电信号分类仿真

为了验证本文提出的基于狄利克雷混合模型的无线电信号分类器的分类性能, 本文在 Matlab 数学计算软件中仿真实现了本文提出的狄利克雷信号分类器, 验证了本文信号分类器的性能并分析了在信息样本数量不变的情况下分类数目不同和分类数目不变的情况下, 信号的样本数量不同这两种情况下该信号分类器信号正确识别率的变化情况。

3.4.1 无线电信号分类仿真结果

本文选择了三种类别的信号进行仿真试验: 一种常见的手机 WiFi 信号, 另外两种分别是 Bebob 无人机起飞时的无线电信号和 AR Drone 无人机起飞时的无线电信号。其中 WiFi 信号和两种无人机无线电信号均工作在 2.4GHz 附近, WiFi 信号的带宽为 22MHz 而两种无人机无线电信号则具有 80MHz 的带宽, 这三种无线电信号的符号速率均可用循环谱估计求出。由此可以得到这三种无线电信号载频、带宽和符号速率这三个维度的数据库。将该数据库作为狄利克雷混合模型的输入, 当 $\pi_{n,i}^*$ 、 a_i^* 、 b_i^* 和 λ_i^* 这四个参数迭代更新收敛时即可得到无线电信号分类的正确识别率, 下图 3-7 为参数随着迭代次数变化逐渐收敛的过程

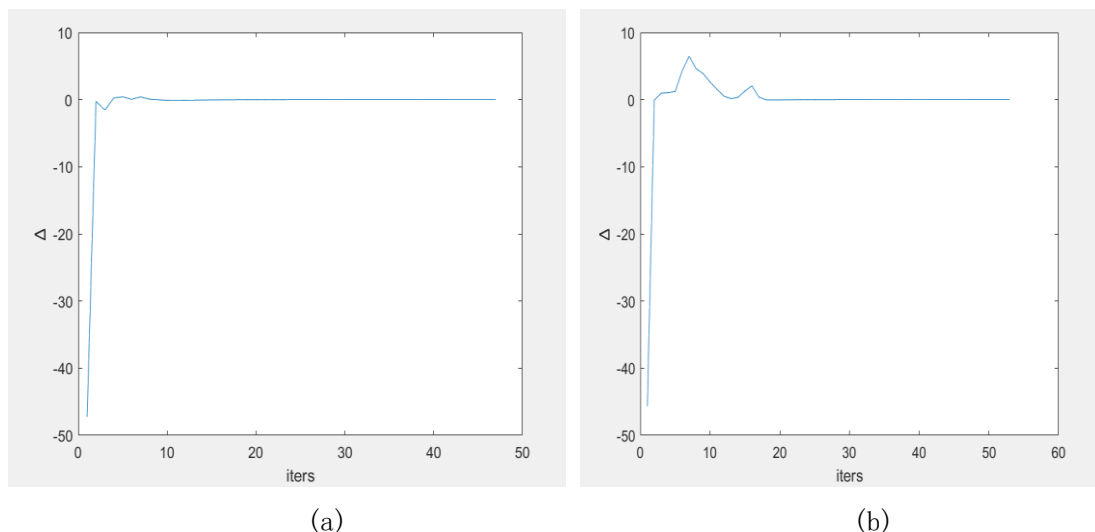


图 3-7 信号类型数目 $I=3$, 每类信号数量不同时参数收敛情况

(a) 每类信号数量 $N=50$; (b) 每类信号数量 $N=10$

根据图 3-7(a)可以看出在信号分类数目 $I=3$, 每类信号样本数量 $N=10$ 即共 30 个信号的情况下该程序达到收敛的速度较快, 在第十次迭代时即达到了收敛。根据图 3-7(b)可以看出在信号分类数目 $I=3$, 每类信号样本数量 $N=50$ 即共 150 个信号

的情况下该程序达到收敛的速度相较信号数量少的情况下要更慢，在第二十二次迭代才达到收敛。

由图 3-8 可以得出在信号类型 $I=3$ ，每类信号数量 $N=10$ 时即信号样本数量总量为 30 个时分类准确率最高，达到了 86.50%。每类信号数量 $N=30$ 时信号的分类准确率为 84.31%和每类信号数量 $N=50$ 时信号的分类准确率为 83.22%。




图 3-8 信号类型 $I=3$ ，每类信号数量 $N=10$ 、30、50 时的分类准确率

3.4.2 分类正确率仿真结果分析

在无线电环境中影响无线电信号分类结果的主要因素有两个，分别是该无线电环境中无线电信号的类型数目和无线电环境中信号的数目。为了判断这两个因素对无线电信号分类正确率的影响，下面根据控制变量法来进行仿真分析。




图 3-9 无线电信号类型数目固定，信号数目变化时分类正确率情况

先固定输入狄利克雷混合模型的无线电信号类型数目固定为 $I=3$ ，然后分布设定三次仿真实验中每一类无线电信号的数目分别为 $N=10$ 、 $N=30$ 和 $N=50$ 。由此可以绘制出在无线电信号类型数目固定而无线电信号数目不同的情况下无线电信号分类模型的分正确率随着迭代次数不断增加的变化情况。

由图 3-9 可以看出随着无线电信号数目的增多在算法收敛后实际无线电信号分类正确率相差幅度并不大，尤其是考虑到信号数目增加的幅度比分类模型的分正确率的增加幅度大得多，可以说该无线电信号分类模型的性能几乎不受无线电信号数目多少的影响。出现这样的结果的原因是虽然无线电信号数目增多带来了更多的有效信息，但这些有效信息的作用仅仅是为分类模型提供了更加充足的数据，对于信号的分类来说并不具有太多的价值。

每一类无线电信号的数目固定为 $N=50$ ，设置三次仿真实验中无线电信号分类模型输入的无线电信号类型分别为 $I=3$ 、 $I=5$ 和 $I=7$ 。这里固定的是每一类无线电信号数目，所以无线电信号类型增多时输入该无线电信号分类器的无线电信号数目总量也是会增多的。但是根据上面分析的无线电信号数目增多对无线电信号分类模型的性能几乎没有影响可以将这三次仿真实验的前置条件近似看成无线电信号数目固定，也满足了控制变量法。由此可以绘制出在无线电信号每一类信号数目固定而无线电信号类型数目变化的情况下无线电信号分类模型的分正确率随着迭代次数不断增加的变化情况。




图 3-10 每一类无线电信号数目固定，信号类型数目变化时分类正确率情况

由图 3-10 可以看出随着无线电信号类型数目的增多在算法收敛后实际无线电信号分类正确率也随之下降，出现这种情况的原因时随着无线电信号类型数目的

增多无线电信号分类模型需要区分更多类型的信号，但这些信号都在 2.4GHz 频段附近，这些信号之间的差别也越来越小，区分这些信号也就变得越来越难，相应的该无线电信号分类模型的分类正确率也随着这些变化下降。

3.5 本章小结

本章主要完成了陌生无线电环境中无线电信号的分类问题。本章在进行对无线电信号的分类前先完成了对无线电信号的切分、异常数据剔除和滤波等预处理，又用修正的平均周期法完成了对无线电信号带宽的提取和根据信号的循环平稳性用循环谱估计的方法完成了无线电信号载波频率和循环频率的提取。最后用基于狄利克雷混合模型的无线电信号分类算法对无线电信号的三个特征参数组成的数据库进行无线电信号分类并用控制变量法分析了无线电信号分类准确率与信号类型数目和信号样本数量之间的关系。

第四章 基于改进的卷积神经网络的无人机信号分类识别研究

对无人机进行检测时,需要先对原始的无人机无线电信号进行预处理,这样可以提高样本数据的质量并在一定程度上可以提高无人机检测程序的识别率。利用无线电信号对无人机进行检测时,传统的机器学习算法仅利用机器学习算法根据人工提取出的信号特征进行分类,因此人工选择出来的信号特征对最终检测结果的影响极大。近年来随着计算机技术和深度神经网络技术的发展,深度学习在无线电信号的分类识别领域也开启了无线电信号识别从人工选择信号特征的经验驱动到数据驱动的转变。

本文在对无人机信号进行检测识别时选择了一种改进的卷积神经网络算法同时结合图像处理的思路,先将无人机信号样本数据转化为信号瀑布图和双谱分析图将无线电信号识别的问题转为图像识别领域的问题,再将得到的图片输入结合自校准卷积和注意力机制的残差神经网络模型,经过训练最终得到无人机信号识别程序。

4.1 无人机通信系统

4.1.1 无人机无线电信号

无人机的通信系统主要包括遥测遥控系统和导航系统,其中遥测遥控系统主要用于接收来自地面端的控制信号和向地面端发送数字或图像信息,而导航系统则是用于获取无人机自身所在的位置信息和地面控制站所在的位置信息。无人机的导航系统只接收信号,所以在本文中并不对无人机导航系统这一通信链路进行研究。

不同的无人机厂家生产的无人机使用的通信制式可能不同,其中比较常见的有移频键控(FSK)、正交频分复用调制(OFDM)和 WiFi 协议等等。其中正交频分复用的主要思想是先按照不同的频率将信道划分为多个正交的子通道,再在信号传输时将高速数据流转换为并行的低速字子数据流并将各个子数据流调制到不同的子信道以此实现频率的多路复用。WiFi 协议在无人机及其他的移动无线电通信设备中经常用到,并随着这些通信设备对通信速率和传输距离等方面的要求不断提高而发展出了 WiFi 802.11a/b/g/n/ac 等版本的协议。这些协议的工作频段主要在 2.4GHz 和 5GHz,使用的传输技术主要有 DSSS 和 OFDM 调制解调系统。本文

对无人机无线电信号进行分析时的对象的通信制式就是 WiFi 协议且本文中用到的信号频段均在 2.4GHz。

4.1.2 无人机信号指纹特征

对于无线电信号来说产生信号细微特征的原因主要在于模拟信号处理单元，因此对发射机个体信号特征进行分析时关注的点主要集中在频率源、调制器和射频放大器上。通信发射机的载波频率的频率源有晶体震荡管、锁相式频率源和直接数字频率合成器。但在通信系统中合成载频产生时最初的参考频率总要用到晶体震荡管，又因为不同的通信设备中用到的晶体震荡管不同，所以不同通信设备的载波频率因晶振频率而存在的偏差也不相同，且因晶体震荡管出现的载频偏差具有各自的变化规律，所有这一点可以作为识别个体的指纹特征。除此之外，对于不同的通信设备发射机，它们的电路结构和排布、选用的器件等也会存在一定的差异，还有模拟器件如射频功率放大器等的非线性特性带来的失真，这些情况都不可避免的对最终发射处理的信号在时域和频域上产生一定的影响，而这些影响也就构成了不同通信设备发射机个体的指纹特征。

对于无人机来说，除了上面提到的情况还存在一些无人机特有的情况，可以通过无人机的动力学模型和模态特性等方面的力学分析来了解。无人机的机械震动必定会对机载的发射机产生影响，进一步表现为无人机个体的指纹特征。无人机指纹特征的主要来源是发射机中频率源存在稳定度的不同和射频功率放大器这类模拟器件的非线性特性。其中频率源的稳定度差异在长期上因发射机本身电路等的影响表现为发射信号载波频率的偏移，在短期上则表现为发射信号中的相位噪声且短期稳定度主要是受到电源电压变化和无人机机械震动等外部因素的影响。因此经过分析可以得出，对于无人机来说其个体指纹特征主要表现在发射信号的载波频率偏移、相位噪声和非线性特性这三个方面。

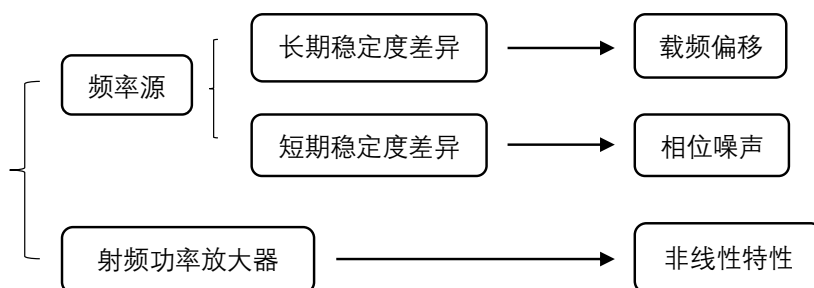


图 4-1 无人机指纹特征

4.2 无人机信号时频分析与仿真

对无人机的无线电信号进行分析时时域和频域上都需要涉及到,信号的傅里叶变换是在整个的时域范围内对该无线电信号进行积分操作得到结果的,这种情况下对时变的无线电信号进行傅里叶变换毫无疑问的对该信号局部情况的分析能力很差,并且无法准确地反映出该无线电信号的时变性。由此可以推断出对于时变的无线电信号来说傅里叶变换并不适用,而能够同时的反映出信号时域特性和频域特性的时频分析方法在处理这一类时变的无线电信号时却是非常有效的。

4.2.1 基于短时傅里叶变换的时频分析

短时傅里叶变换(STFT)可以同时的反映出无线电信号的时域特性和频域特性,并且将信号的时域和频域联合到一起对信号进行分析时可以得到无线电信号的频率随着时间的改变发生的变化情况。在传统的傅里叶变换中对于信号进行分析时其时域特性和频域特性其实是分割开的,以至于对于一个时变的无线电信号来说采用传统的傅里叶变换根本不能得到随着时间的变化该无线电信号的频谱的改变情况,但是这一点却是对时变的无线电信号进行分析时不能忽略的重点,所有对于时变的无线电信号来说选择短时傅里叶变化这一类可以反映出信号的频谱随着时间的变化而发生改变的情况的联合时频分析方法才是更合适的。

短时傅里叶变换的基本方法就是先对要进行分析处理的信号进行加窗操作,通过窗函数随着时间的变化在该信号时间轴上进行平移的操作可以把该时变的信号分割成一小段一小段的信号,这些小段的信号因为整个分割时间间隔比较小,就可以把它们看出是在这一小段时间内基本不发生改变平稳信号,最后对加窗后得到这些小段的信号分别进行傅里叶变换,得到每一小段信号在对应的时间窗内的频谱图,再将这些时间窗联合起来就可以得到时变的无线电信号随着时间或者时间窗的变化信号的频谱的变化情况。

联合了信号的时域特性和频域特性的短时傅里叶变换的性能分析集中在对信号的时间分辨率和频率分辨率这两个方面的分析上,而根据上面对短时傅里叶变换基本方法的描述可以很明显的得出这两点都与选择的窗函数类型和窗函数的窗长有着紧密的联系。不同的窗函数对信号进行处理时侧重的情况不同最后出来的结果自然也有不同,根据哪一种结果更符合对信号处理的要求就可以选定在不同的情况下应该选择使用哪一种窗函数。而选定了窗函数之后不同的窗长也会产生的不同的效果,当选择的窗函数的窗长比较长的时候用该窗函数处理无线电信号后得到信号长度也越长,这种情况会导致在最终得到的结果图里对信号的频率分辨率更高而对时间分辨率来说却变低,相应的选择比较短的窗长的时候信号的时

间分辨率自然会变得更高而频率的分辨率会变得更低，所以最终可以根据对无线电信号进行分析时更注重该信号在频率上的信息还是更注重该信号在时间上的信息来选定窗函数的窗长。

根据上面对短时傅里叶变换的分析可以得出，短时傅里叶变换的实际过程其实就是选定一个窗函数与要处理的信号相乘，并将得到的结果进行傅里叶变换，因此有短时傅里叶变换的表达式如下

$$STFT_x(t, \omega) = \int_{-\infty}^{\infty} x(\tau) g^*(\tau - t) e^{-j\omega\tau} d\tau \quad (4-1)$$

式子中的 $g(t)$ 为窗函数且与 $g^*(t)$ 互为共轭。当窗函数 $g(t)=1$ 时加窗后短时傅里叶变换与傅里叶变换的信号处理过程没有变化，也就是说此时就相当于直接做傅里叶变换。

4.2.2 无人机信号瀑布图仿真

根据上一节的分析可以得知短时傅里叶变换其实就是采用一个在时间上宽度很小的实值函数作为窗函数，实现从时变的无线电信号的截取时间间隔特别短的小段信号，这些时间间隔足够短以至于可以将这些从时变的信号的截取的小段信号看作是平滑不变的信号，在将这些截取到的小段信号依次进行傅里叶变换，将变换后的频谱按照窗函数在时间轴上的滑动顺序连接起来，就可以得到联合了信号时域特性和频域特性的时频瀑布图了。所以可以画出短时傅里叶变换的原理图如图 4-2:

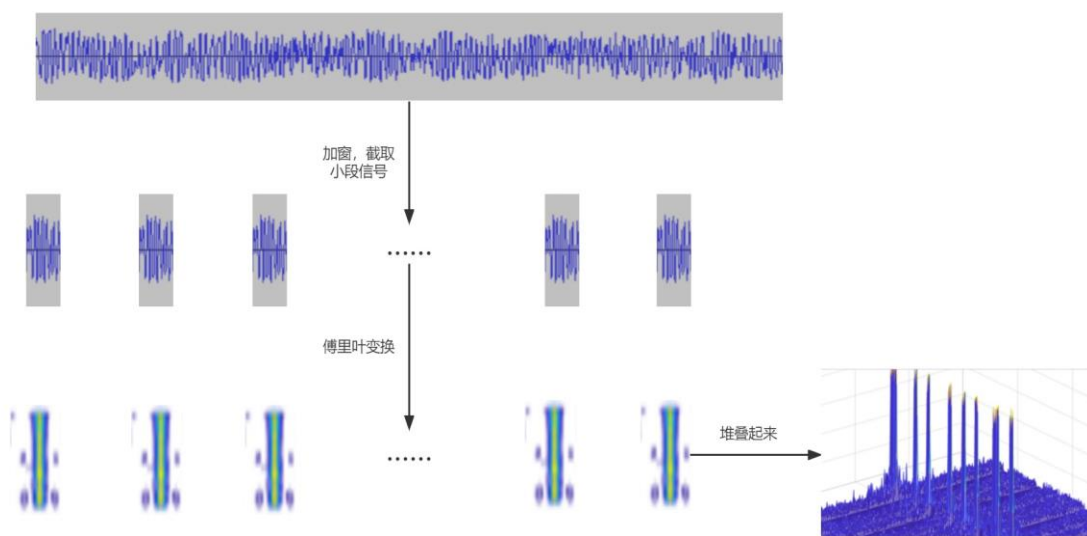


图 4-2 短时傅里叶变换原理图

根据上面的分析可以得知短时傅里叶变换的窗函数在时频上的分辨能力是受到制约的,对于给定信号的时间分辨率和频率分辨率之间成反比,因此在实际的应用场景下时间分辨率和频率分辨率无论提高哪一个的分辨率都必然伴随着另一个分辨率的下降,所以只能根据实际的应用情况选择其中一个。

下面对无无人机时的背景信号和 **Bebop** 无人机悬停时的信号进行分析并绘出相应的信号瀑布图如图 4-3 和图 4-4。




图 4-3 背景信号短时傅里叶变换时频图

(a) 背景信号二维时频图

(b) 背景信号三维时频图




图 4-4 Bebop 无人机悬停时信号短时傅里叶变换时频图

(a) Bebop 无人机悬停时信号二维时频图

(b) Bebop 无人机悬停时信号三维时频图

根据图 4-3 和图 4-4 可以看出无无人机时背景信号时频分析图跟 **Bebop** 无人机悬停时信号的时频分析图存在明显差异,因此可以用于无人机识别。

4.3 无人机信号双谱特征分析与仿真

根据上面的分析得知无人机的指纹特征主要可以分为频率偏移、相位噪声和非线性特性这三种，但是在实际的应用中这三种指纹特征很难单独获取。无人机指纹特征的来源信息跟发射信号一起发送出来，并在发射信号中主要表现为对信号的随机调幅和调相。信号的高阶谱可以更好地描述信号的幅度和相位信息，所以本文选择采用高阶谱分析的方法来实现对无人机个体指纹特征的描述。

在实际的应用中，低阶的信号分析方法很难详细的描述出无人机无线电信号的特性。所以为了更好的从无人机无线电信号中提取出与信号发射源个体识别相关的信息就需要对无人机无线电信号进行高阶谱分析。在信号处理领域基于信号的二阶统计量提取信号特征是比较常用的方法，但这种方法在实际的应用中并不能适用于非高斯分布的信号。而高阶谱分析不仅能提取信号中包含的非高斯特性，还能很好的解决使用低阶统计量对信号进行分析处理时肯存在的相位信息失真和幅度信息失真的问题。

4.3.1 高阶谱理论与信号双谱分析

根据前人的研究可以得知在现代数字信号处理领域基于高阶谱分析提取出来的信号特征明显比基于短时傅里叶变换和小波变换等低阶特征提取方法提取出来的信号特征效果更好，不仅能尽可能多的保留信号中的有用信息还能在一定程度上降低噪声对信号的影响。

高阶谱中的三阶谱也就是双谱在高阶谱中阶数最低，相应的处理方法最简单，应用也最广泛。对于一个平稳随机过程来说其 k 阶谱是该平稳随机过程 $k-1$ 维 k 阶累积量的傅里叶变换。信号的三阶矩和三阶累积量相同，所以可以把三阶谱定义为三阶自相关函数的二重傅里叶变换。假设随机变量 X 特征函数表达式如下

$$\varphi(\omega) = \int_{-\infty}^{\infty} P(x) e^{j\omega x} dx = E[e^{j\omega x}] \quad (4-2)$$

其中 $P(x)$ 是随机变量 X 的概率密度函数。对上面的式子取对数可以得到随机变量 X 的第二特征函数的表达式

$$\psi(\omega) = \ln(\varphi(\omega)) = \ln[E(e^{j\omega x})] \quad (4-3)$$

将上面的两个式子推广到 k 维的变量，则可以得到相应的特征函数和第二特征函数的表达式分布为

$$\varphi(\omega) = E(e^{j\omega^T x}) = E(e^{j(\omega_1 x_1 + \dots + \omega_k x_k)}) \quad (4-4)$$

$$\psi(\omega) = \ln \left[E \left(e^{j\omega^T x} \right) \right] = \ln \left[E \left(e^{j(\omega_1 x_1 + \dots + \omega_k x_k)} \right) \right] \quad (4-5)$$

K 维随机变量 X 的 k 阶累积量是其第二特征函数在零点处的 k 阶导数，所以可以得到 k 维随机变量 X 的 k 阶累积量的计算式为

$$c_k = (-j)^k \psi^{(k)}(0, \dots, 0) = (-j)^k \frac{\partial^k \psi(\omega_1, \dots, \omega_k)}{\partial \omega_1 \dots \partial \omega_k} \Big|_{\omega_1 = \dots = \omega_k = 0} \quad (4-6)$$

假设随机变量 X 的 k 阶累积量满足下面的式子

$$\sum_{\tau_r = -\infty}^{\infty} \dots \sum_{\tau_{r-1} = -\infty}^{\infty} |c_{kx}(\tau_1, \dots, \tau_{k-1})| < \infty \quad (4-7)$$

则可以得到随机变量 X 的 K 阶谱的定义式为

$$S_{kx}(\omega_1, \dots, \omega_{k-1}) = \sum_{\tau = -\infty}^{\infty} \dots \sum_{\tau_{i-1} = -\infty}^{\infty} c_{kx}(\tau_1, \dots, \tau_{k-1}) e^{-j \sum_{i=0}^{k-1} \omega_i \tau_i} \quad (4-8)$$

所以根据上面的式子可以得到信号的三阶谱也就是双谱的表达式为

$$B(\omega_1, \omega_2) = \sum_{\tau_1 = -\infty}^{\infty} \sum_{\tau_2 = -\infty}^{\infty} c_3(\tau_1, \tau_2) e^{-j(\omega_1 \tau_1 + \omega_2 \tau_2)} \quad (4-9)$$

4.3.2 无人机信号双谱图仿真

对采集到的无无人机时的背景信号和无人机信号中的 Bebob 无人机悬停时的无线电信号进行双谱分析，可以得到相应的图像如下

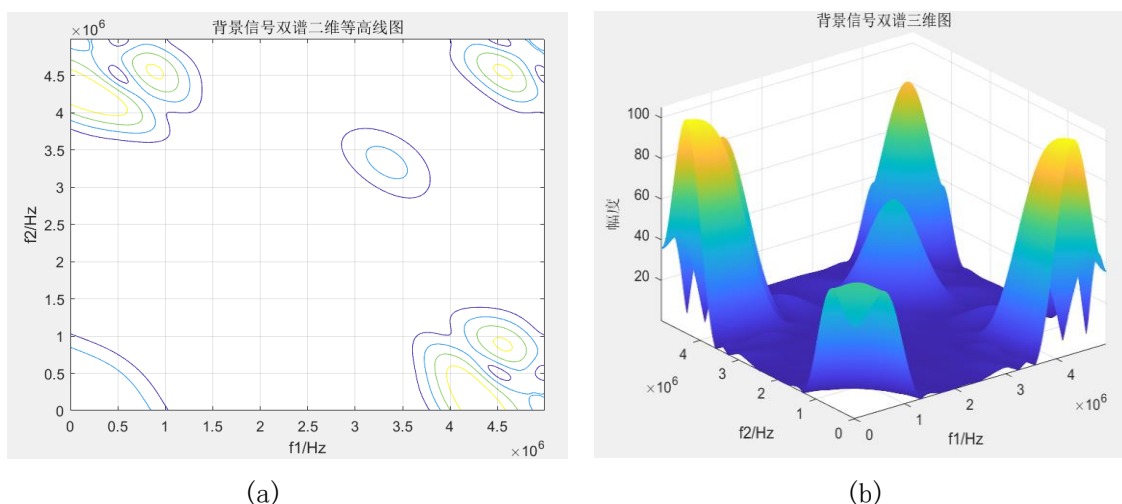


图 4-5 无无人机背景信号双谱分析图

(a) 背景信号双谱分析二维等高线图 (b) 背景信号双谱分析三维图

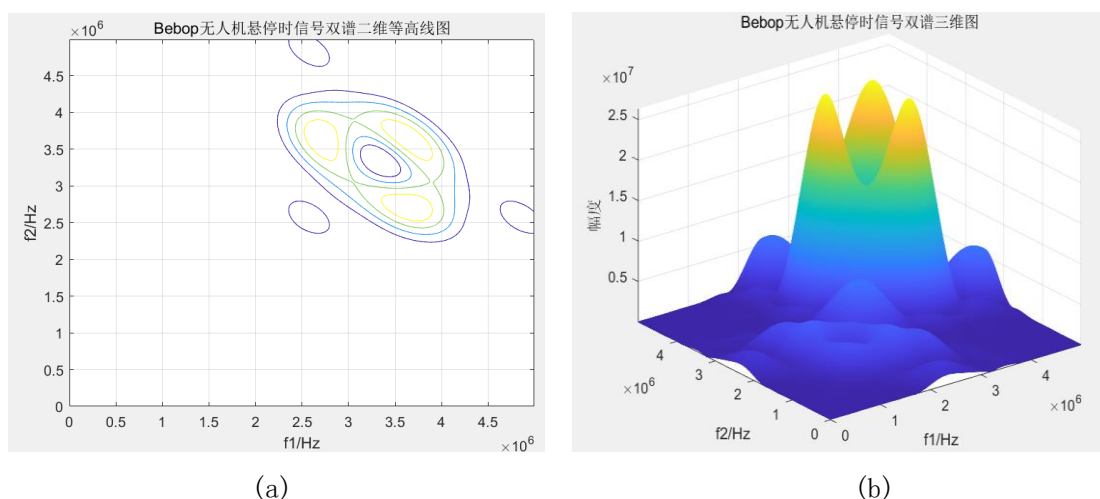


图 4-6 Bebop 无人机悬停时信号双谱分析图

(a) Bebop 悬停时信号双谱分析二维等高线图 (b) Bebop 悬停时信号双谱分析三维图

从图 4-5 和图 4-6 的对比可以看出无无人机时的背景信号与 Bebop 无人机飞行时信号的双谱分析图很明显不同，用信号双谱分析的二维等高线图作为对无人机信号进行识别的图像特征是可行的。

4.4 经典卷积神经网络介绍

深度学习是当前人工智能领域的关键技术且卷积神经网络是深度学习算法中发展迅速的一个研究方向。尤其是在图像处理和向量数据处理领域，卷积神经网络可以通过高效地训练具有深层结构的神经网络并因此在应用中有着比较突出的数据处理能力[42]。深度学习方法首先通过对大量数据的迭代实验以使得网络模型能够最大程度的逼近理论上最高的识别精度，并根据验证集或者预测集提供的新的数据特征对其进行预测[43]。深度学习不仅可以通过增加网络模型的层数来增强该深度神经网络模型的函数表达能力，还能通过该神经网络中的参数和权重的调整来进一步加强它，这是其他机器学习算法所不具备的优点。而且深度学习还可以通过改变中间层数目的多少改变模型的参数数目并通过特征的分布式使深度神经网络模型的表达能力比其他浅层的模型更强[44]。本文主要采用的是深度神经网络模型中的卷积神经网络模型，所以接下来主要对卷积神经网络模型相关的内容进行介绍。

4.4.1 卷积神经网络基本原理

卷积神经网络的结构可以看作一种特殊的多层感知机或者一种前馈神经网络，它主要是由输入层、多个包含卷积层和池化层的隐藏层、全连接层和输出层构成。。

卷积层则是对输入该神经网络模型的数据进行特征提取，它是由多个卷积核组成的并且每一个卷积核都可以实现对输入数据的扫描式计算。池化层则是对进行卷积处理后的信号进行区域划分，并通过最大池化或者平均池化对每一个区域内的特征值进行降低特征稀疏度的操作。局部连接和权重共享是卷积神经网络模型的主要特点。其中局部连接其实就是神经网络模型可以根据图像等数据本身的统计特性将其划分成多个小区域，并利用相同的小卷积核对这些划分后的区域进行处理，这样可以更加有效地提取图像等数据的局部信息同时还能很好的减少相邻层之间的连接。另一个特点也就是权值共享则可以大大的减少训练参数的数量，在这种情况下可以实现一个卷积核的运算结果就可以相当于神经网络模型学习到了一个图像的特征，这不仅可以降低神经网络模型的学习难度还可以实现并行训练^[45]。而且神经网络模型中网络的权重大部分都是需要一些特点的学习过程来完成优化的并且不同的层之间计算方式也是有可能存在不同的^[46]。根据上面的这些分析可以化成卷积神经网络模型的一般结构图如下图 4-7 所示




图 4-7 卷积神经网络结构图

图 4-7 中该卷积神经网络模型的第一层是输入层其实就是数据输入层，它主要是对神经元接收到的大量的非线性信息，也就是输入的原始图像数据或者向量数据做预处理。

图 4-7 中该神经网络模型的第一个隐含层是卷积层 H_1 ，在这一层主要是通过卷积核来进行卷积操作以映射出下一层的输入图像数据。其中卷积核的权重核偏置是待学习的参数且卷积层是由所有的卷积面组成的，这里选择用 $W^{1,\alpha}$ 来表示该卷积层 H_1 的第 α 个卷积核和用 $h_{1,\alpha}$ 来表示该卷积层 H_1 的第 α 个卷积面，则可以得到该卷积层 H_1 第 α 个卷积面 $h_{1,\alpha}$ 的计算式如下

$$h_{1,\alpha} = f(u_{1,\alpha}) = f(C^{1,\alpha} + b^{1,\alpha}) = f(x \otimes W^{1,\alpha} + b^{1,\alpha}) \quad (4-10)$$

在实际的应用中卷积层后面往往会连接着激励层其实也就是激活层，激活层会使用如线性整流函数（The Rectified Linear Unit, ReLU）等激活函数对每一次卷积操作后的结构进行处理。

图 4-7 中该神经网络模型的下一个隐藏层是池化层 H_2 ，池化层可以通过下采样操作来减少数据特征的维度以提高神经网络结构的容错性，并减轻肯出现的过拟合现象，同时还可以有效地控制整个神经网络模型中出现的参数的数量。类似对上一层的分析该池化层 H_2 也是由该层所有的下采样面组成的并且可以将该池化层 H_2 的第 α 个下采样面记为 $h_{2,\alpha}$ ，可以得出其与 $h_{1,\alpha}$ 的关系的表达式如下

$$h_{2,\alpha} = g\left(\beta_2 \text{down}_{\lambda_2, \tau_2}(h_{1,\alpha}) + \gamma_2\right) \quad (4-11)$$

式子(4-11)中函数 $g(\cdot)$ 表示的是恒等的线性函数而 β_2 和 γ_2 分别表示的是该池化层的权重和偏置。

图 4-7 中该神经网络模型的第三个隐藏层是卷积层 H_3 。从上一层的池化层的 $h_{2,\alpha}$ 中选择 r 给下采样面并且将其分别记为 h_{2,α_i} 且有 $1 \in [1, r]$ ，那么在第三个隐藏层对应的卷积核可以用 $W_{\alpha_i}^{3,(\alpha_1, \alpha_2, \dots, \alpha_r)}$ 来表示，并且可以得出在该卷积层中任意一个卷积面的表达式如下

$$h_{3,\omega} = h_{3,(\alpha_1, \alpha_2, \dots, \alpha_r)} = f\left(\sum_{i=1}^r h_{2,\alpha_i} \otimes W_{\alpha_i}^{3,(\alpha_1, \alpha_2, \dots, \alpha_r)} + b^{3,(\alpha_1, \alpha_2, \dots, \alpha_r)}\right) \quad (4-12)$$

图 4-7 中该神经网络模型的第四个隐藏层是记为 H_4 的池化层，它主要是对上一层卷积层 H_3 的计算进行下采样以达到在数据压缩和降低噪声的同时扩大神经网络中神经元在空间上的感受野，更有利于后续在更大的尺度上的特征学习。卷积层 H_3 中的每一个卷积面 $h_{3,\omega}$ 都与该池化层 H_4 的一个池化面 $h_{4,\omega}$ 相对应，并由此可以得出该池化层中任意一个池化面 $h_{4,\omega}$ 的表达式为

$$h_{4,\omega} = h_{4,(\alpha_1, \alpha_2, \dots, \alpha_r)} = g\left(\beta_4 \text{down}_{\lambda_4, \tau_4}(h_{3,(\alpha_1, \alpha_2, \dots, \alpha_r)}) + \gamma_4\right) \quad (4-13)$$

跟上一个池化层 H_2 类似，式子(3-26)中的 β_4 和 γ_4 分别表示该池化层的权重和偏置。

图 4-7 中该神经网络模型的第四个隐藏层后面的 H_5 至 H_n 表示的是该卷积神经网络的全连接层。全连接层主要是通过空间映射到从前面的卷积层和池化层中提取到的特征空间变化为样本标记空间并以此来达到对输入数据的分类作用。最后一个全连接层也可以称为是输出层。全连接层的后面还有可能会有一个 SoftMax 层且其输出值在 0 到 1 之间，将其看作概率分布就可以得到分类结果的概率值。

卷积神经网络的不断发展其模型也出现了不少的变种，有通过用重叠池化进行下采样来改变池化层的 AlexNet 网络模型^[47]，有使用更小的卷积核并构建更深层网络的 VGG 网络模型^[48]，还有通过增加残差单元来提高深度卷积神经网络性能的 ResNet 网络模型等等，下面主要对本文会用到的残差神经网络结构、自校准卷积和注意力机制进行详细的介绍。

4.4.2 残差神经网络

在深度学习算法中一般情况下模型的性能都会随着神经网络深度的增加而提升，但是当神经网络模型的深度达到一定程度后训练过程中的损失函数却不会再继续下降，甚至有的时候还会出现随着神经网络深度的增加其模型的性能反而降低的情况，这种情况被称为深度神经网络模型的退化。也就是说随着神经网络的不断加深对神经网络的优化也就变得越来越困难，而残差神经网络就是为了解决这种退化问题设计出来的^[49]。残差神经网络模型主要是在普通的神经网络模型中通过引入残差单元也称为残差块的结构，将低层的特征引入到高层网络结构中以此来减轻深度神经网络中存在的退化问题。其中残差单元的结构图如图 4-8 所示。




图 4-8 残差单元

将残差单元接入深度神经网络模型后模型会首先对输入的数据进行备份之后再学习并且在最终输出的是备份的原数据与学习之后输出的结果相加得到的值，这样以来引入残差单元之后就可以保证该深度神经网络模型总能够得到之前完整的数据信息并能够保证该深度神经网络即使是在网络中没能学习到有效的信息的时候单靠对输入的原始数据的恒等映射也能保证性能相比于前一层的网络不会下降。不过在实际的应用中残差通常是不会为 0 的也就是总能保证每一层的网络可以学习到新的知识并实现更好的性能。

从数学的角度来分析残差结果在深度神经网络模型中的优势，可以得到残差单元的表达式如下

$$\begin{aligned} y_l &= h(x_l) + F(x_l, W_l) \\ x_{l+1} &= f(y_l) \end{aligned} \quad (4-14)$$

在式子(4-14)中 x_l 表示的是第 l 个残差单元的输入而 x_{l+1} 表示的则是该残差单元的输出，不过这里需要注意的是每一个残差单元中其实不是只有一层结构而是一般都有多层。除此之外还有表示对残差单元的输入数据做恒等映射的函数 $h(x_l) = x_l$ 、残差函数 F 则表示了学习到的残差块其情况和表示 ReLU 激活函数的 f 。根据上面的内容可以得出从记为 l 的浅层到记为 L 的深层的特征学习的表达式如下

$$x_L = x_l + \sum_{i=1}^{L-1} F(x_i, W_i) \quad (4-15)$$

根据链式传播的规则可以推导出相应的反向传播过程梯度的表达式为

$$\frac{\partial loss}{\partial x_l} = \frac{\partial loss}{\partial x_L} \cdot \frac{\partial x_L}{\partial x_l} = \frac{\partial loss}{\partial x_L} \cdot \left(1 + \frac{\partial}{\partial x_l} \sum_{i=1}^{L-1} F(x_i, W_i) \right) \quad (4-16)$$

式子(4-16)中的表示损失函数到达第 L 层的梯度而常数 1 表示在该残差单元里输入数据可以通过恒等映射无损的完成对梯度的传播，而另外一边输入数据则需要通过卷积层和池化层完成该模块对输入数据的学习同时获得另一个基本不太可能会为 -1 的梯度，这样两者相加不会出现梯度消失导致深度神经网络模型性能变差的情况。

4.4.3 注意力机制

因为注意力机制在实现的时候没有具体的和规范性的要求，所有在使用的时候可以根据实际的需要和具体的应用场景等情况对使用的主干网络进行适当的调整就可以了。注意力机制可以让神经网络模型在训练的过程中更多的关注“感兴趣”的区域实现对这些区域的特征更深层次的提取并淡化或者忽略“不感兴趣”的区域，其中比较常见的一种注意力机制就是压缩和激励网络(Squeeze-and-Excitation, SE)模块。压缩和激励网络模块主要通过全连接层和相乘特征融合这两个地方实现注意力机制，假设有一个 $H \times W \times C$ 的输入图像在通过全局池化层和全连接层后可以将其拉伸成 $1 \times 1 \times C$ ，这样再与原来的图像相乘并给每一个通道赋予权重。比如在一个去噪的任务中可以给每一个噪声的赋予一定的权重，在 SE 模块进行处理后会

取出低权重的噪声点而保留高权重的噪声点以此来减少参数运算并提升该神经网络模型的性能。下面的图 4-9 给出了压缩和激励网络模块的结构图：




图 4-9 压缩和激励网络（SE）模块

如图 4-9 所示对输入的维度为 $H \times W \times C$ 的特征图数据进行压缩操作也就是函数 $F_{sq}(\cdot)$ 所表示的步骤，这一步骤需要对输入的数据进行一个全局平均池化操作将维度为 $H \times W \times C$ 的特征图压缩到 $1 \times 1 \times C$ 的维度并且可以将这一过程用数学表达式表达出来

$$s_i = F_{sq}(u_i) = \frac{1}{H \times W} \sum_{p=1}^H \sum_{q=1}^W u_i(p, q) \quad (4-17)$$

其中式子中的 u_i 表示的是原始输入数据每个通道的特征图。

接着如图 4-9 所示对压缩操作得到的结果进行激发操作并将这一过程在图中用函数 $F_{ex}(\cdot, w)$ 来表示，该过程可以有效的实现减少通道数量以降低计算量的目标，这一过程包含了多个操作并以此分别为输入上一层压缩操作得到的结果并将其送入记为 f_{c1} 的全连接层，接下来是记为 σ_1 的激活函数并在这之后再一次送入记为 f_{c1} 的全连接层，最后再进行一次激活函数并记为 σ_2 就可以得到输出的特征，整个过程中进行每一步的早在后特征图的维度都会发生变换并且变化的过程为 $1 \times 1 \times C_2 \rightarrow 1 \times 1 \times C_2 \times w \rightarrow 1 \times 1 \times C_2 \times w \rightarrow 1 \times 1 \times C_2 \rightarrow 1 \times 1 \times C_2 \rightarrow$ 输出，整个过程可以用下面的数学式来表达

$$e_i = F_{ex}(s, w) = \sigma_2 \left(f_{c2} \left(\sigma_1 \left(f_{c1} (s_i, w) \right) \right) \right) \quad (4-18)$$

图 4-9 中的最后一个步骤也就是用函数 $F_{scale}(\cdot)$ 表示的更新权重了，在这一步骤里用激励操作中学到的权重与原始的特征向量相乘并根据这个几个对原始特征图

中每一部分的权重进行更新并输出特征权重更新后的结果，这一过程的表达式是如下

$$\tilde{x} = F_{scale}(u_i, e_i) \quad (4-19)$$

在 SE 模块的激励操作中使用了两次全连接层主要是为了加深该网络模型的线性程度以便于处于各通道之间的相关性和减少该网络模型的参数量以提高该神经网络模型的运算速度和收敛速度。

4.4.4 自校准卷积

自校准卷积神经网络模型是在一般的深度卷积神经网络模型中引入一种利用多个卷积注意力组合起来并能够以此实现自校准操作的模块来替换原来基本的卷积结构。跟标准的卷积结构相比自校准卷积模块不仅能产生更有区分度的特征还能在不增加额外的参数和计算量的情况下产生全局的感受野，这样以来引入自校准卷积的深度卷积神经网络模型跟之前的模型的性能相比必然能得到相应的提升。下面图 4-10 给出了自校准卷积模块的结构图并根据该结构图分析了自校准卷积模块的工作流程

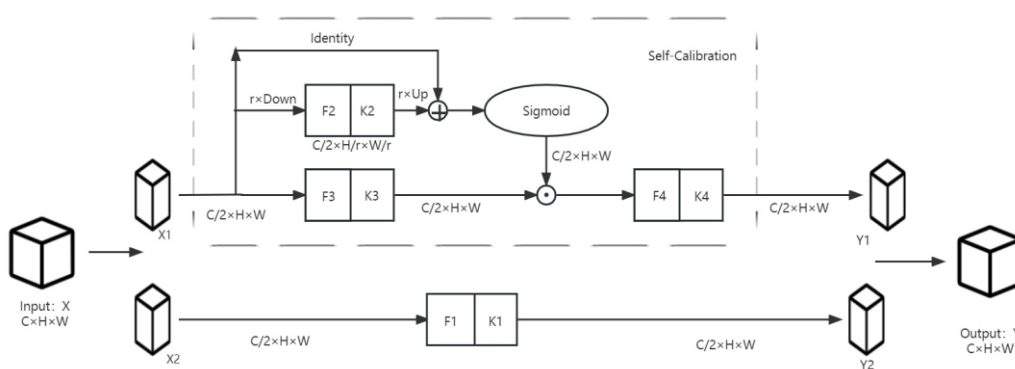


图 4-10 自校准卷积模块

如图 4-10 所示自校准卷积模块的操作可以划分为两个部分，图中用虚线框起来的部分就是第一个部分，它其实是自校准卷积模块中最重要的部分也就是自校准操作的部分，而第二部分就是虚线框下面传统的卷积操作部分。下面大致写成自校准卷积模块的操作流程

首先要把输入维度为 $C \times H \times W$ 的特征图 X 拆分成两个维度都为 $C/2 \times H \times W$ 的特征图 X_1 和 X_2 。还要把原本维度为 $C \times C \times H \times W$ 的卷积核 K 也拆分成维度都为 $C/2 \times C/2 \times H \times W$ 的四个作用不同的卷积核 K_1, K_2, K_3, K_4 。

接下来对有原始特征图 X 拆分出来的 X_1 和 X_2 进行处理, 其中 X_1 分成三路分别进行处理才能得到最终的输出 Y_1 而 X_2 只需要进行一次传统卷积操作就可以得到该部分的最终输出 Y_2 , 这些先写出特征图 X_2 的简单卷积操作的表达是为

$$Y_2 = F_1(X_2) = X_2 * K_1 \quad (4-20)$$

下面对特征图 X_1 的处理过程进行介绍, 在这个过程中对特征图 X_1 分成了三路并分别用卷积核 K_2, K_3, K_4 对特征图 X_1 进行卷积并执行自校准操作得到输出 Y_1 。在对特征图 X_1 进行自校准操作这一过程中实现特征图在两个不同的尺度空间中的卷积特征转换, 这主要是在特征图 X_1 原始的空间尺度和对特征图 X_1 进行下采样操作后的空间尺度。因为下采样后的特征图具有较小的分辨率和较大的感受野, 所有可以将该采样后得到的特征图进行卷积操作后得到的结果用于与原始特征图 X_1 经过卷积操作后的结果的校准操作来指导原始特征图 X_1 特征空间中的特征变换的过程。

在这个过程中执行的操作用数学表达式来描述时为先用大小为 $r \times r$ 的滤波器和步长也为 r 的对特征图 X_1 进行平均池化下采样并且此时下采样倍数也为 r , 那么这个过程的数学表达式如下

$$T_1 = \text{AvgPool}_r(X_1) \quad (4-21)$$

之后对下采样得到的结果进行卷积操作, 再通过上采样操作将下采样后的卷积结果这个小尺度的中间参考映射到原始的空间尺度, 这个过程可以用下面的式子表达

$$X'_1 = \text{Up}(F_2(T_1)) = \text{Up}(T_1 * K_2) \quad (4-22)$$

其中式子(4-22)中的 $\text{Up}(\)$ 表示的是双线性插值函数。

卷积核 K_3 对原始特征图 X_1 进行卷积操作后提取的特征值用 Sigmoid 激活函数根据上面得到的结果 X'_1 对它进行校准操作得到的就是该自校准操作的输出 Y_1 , 这个过程的表达式如下

$$\begin{aligned} Y'_1 &= F_3(X_1) \cdot \sigma(X_1 + X'_1) = (X_1 * K_3) \cdot \sigma(X_1 + X'_1) \\ Y_1 &= F_4(Y'_1) = Y'_1 * K_4 \end{aligned} \quad (4-23)$$

其中式子(4-23)中的 σ 表示的就是 Sigmoid 激活函数而 X'_1 可以理解为用来形成权重的残差。

最后将两个部分得到的最终输出 Y_1 和 Y_2 进行拼接得到最终输出的特征图 Y 。

4.5 无人机无线电信号分类识别算法

针对无人机无线电信号的分类识别问题,本文选择了改进的卷积神经网络算法分别是结合了注意力机制中的 SE 模块的残差神经网络模型和结合了自校准卷积模块的残差神经网络模型,同时结合图像处理的思路将无人机无线电信号转化为瀑布图和双谱图的形式并以此为训练集对构建的无人机无线电信号识别程序进行经过训练。

4.5.1 无人机信号瀑布图样本库

将无人机无线电信号的样本数据经过时频分析转化为瀑布图和双谱图,并将这些图片分为训练集和验证集建立无人机无线电信号图片形式的样本库。

实验采集了 10.5s 的背景信号和每种飞行状态下 5.25s 的共计 227 个信号样本,这些样本中每一个都包含了 10^7 个采样点。无人机无线电信号分类如表 4-1 所示

表 4-1 无人机无线电信号类型

信号类型	无无人机背景信	Bebop	AR Drone	DJI Phantom
1	背景信号			
2		起飞		
3		悬停		
4		正常飞行		
5		传输视频		
6			起飞	
7			悬停	
8			正常飞行	
9			传输视频	
10				起飞

为了增大样本数量,首先对信号进行切片处理,以 10^6 作为切片长度最终得到 2270 个信号样本。然后在这十种信号类型中选择 100 个信号片段作为接下来进行信号分类识别的样本组成共含有 1000 个信号作为训练集样本的样本库;这十种信号类型中选择 20 个信号片段作为接下来进行信号分类识别的样本组成共含有 200 个信号作为验证集样本的样本库;之后对选择出来样本信号进行转换,将这些无线电信号样本转化为时频分析图和双谱分析图,进而将无人机无线电信号识别问题转化为图像识别问题。

4.5.2 无人机信号分类算法

理论上对于一个深度卷积神经网络模型来说网络的越深模型的训练效果也就越好，因为每一层的神将网络都能从输入数据里提取到不同的特征信息而且这些特征信息之间的组合方式多种多样。但是实际上一些深度升级网络模型如 VGGNet 模型却并不能达到这样的效果，它们训练时的损失函数最开始是会逐渐减小但随着网络层数的不断加深损失函数不仅不会继续减小反而还可能增大。因此深度卷积神经网络模型中层数加深到一定层次后继续加深很有可能会出现梯度消失或者梯度爆炸等问题，这些问题极大地影响了深度神经网络模型的性能，而残差神经网络模型则正是为了改善这些情况而提出来的。

本文就选择了使用残差神经网络模型并对残差神经网络模型进行一定的改进以提高本文开发的无人机无线电信号分类识别程序的识别率。对残差神经网络模型来说它使用的传统卷积预定义了卷积核的大小也就控制了每个空间位置的感受野，很容易出现感受野获取不足的问题并出现易丢失上下文信息从而影响识别准确率的情况。针对残差神经网络模型存在的这个问题，本文分别选择了引入注意力机制中的 SE 模块和自校准卷积（SC）模块来对残差神经网络模型进行改进。残差神经网络模型中 resnet18/34 使用的残差块是 BasicBlock 而 resnet50/101/152 使用的残差块是 Bottleneck。比如 resnet50 就是四个分别由 3、4、6、3 个 Bottleneck 组成的模块再加上头尾等组成的一个深度神经网络。这两种常使用的残差结构的基本原理相同，其中 BasicBlock 结构中包含两个 3×3 的卷积层，Bottleneck 则是由 3 个分别为 1×1 、 3×3 、 1×1 的卷积层组成的。其结构如下图所示




图 4-11 两种残差结构

深度神经网络模型进行学习时虽然拥有了记忆力和注意力但是却没有人脑的注意力行为不能很好的关注上下文的信息，也就不能自动过滤掉不重要的信息并排除这些信息的干扰，这会导致深度神经网络模型存储的信息中有很很大一部分是无用的信息，而注意力机制就是使得深度神经网络模型能够模拟人脑的注意力行为提高对有用信息的关注以提高深度神经网络模型的性能。引入注意力机制后残差神经网络模型中的残差块结构需要在 BasicBlock 结构中加入 SE 模块的内容将其变为 SE-BasicBlock。本文用到的残差神经网络为 ResNet-50 和 ResNet-101，这两个网络模型使用的是 Bottleneck 进行堆叠，因此要得到 SE-ResNet-50 和 SE-ResNet-101 最主要的就是实现 SE-Bottleneck。根据上面的分析可以得到加入 SE 模块的残差结构图如下




图 4-12 加入 SE 模块的残差结构图

自校准卷积模块则是将一个标准的卷积操作拆分成多个小卷积操作,在不引入额外参数的前提下扩大全局感受野,以此来提取更丰富的图像特征信息进而提升深度神经网络模型的性能。本文中用到的网络模型为 SE-ResNet-50 和 SE-ResNet-101, ResNet-50 主要由四个残差学习模块组成,且这四个残差学习模块分别由 3、4、6、3 个 Bottleneck 模块组成。将自校准卷积模块引入该网络模型时主要将这四个残差

电子科技大学硕士学位论文

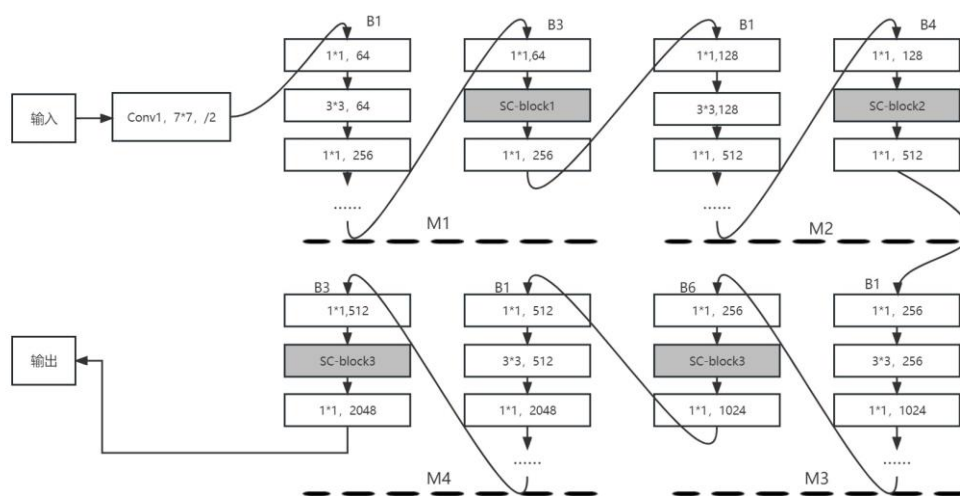


图 4-13 SC-ResNet 网络模型结构图

4.6 无人机信号分类识别算法仿真结果及分析

4.6.1 无人机信号分类算法仿真结果

将无人机无线电信号的瀑布图和双谱图建立的样本库输入到 SE 模块结合残差神经网络构建的 SE-ResNet 模型和自校准卷积结合残差神经网络构建的 SC-ResNet 模型，每一个模型运行 200 次取平均值可以得到不同算法分别为 50 层和 101 层时验证集的识别率如下表 4-2

表 4-2 不同算法的无人机无线电信号识别率

无人机信号 识别算法	数据集	时频分析识别率 (%)	双谱分析识别率 (%)
ResNet-50	本文信号瀑布图数据库	87.51	88.27
ResNet-101	本文信号瀑布图数据库	88.73	89.45
SE-ResNet-50	本文信号瀑布图数据库	89.05	89.94
SE-ResNet-101	本文信号瀑布图数据库	90.83	91.78
SC-ResNet-50	本文信号瀑布图数据库	90.67	91.62
SC-ResNet-101	本文信号瀑布图数据库	91.54	92.86

表 4-2 列举了残差神经网络模型、结合自校准卷积模型的残差神经网络模型和结合注意力机制的残差神经网络模型的信号识别率, 由表中可以看出由双谱分析得到的信号特征图作为输入时无人机识别率高于由时频分析得到的信号特征图作

为输入的识别率，还可以得出 SE-ResNet 模型和 SC-ResNet 模型无论为 50 层还是为 101 层都可以有效的提高无人机无线电信号的识别率，并且 SC-ResNet 模型的提升效果更明显。

4.6.2 仿真结果的评价指标及分析

从信号的识别率可以看出使用的深度神经网络模型在验证集上对无人机无线电信号瀑布图的识别性能但是却无法从最终的识别率上得出模型对每一类信号识别的准确率，所以这里引入混淆矩阵(confusion matrix)来进一步的得出这些网络模型对每一类信号的识别率和各个类别之间的混淆情况。

混淆矩阵也被称为误差矩阵，它主要是通过通过对不同精度的评价从不同的方面来反映图像分类的精度。混淆矩阵就是分类算法的一个总结矩阵并在机器学习等分类算法中的模型精度评价中得到了广泛的应用。可以说混淆矩阵就是表示精度评价的一种标准格式且它的表示形式就是一个 $n \times n$ 的矩阵，比如对于一个二分类算法来说对于的混淆矩阵就是一个 2×2 的矩阵。对于混淆矩阵来说其纵坐标为真实类别并用 y 来表示，横坐标为预测类别并用 x 来表示那么可以得出矩阵中的每一格 (x, y) 表示的则是真实类别为 y 并被识别为预测类别 x 的数目。对于每一个类别来说可能出现的情况一共有四种，如图 4-14 所示




图 4-14 混淆矩阵

根据图 4-14 可以得出对于某一类别如类别 3 会出现 TP (True Positive)、FN (False Negative)、FP (False Positive)、和 TN (True Negative) 这四种情况，其中 TP 也就是真正样本的意思并且表示的是真实类别和经过分类模型后预测出来的类

别相同的情况，FN 也就是假负样本的意思表达的意思是真实类别为 3 的样本经过分类模型预测出来的结果却是属于其他的类别，FP 也就是假正样本的意思并且表达的是真实类别不是类别 3 的样本经过分类模型后却被预测为了类别 3，TN 是真负样本的意思并且表示的是真实类别不是类别 3 经过分类预测模型后预测出来的结果也不属于类别 3 的情况。

根据这四种情况可以进一步的计算出每一类数据对应的查全率（Recall）和查准率（Precision），其中查全率又被称为召回率表示的是所有的真实类别是类别 3 的数据中有多少经过分类模型后也被准确地预测为了类别 3，并且可以得出查全率的数学表达式为

$$Recall = \frac{TP}{TP + FN} \quad (4-24)$$

另一个查准率又被称为精确率并且表示了在经过分类模型后所有被预测为类别 3 的数据中一共有多少数据样本的真实类别就是类别 3，可以得出它的数学表达式如下

$$Precision = \frac{TP}{TP + FP} \quad (4-25)$$

根据查全率和查准率的定义可以绘出关于这两中精度的混淆矩阵，如下图 4-15 是 SC-ResNet-101 模型的查全率情况，如图 4-16 是 SC-ResNet-101 模型的查准率情况




图 4-15 SC-ResNet-101 模型查全率

如图 4-15 所示可以看出本文中 10 种无人机无线电信号经过 SC-ResNet-101 模型的识别率都达到了 80% 以上, 其中表示无无人机背景信号的信号类 1 和表示 DJI Phantom 无人机起飞时信号的信号类别 10 都达到了 100% 的识别率, 这些都证明了该 SC-ResNet-101 模型在本文中识别无人机无线电信号类别的有效性




图 4-16 SC-ResNet-101 模型查准率

如图 4-16 所示可以看出本文中 10 种类别的无人机无线电信号经过 SC-ResNet-101 模型处理后查准都达到了 90% 以上, 这个结果也证明了 SC-ResNet-101 模型在本文中对无人机无线电信号进行识别的有效性。

4.7 无线电环境中无人机信号识别

使用狄利克雷混合模型完成无线电信号分类形成原始分类数据库, 依据简单随机抽样法从原始分类库中按类抽样并绘出抽样得到的原始信号的瀑布图和双谱图生成待处理样本数据库。最后训练完成的无人机无线电信号识别程序处理该样本数据库, 完成对陌生无线电环境中无人机信号的识别。

为满足从原始分类数据库中筛选的样本信号能更好的反应这一类信号整体情况的要求, 本文在筛选样本信号时选择了分层随机抽样法。分层随机抽样是将需要进行抽样的总体按照层间差异尽可能小而层内差异尽可能大的要求划分为不同的层或者称为不同的子总体, 然后再分别从每一层按照某种抽样设计抽取样本单元。分层随机抽样不仅比简单随机抽样的误差更低, 还能把各层当作独立的总体进而在估计总体的同时也能分析各分层的情况。各分层也就是各子总体之间的抽样

相互独立, 因此在不同的分层进行抽样的时候还可以选择如比例分配、最优分配等不同的抽样方法, 从而大大提高了分层随机抽样的灵活性。

用训练后的无人机无线电信号分类识别程序处理抽样得到的信号的瀑布图和双谱图即可以得出该抽样信号是否为无人机无线电信号, 其中测试结果示例如下图 4-17 所示。从图 4-17 可以看出抽样信号是否为无人机无线电信号并可以进一步根据某一类型无线电信号抽样后的测试结果推断该类型无线电信号是否为无人机信号, 若该类型无线电信号抽样后的测试结果或者该无线电环境中其他类型的信号中有某一类型信号的抽样测试结果大部分都是无人机无线电信号, 那就可以判断该无线电环境中存在无人机, 并可以在存在无人机的情况下进一步的判断出该无人机的型号和飞行状态。

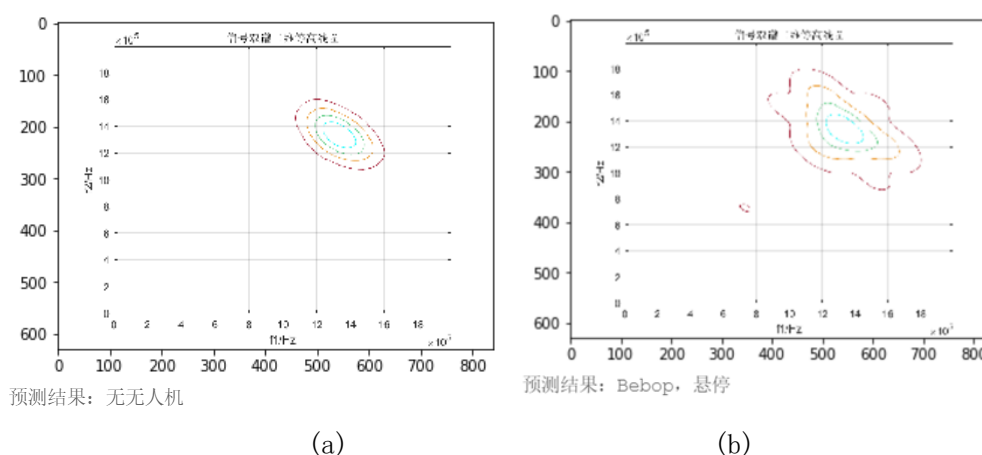


图 4-17 无人机信号识别结果

(a) 背景信号识别结果 (b) Bebop 无人机信号识别结果

4.8 本章小结

本章主要实现了结合自校准卷积模块和 SE 模块的残差神经网络模型对无人机无线电信号的识别与分类及其仿真实现。先将无人机无线电信号进行切分并去除无人机无线电信号中无无人机信号表达的片段, 最终建立无人机无线电信号的训练集和验证集。将这些样本信号转化为时频图和双谱图, 将时频图和双谱图作为上面开发的无人机无线电信号分类识别程序的样本库并利用该样本库对无人机识别程序进行训练、验证。最后用训练后的无人机信号识别程序对分类并抽样得到的未知无线电环境中的信号样本进行处理以实现对该未知无线电环境中是否存在无人机的识别。

第五章 全文总结与展望

5.1 全文总结

随着无人机技术的逐渐成熟其应用领域也在不断的扩展，从军事领域到现在的工业和民用无人机逐步走进大家的日常生活，尤其是在救援搜索和航空拍摄等方面。但不可忽略的是无人机在给大家带来便利的同时也带来了各种问题，尤其是在政府部门、科研机构、机场和一些大型活动现场等敏感和人员密集的情况下。这些场景下能够从周围的复杂无线电环境中发现“黑飞”无人机就变得尤为重要。要从复杂的无线电环境中识别“黑飞”的无人机，就需要对该复杂无线电环境中的无线电信号进行分析。

无线通信是当前运用最为广泛的通信方式且无线电信号的识别技术在军用和民用通信领域都有着重要的地位。各种类型的以无线电通信为载体的设备和各种复杂的信号先后大规模的应用更进一步增加了电磁环境的复杂性而对无线电通信信号的识别也变得愈发重要，同时也导致了在复杂电磁环境下对非法使用和在非合作信道中的分析变得更加困难。因此本文提出了先对未知复杂无线电环境中的无线电信号进行分类，将分类并筛选后的信号输入无人机无线电信号识别程序的流程以预测该未知无线电环境中是否存在无人机信号，主要研究内容如下：

1. 对未知且复杂的无线电环境中信号进行分类时选用的不需要预先确定信号类型数目等先验知识的狄利克雷混合模型并对相关的理论知识进行了介绍，如贝叶斯无参模型概念、狄利克雷分布和狄利克雷过程以及狄利克雷过程的几种构造方法，并根据狄利克雷模型和断棍模型完成了狄利克雷混合模型的构造并分析了对狄利克雷混合模型求解时常用的两种算法。
2. 对复杂无线电环境中的无线电信号进行数据切片、异常数据剔除和滤波去噪等预处理以便于后续的特征提取。在对无线电信号特征进行提取时，本文选择了无线电信号的带宽、循环频率和载波频率这三个参数，其中对无线电信号的带宽选择了修正的平均周期图法，对无线电信号的循环频率和载波频率的提取则选择了循环谱法。在本章中还根据狄利克雷混合模型提出了本文的无线电信号分类系统模型及其算法，将由无线电信号的特征向量组成的数据库输入该无线电信号分类模型完成复杂无线电环境中的无线电信号分类，最后从每一类无线电信号中采用分层随机抽样法筛选出作为识别该复杂无线电环境中是否有无人机信号存在的样本数据。

3. 实现了无人机无线电信号分类识别程序的,将分类并筛选后的样本信号输入该程序即可完成对无人机信号的分类识别。先将无人机无线电信号的瀑布图和双谱分析图建立为无人机无线电信号分类识别程序的数据库,这一过程将无人机无线电信号的分类识别转换成图像识别问题。对无人机无线电信号的分类识别选择了使用图像分类的最常用模型残差神经网络并将自校准卷积模块和 SE 模块与之结合,无人机无线电信号瀑布图和双谱分析图建立的样本库作为训练集和验证集输入改进的卷积神经网络模型并经过训练得到无人机无线电信号分类识别程序,将上面分层抽样得到样本数据作为输入即可判断该复杂无线电环境是否存在无人机信号。

5.2 问题与展望

本文主要完成了复杂无线电环境中无线电信号的分类,并将分类后的信号经过分层随机抽样筛选出的样本输入到无人机无线电信号识别程序完成未知无线电环境中无人机的识别流程。由于时间和条件限制,本文无法对某些方面做更深入的研究,针对后续研究工作,现提出以下两点展望:

- 1、本文提出的基于狄利克雷混合模型的无线电信号分类模型在信号类型数目较多的情况下分类性能一般,针对信号类型数目多的场景需要进一步的研究。
- 2、在无人机无线电信号分类识别时样本库建立是将无人机信号转化为时频图和双谱分析图。本文建立的无人机无线电信号瀑布图和双谱分析图数据库仅有 1000 个样本,样本库数据量较小,可以继续更新样本库并对无人机信号识别程序进行训练。
- 3、本文中仅对三种型号的无人机无线电信号进行研究,同时每一种型号也仅有一架无人机的数据。无人机型号数目和同一型号不同无人机个体数目都存在不足的问题,后续可以针对这两个方面进行更深入的研究。

参考文献

- [1] Nguyen P, Ravindranatha M, Nguyen A, et al. Investigating Cost-effective RF-based Detection of Drones[C]. ACM, 2016:17-22.
- [2] Li D, Yang R, Li X, et al. Radar Signal Modulation Recognition Based on Deep Joint Learning[J]. IEEE Access, 2020, PP (99):1-1.
- [3] Işık G and Artuner H. Recognition of radio signals with deep learning Neural Networks[C]. Signal Processing & Communication Application Conference. IEEE, 2016.
- [4] Dauphin Y, Pascanu R, Gulcehre C, et al. Identifying and attacking the saddle point problem in high-dimensional non-convex optimization[J]. Advances in neural information processing systems, 2014, 27.
- [5] Dobre O. A, Bar-Ness Y and Su W. Higher-Order Cyclic Cumulants for High Order Modulation Classification[C]. Military Communications Conference, IEEE, 2003.
- [6] Zhang Z, Li Y, Zhu X, et al. A Method for Modulation Recognition Based on Entropy Features and Random Forest[C]. 2017 IEEE International Conference on Software Quality, Reliability and Security Companion (QRS-C). IEEE, 2017.
- [7] Wu Z, Zhou S, Yin Z, et al. Robust Automatic Modulation Classification under Varying Noise Conditions[J]. IEEE Access, 2017:1-1.
- [8] 袁海英, Xun S, Haitao L. The modulation recognition based on decision-making mechanism and neural network integrated classifier[J]. 高技术通讯: 英文版, 2013(2):5.
- [9] Kim K, Akbar I, Bae K, et al. Cyclostationary Approaches to Signal Detection and Classification in Cognitive Radio[C]. New Frontiers in Dynamic Spectrum Access Networks, IEEE, 2007.
- [10] Baldo N and Zorzi M. Learning and Adaptation in Cognitive Radios Using Neural Networks[C]. Consumer Communications & Networking Conference. IEEE, 2013.
- [11] Taj M. I and Akil M. Cognitive Radio Spectrum Evolution Prediction using Artificial Neural Networks based Multivariate Time Series Modelling[M]. 2011.
- [12] Zhuo Y, Yao Y. D and Sheng C, et al. MAC protocol classification in a cognitive radio network[C]. The 19th Annual Wireless and Optical Communications Conference(WOCC 2010),IEEE, 2010.
- [13] Petrova M, Mähönen P and Osuna A. Multi-class classification of analog and digital signals in cognitive radios using Support Vector Machines[J]. IEEE, 2010.

- [14] Clancy T, Khawar A and Newman T. Robust signal classification using unsupervised learning[J]. IEEE Transactions on Wireless Communications, 2011,10(4): 1289-1299.
- [15] Bouguila N and Ziou D. A dirichlet process mixture of Dirichlet distributions for classification and prediction[C]. IEEE Workshop on Machine Learning for Signal Process, Cancun, Mexico, October, 2008, 297-302.
- [16] Shetty N, Pollin S, Pawelczak P. Identifying Spectrum usage by unknown systems using experiments in machine learning[C]. IEEE wireless communications and network conference, Budapest, Hungary, 2009, 1-6.
- [17] 杨亚南. 无人机信号的侦收与识别方法研究[D].电子科技大学,2018.
- [18] Nemsick L. W and Geraniotis E. Adaptive multichannel detection of frequency-hopping signals[J]. IEEE Transactions on Communications, 1992, 40(9):1502-1511.
- [19] Weber J, Kowalske K, Robertson C, et al. Detection of Frequency-Hopped Waveforms Embedded in Interference Waveforms with Noise. 2007 IEEE International Conference on Communications, 2007, pp. 2973-2978, doi: 10.1109/ICC.2007.494.
- [20] 孙德刚,王友军,王文,魏冬.基于 HOG 的跳频信号自动化检测模型[J].通信技术,2018,51(04):758-762.
- [21] 蔡传雨. 无人机测控信号识别与截获方法研究[D].电子科技大学,2017.
- [22] 陈君胜,杨小勇,徐怡杭.基于遥控信号频谱特征的无人机识别算法[J].无线电工程,2019,49(02):101-106.
- [23] 章鹏飞,李刚,霍超颖,殷红成.基于双雷达微动特征融合的无人机分类识别[J].雷达学报,2018,7(05):557-564.
- [24] 卢宏涛,张秦川.深度卷积神经网络在计算机视觉中的应用研究综述[J].数据采集与处理,2016(1):1-17.
- [25] 陈含欣,江桦,崔伟亮.一种基于形态学预处理的时频检测算法[J].信息工程大学学报,2010,11(04):438-442.
- [26] 李琰,李天昀,葛临东.一种基于图像分割和模板匹配的短波跳频信号盲检测算法[J].信息工程大学学报,2010,11(06):756-761.
- [27] 马旗,朱斌,张宏伟,等.基于优化 YOLOv3 的低空无人机检测识别方法[J].激光与光电子学进展,2019, 56(20).
- [28] 王靖宇,王霁禹,张科,等.基于深度神经网络的低空弱小无人机目标检测研究[J].西北工业大学学报,2018, v.36;No.170(02):63-68.
- [29] 马旗,朱斌,程正东,等.基于双通道的快速低空无人机检测识别方法[J].光学学报,2019, 39(12).

- [30] 马旗, 孙晓军, 张杨,等. 基于红外图像的低空无人机检测识别方法[J]. 弹箭与制导学报, 2020, 40(3):5.
- [31] LIU J, HOU Q, CHENG M, et al. Improving convolutional networks with self-calibrated convolutions. 2020IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Seattle, WA, USA, 2020: 10093-10102.
- [32] Jie H, Li S, Gang S, et al. Squeeze-and-Excitation Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, PP (99).
- [33] Wasserman L. All of Nonparametric Statistics[M]. Berlin: Springer, 2006, 183-195.
- [34] Bkassiny M, Jayaweera S. K, Li Y, et al. Blind cyclostationary feature detection based spectrum sensing for autonomous self-learning cognitive radios[C]. IEEE International Conference on Communications, Ottawa, Canada, 2012, 1507-1511.
- [35] West M. Hyperparameter estimation in Dirichlet process mixture models[R]. NC USA: Duke University, 1992.
- [36] King N. J and Lawrence N. D. Fast variational inference for Gaussian process models through KL-correction[C]. 17th European Conference on Machine Learning, Berlin, Germany, 2006, 270-281.
- [37] Bishop C. M. Pattern recognition and machine learning[M]. Singapore: Springer Science and Business Media, 2006, 461-558.
- [38] Ciblat P, Loubaton P, Serpedin E, et al. Asymptotic analysis of blind cyclic correlation-based symbol-rate estimators [J]. IEEE Transactions on Information Theory. 2002, 48 (7): 1922–1934.
- [39] López-Salcedo J A, Vázquez G. Asymptotic equivalence between the unconditional maximum likelihood and the square-law nonlinearity symbol timing estimation [J]. IEEE Transactions on Signal Processing. 2006, 54 (1): 244–257.
- [40] Hurd H L, Gerr N L. Graphical Methods for Determining the Presence of Periodic Correlation [J]. Journal of Time Series Analysis. 1991, 12 (4): 337–350.
- [41] Dandawate A, Giannakis G. Statistical tests for presence of cyclostationarity [J]. IEEE Transactions on Signal Processing. 1994, 42 (9): 2355–2369.
- [42] 盖荣丽, 蔡建荣, 王诗宇, 仓艳, 陈娜. 卷积神经网络在图像识别中的应用研究综述[J]. 小型微型计算机系统, 2021, 42(09): 1980-1984.
- [43] Schmidhuber J. Deep learning in neural networks: An overview[J]. Neural Networks: The Official Journal of the International Neural Network Society, 2015, 61: 85-117
- [44] 张全新. 深度学习中的图像分类与对抗技术 [M]. 北京: 北京理工大学出版社, 2020
- [45] 张重生. 深度学习原理与应用实践 [M]. 北京: 电子工业出版社, 2016

- [46] 李玉鉴, 张婷. 深度学习导论及案例分析 [M]. 北京: 机械工业出版社, 2016
- [47] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25: 1097-1105
- [48] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]. 3rd International Conference on Learning Representations (ICLR 2015), 2015, 1-14
- [49] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, 770-778